

学校代码	10699
分 类 号	TP183
密 级	公开
学 号	2023264157



西北工业大学
NORTHWESTERN POLYTECHNICAL UNIVERSITY

硕士学位论文

专业学位研究生

题目 基于视觉配准的无人飞行器
定位方法的研究

作者 黄如意

专 业 领 域 软件工程

指 导 教 师 魏倩茹 副教授

培 养 单 位 软件学院

申 请 日 期 2026 年 6 月

西北工业大学

硕士学位论文

题目：基于视觉配准的无人飞行器
定位方法研究

专业领域：软件工程

作者：黄如意

指导教师：魏倩茹

2026 年 6 月

**Title: Research on UAV Localization Methods
Based on Visual Registration**

By
RuYi Huang
Under the Supervision of Professor
QianRu Wei

A Dissertation Submitted to
Northwestern Polytechnical University

In Partial Fulfillment of The Requirement
For The Degree of
Master of Software Engineering

Xi'an P. R. China
June/2026

学位论文评阅人和答辩委员会名单

学位论文评阅人名单

姓名	职称	工作单位
全盲评阅	无	无
全盲评阅	无	无

答辩委员会名单

答辩日期	2026 年 6 月 5 日		
答辩委员会	姓名	职称	工作单位
主席	徐韬	教授	西北工业大学软件学院
委员	黎昞	副教授	西北工业大学软件学院
委员	解虎	高工	西安空间无线电技术研究所
秘书	郭佳	副教授	西北工业大学软件学院

摘要

随着无人机技术的广泛应用，在 GPS 拒止的复杂场景下，基于图像配准的地理定位技术在无人机的高精度自定位与自主导航中发挥着至关重要的作用。该技术将无人机实时拍摄的图像与卫星基准图像库进行特征匹配，检索到特征距离最近的卫星参考图像，进而解算无人机地理坐标，实现无人机的自定位。该方法有效克服了传统定位方式的局限，但在实际应用中，该匹配过程主要面临两大核心挑战：一是跨视角特征不一致，无人机与卫星视图的成像机理和观测模式的不同，导致两类视图在空间、尺度和语义上存在显著差异，制约了跨视图配准定位精度；二是有效特征稀疏，无人机与卫星视图的纹理信息薄弱与关键地理目标占比不足导致的特征稀疏问题，影响了配准与定位的有效性。针对以上问题，本文的主要研究内容和贡献如下：

(1) 针对无人机与卫星视图间的几何错位、尺度差异及语义差异导致的跨视图特征不一致问题，提出基于视图校正与尺度自适应的图像配准地理定位方法。首先，构建语义引导视图校正模块，利用语义先验驱动空间仿射变换，将倾斜视角的无人机特征投影至近似正射空间以消除几何错位；随后，设计尺度自适应特征校准模块，通过动态匹配语义粒度并校正空间布局偏移，有效缓解特征的尺度差异并提供统一尺度对齐基准；最后，提出跨视角语义对齐模块，构建跨视图的局部与全局交互机制，促使跨视图特征相互引导与自适应加权，从而抑制非共有区域特征并强化共有静态地物特征。实验结果表明，所提出方法在大视角差异场景下实现了高精度的图像配准与地理定位。

(2) 针对无人机与卫星视图的纹理信息薄弱和关键地理目标占比不足导致的特征稀疏问题，提出基于特征补全与特征增强的图像配准地理定位方法。首先，设计多尺度几何结构编码器，引入法线图像的几何先验信息，对可见光图像的弱纹理区域进行特征补全以构建结构化表征；随后，提出空间引导语义增强模块，利用获取的空间结构先验动态校准特征通道，精准激活并定向增强关键地理目标占比不足导致的稀疏语义特征响应；最后，构建频域感知背景抑制模块，通过小波变换卷积在频域解耦前景与背景特征，并自适应抑制背景噪声以提升稀疏前景特征信噪比。实验结果表明，所提出方法在弱纹理等特征稀疏场景下实现了高精度的图像配准与地理定位。

(3) 针对算法面向无人飞行器机载边缘平台部署时面临的算力限制与实时性需求，设计并实现了基于图像配准算法的地理定位系统。测试结果表明，该系统在保持较高定位精度的同时，降低了模型存储开销，并在机载边缘计算设备上实现了稳定的实时推理，推动了理论模型向实际工程应用的转化。

关键词：无人机视图；卫星视图；图像配准；地理定位

Abstract

With the widespread application of unmanned aerial vehicle (UAV) technology, image registration-based geolocalization plays a crucial role in high-precision self-localization and autonomous navigation of UAVs in GPS-denied complex scenarios. This technology matches images captured by UAVs in real time with a satellite reference image database, retrieves the satellite reference image with the closest feature distance, and further estimates the geographic coordinates of the UAV to achieve self-localization. Although this method effectively overcomes the limitations of traditional positioning approaches, the matching process still faces two major challenges in practical applications. First, the feature inconsistency between UAV and satellite views is caused by differences in imaging mechanisms and observation patterns, which leads to significant discrepancies in spatial structure, scale, and semantics, thereby restricting the accuracy of cross-view registration and geolocalization. Second, feature sparsity caused by weak texture information and insufficient proportions of key geographic targets in UAV and satellite views affects the effectiveness of registration and localization. To address these issues, the main research contents and contributions of this thesis are as follows.

(1) To address the cross-view feature inconsistency caused by geometric misalignment, scale variation, and semantic discrepancy between UAV and satellite views, an image registration-based geolocalization method with view correction and scale adaptation is proposed. First, a semantic-guided view correction module is constructed, where semantic priors are used to drive spatial affine transformation and project oblique UAV features into an approximately orthographic space, thereby reducing geometric misalignment. Then, a scale-adaptive feature calibration module is designed to dynamically match semantic granularity and correct spatial layout offsets, effectively alleviating scale discrepancies and providing a unified scale-alignment basis. Finally, a cross-view semantic alignment module is proposed to establish local and global interaction mechanisms across views, enabling cross-view features to guide each other and be adaptively weighted. In this way, non-shared regional features are suppressed while shared static geographic features are enhanced. Experimental results demonstrate that the proposed method achieves high-precision image registration and geolocalization in scenarios with large viewpoint differences.

(2) To address the feature sparsity problem caused by weak texture information and insufficient proportions of key geographic targets in UAV and satellite views, an image registration-based geolocalization method with feature completion and feature enhancement is

proposed. First, a multi-scale geometric structure encoder is designed to introduce geometric prior information from normal images, completing features in weak-texture regions of visible images and constructing structured representations. Then, a spatial-guided semantic enhancement module is proposed, which dynamically calibrates feature channels using the acquired spatial structure priors, accurately activating and directionally enhancing sparse semantic feature responses caused by the insufficient proportion of key geographic targets. Finally, a frequency-aware background suppression module is constructed. Through wavelet-transform convolution, foreground and background features are decoupled in the frequency domain, and background noise is adaptively suppressed to improve the signal-to-noise ratio of sparse foreground features. Experimental results show that the proposed method achieves high-precision image registration and geolocalization in feature-sparse scenarios such as weak-texture environments.

(3) To meet the computational constraints and real-time requirements of UAV onboard edge deployment, a geolocalization system based on the proposed image registration algorithms is designed and implemented. Test results indicate that the system reduces model storage overhead while maintaining high localization accuracy, and achieves stable real-time inference on onboard edge computing devices, promoting the transition of theoretical models toward practical engineering applications.

Keywords: UAV view; Satellite view; Image registration; Geo-localization

缩写对照表

缩写	英文全称	中文全称
LTE	Lite Transformer Encoder	轻量级 Transformer 编码器
STN	Spatial Transformer Network	空间变换网络
VCSA-Net	View Correction and Scale-Adaptive Network	基于视图校正与尺度自适应的 图像配准网络
FCFE-Net	Feature Completion and Feature Enhancement Network	基于特征补全与特征增强的图 像配准网络
VRM	Semantic-guided View Rectification Module	语义引导视图校正模块
SAM	Scale Adaptive Feature Calibration Module	尺度自适应特征校准模块
CSM	Cross-view Semantic Alignment Module	跨视角语义对齐模块
GGF	Global Guided Enhancement Flow	全局引导增强流
LRF	Local Reconstruction Enhancement Flow	局部重构增强流
GSAM	Geometric Spatial Alignment Module	几何空间对齐子模块
MSCM	Multi-Scale Perception Module	多尺度感知子模块
SCA	Spatial Coordinate Attention	空间坐标注意力
CLIM	Cross-view Local Interaction Module	跨视角局部交互子模块
CGIM	Cross-view Global Interaction Module	跨视角全局交互子模块
MGSE	Multi-scale Geometric Structure Encoder	多尺度几何结构编码器
SEM	Spatial-Guided Semantic Enhancement Module	空间引导语义增强模块
FSM	Frequency-Domain-Aware Background Suppression Module	频域感知背景抑制模块
SGIM	Semantic-Geometry Feature Interaction Module	语义-几何特征交互模块
MSFA	Multi-scale Feature Aggregation Module	多尺度特征聚合模块
SSPM	Spatial Structure Perception Module	空间结构感知子模块
SFEM	Semantic Feature Enhancement Module	语义特征增强子模块
WTConv	Wavelet Transform Convolution	小波变换卷积
ABS	Adaptive Background Suppression Attention	自适应背景抑制注意力
R@K	Recall@K	召回率
AP	Average Precision	平均精度

目 录

摘 要.....	I
Abstract	III
缩写对照表.....	V
第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于传统方法的图像配准地理定位方法.....	2
1.2.2 基于深度学习的图像配准地理定位方法.....	3
1.3 论文组织架构.....	5
第 2 章 相关理论基础与技术.....	9
2.1 ConvNeXt 网络.....	9
2.2 Lite Transformer Encoder	10
2.3 Spatial Transformer Network.....	11
2.3.1 定位网络.....	11
2.3.2 网格生成器.....	12
2.3.3 采样器.....	12
2.4 基于 Omnidata 预训练模型的法线生成方法.....	13
2.4.1 Omnidata 数据管线生成方法.....	13
2.4.2 法线估计模型的网络结构与训练.....	13
2.5 小波变换.....	14
2.6 数据集及评价指标.....	15
2.6.1 数据集.....	15
2.6.2 评价指标.....	17
2.7 本章小结.....	17
第 3 章 基于视图校正与尺度自适应的图像配准的地理定位方法.....	19
3.1 引言.....	19
3.2 总体结构.....	19
3.3 语义引导视图校正模块 VRM.....	21
3.3.1 全局引导增强流 GGF.....	22
3.3.2 局部重构增强流 LRF.....	23
3.3.3 几何空间对齐子模块 GSAM	24

3.4 尺度自适应特征校准模块 SAM	25
3.4.1 多尺度感知子模块 MSCM	26
3.4.2 空间坐标注意力 SCA	27
3.5 跨视角语义对齐模块 CSM	28
3.5.1 跨视角局部交互子模块 CLIM	29
3.5.2 跨视角全局交互子模块 CGIM	30
3.6 损失函数	31
3.7 实验与分析	32
3.7.1 实验环境与参数设置	32
3.7.2 消融实验	34
3.7.3 对比实验	40
3.8 本章小结	51
第 4 章 基于特征补全与特征增强的图像配准的地理定位方法	53
4.1 引言	53
4.2 总体结构	53
4.3 多尺度几何结构编码器 MGSE	55
4.3.1 语义-几何特征交互模块 SGIM	55
4.3.2 多尺度特征聚合模块 MSFA	58
4.4 空间引导语义增强模块 SEM	59
4.4.1 空间结构感知子模块 SSPM	60
4.4.2 语义特征增强子模块 SFEM	61
4.5 频域感知背景抑制模块 FSM	62
4.5.1 小波变换卷积 WTConv	62
4.5.2 自适应背景抑制注意力 ABS	64
4.6 损失函数	65
4.7 实验结果与分析	65
4.7.1 实验环境与参数设置	65
4.7.2 消融实验	66
4.7.3 对比实验	74
4.8 本章小结	83
第 5 章 基于图像配准算法的地理定位系统设计与实现	85
5.1 引言	85
5.2 系统需求分析	85
5.2.1 功能需求分析	85

5.2.2 性能需求分析	86
5.3 系统总体设计	87
5.3.1 设计原则	87
5.3.2 系统功能设计	88
5.3.3 系统流程设计	89
5.4 系统详细设计	90
5.4.1 数据预处理模块	90
5.4.2 模型转换部署模块	90
5.4.3 定位算法推理模块	92
5.4.4 定位后处理与可视化模块	93
5.5 系统测试	94
5.5.1 模型复杂度与推理效率测试	94
5.5.2 系统场景验证与测试	95
5.6 本章小结	97
第 6 章 总结与展望	99
6.1 全文总结	99
6.2 未来展望	100
参考文献	101
致 谢	109
在学期间发表的学术成果和参加科研情况	111

第 1 章 绪论

1.1 研究背景与意义

近年来,无人飞行器(Unmanned Aerial Vehicle, UAV)凭借机动性强、部署灵活、视野开阔和目标可见性高等优势,已广泛应用于智能物流配送^[1-3]、自动驾驶^[4, 5]、农业植保^[6, 7]、灾害救援等领域。随着任务场景由开阔环境逐渐扩展至城市峡谷、林区、灾害现场和复杂电磁环境,无人机对自主定位与导航能力的依赖不断增强,地理定位已成为支撑其稳定执行任务的基础环节。

当前,无人机定位与导航主要依赖全球定位系统(GPS)等卫星导航设备,该方式通常需要稳定、通畅的卫星信号作为保障。然而,在城市峡谷、森林覆盖、复杂电磁干扰或人为拒止等场景下,GPS 信号容易出现衰减、中断或失效,导致传统定位系统难以持续、准确地获取无人机地理位置。因此,面向 GPS 受限甚至完全不可用场景的高精度自定位技术^[3, 8-18],已成为无人机自主导航领域的重要研究方向。


在此背景下,基于视觉配准的跨视图地理定位技术为无人机自定位提供了不依赖 GPS 信号的视觉定位途径。该技术通常将无人机实时拍摄的查询图像与预先构建的卫星图像数据库进行特征提取与相似性匹配,通过检索特征距离最近的卫星参考图像,进一步估计无人机所在位置。与单纯依赖卫星导航信号的定位方式相比,基于视觉配准的定位方法能够利用场景外观、地物分布和空间结构信息完成位置推断,可作为 GPS 受限或失效条件下的重要定位手段,也为无人机在复杂环境中的自主导航提供技术支撑。

尽管现有基于深度学习的视觉配准方法^[19-25]在跨视图地理定位任务中取得了一定进展,但在真实复杂环境和实际工程部署中仍面临多方面挑战。一方面,无人机视图与卫星视图在成像角度、空间布局、尺度分布和语义内容上存在显著差异,容易造成跨视角特征表征不一致,降低了图像匹配与定位精度。另一方面,在城郊弱纹理或关键地理目标占比有限的区域,视图有效匹配特征呈稀疏分布,导致跨视图匹配所需的判别性特征不足,削弱了配准结果的可靠性。最后,深度神经网络模型通常具有较高的参数量和计算复杂度,直接部署到算力受限的无人机边缘计算平台时,容易产生较高推理延迟,难以满足实际飞行任务对实时性的要求。

综上所述,面向 GPS 受限环境下的无人机自主定位需求,研究基于视觉配准的无人飞行器定位方法,围绕复杂环境下跨视图特征不一致、有效特征稀疏以及边缘端实时部署等关键问题开展算法设计与系统实现,不仅有助于提升无人机在 GPS 受限环境中的高精度自定位能力,也对推动无人机视觉定位技术的工程化应用具有重要的理论意义和实用价值。

1.2 国内外研究现状

跨视角图像地理定位是视觉定位与图像检索领域的重要研究方向，相关研究主要围绕图像特征表达、跨视角匹配机制以及视角差异建模等方面展开。现有综述研究已对该领域的发展脉络进行了较为系统的归纳，认为跨视角图像地理定位方法经历了由人工特征匹配向深度特征学习不断演进的过程^[26]。结合本文所研究的无人机—卫星图像配准定位任务，本节从特征提取与匹配方式的角度对相关研究进行梳理，如图 1-1 所示，主要包括基于传统方法的图像配准地理定位方法和基于深度学习的图像配准地理定位方法两类。其中，基于深度学习的方法又可根据是否显式引入视角差异处理机制，进一步归纳为无视角对齐处理、基于传统图像变换和基于图像生成的方法。



1.2.1 基于传统方法的图像配准地理定位方法

传统的图像配准地理定位方法主要依赖人工设计的局部特征描述符建立查询图像与参考图像之间的视觉对应关系^[27-30]。在该类方法中，图像通常首先被表示为一组具有局部不变性的特征点，这些特征点主要来源于图像中的颜色、纹理、形状、灰度、梯度以及局部极值区域等视觉信息^[31]。典型的局部特征描述符包括尺度不变特征变换（Scale-Invariant Feature Transform, SIFT）^[32]、加速稳健特征（Speeded-Up Robust Features, SURF）^[33]和旋转不变特征（Oriented FAST and Rotated BRIEF, ORB）^[34]等。为了获得更适合图像级匹配的整体描述，局部特征通常还会通过视觉词袋（Bag of Visual Words, BOVW）^[35]、局部聚合描述符向量（Vector of Locally Aggregated Descriptors, VLAD）^[36]或 Fisher 向量^[37]等方式进行聚合，从而形成全局图像表示。随后，系统可通过欧氏距离、余弦相似度或机器学习分类器对图像特征进行相似性计算，进而完成图像检索与地理位置匹配。

早期跨视角地理定位研究多围绕局部特征提取、特征索引和空间一致性约束展开。Zamir 和 Shah 通过构建谷歌街景图像数据集，提取 SIFT 特征并结合投票机制实现查询图像定位^[38]；Bansal 等人在自相似描述子的基础上引入尺度归一化策略，增强了街景图像与航空图像之间的匹配能力^[39]；Lin 等人进一步融合方向梯度直方图（Histogram of Oriented Gradients, HoG）、自相似性、全局图像结构纹理（GIST）和颜色直方图等多种人工特征，并结合已知地理位置图像实现跨视角图像匹配^[40]；Shan 等人则利用多视角和运动结构技术建立地面多视角模型与航空图像之间的对应关系，为跨视角几何匹配提供了有益参考^[41]。

总体而言，传统方法具有实现流程清晰、计算过程可解释、对训练数据依赖较低等优点，在视角变化较小、纹理信息较丰富的场景中能够取得一定效果。然而，该类方法的性能高度依赖人工特征的稳定性和图像间可见区域的一致性。当不同视角图像之间存在较大外观差异、尺度变化或局部遮挡时，人工特征容易出现匹配点不足或误匹配问题。此外，传统特征通常难以针对特定跨视角定位任务进行端到端优化，其特征表达能力和场景泛化能力受到一定限制。因此，随着大规模数据集和深度神经网络的发展，研究者逐渐开始采用深度学习方法学习更具判别性的跨视角图像表征。

1.2.2 基于深度学习的图像配准地理定位方法

随着计算硬件性能提升和大规模标注数据集的出现，深度学习逐渐成为跨视角图像地理定位领域的主流技术路线。与传统人工特征相比，深度神经网络能够通过多层非线性映射自动学习图像中的局部纹理、空间结构和高层语义信息，并借助度量学习、分类监督或对比学习等优化方式，使同一地理位置的跨视角图像在特征空间中相互接近，不同地理位置的图像相互远离^[42-47]。得益于 CVUSA、CVACT、University-1652 等跨视角地理定位数据集的构建，基于深度学习的方法在特征表达能力和匹配精度方面取得了显著进展^[26]。

根据是否显式处理视角差异及其采用的技术策略，基于深度学习的图像配准地理定位方法可进一步分为以下三类。

(1) 无视角对齐处理的图像配准地理定位方法

无视角对齐处理的方法主要侧重于学习具有较强判别能力和一定视角鲁棒性的图像特征表示。该类方法通常将不同视角图像输入卷积神经网络或其他深度网络结构，通过共享特征空间、深层特征提取和度量学习等方式建立跨视角图像之间的匹配关系。

早期深度学习方法多采用卷积神经网络进行特征提取与匹配。Han 等人提出的 MatchNet 由深度卷积网络和多层全连接网络组成，将特征提取与相似性度量过程进行统一建模，减少了传统特征描述与匹配过程中的人工设计环节^[42]。Hu 等人提出的 CVM-Net 采用孪生 VGG 骨干网络与 NetVLAD 层学习视点不变表示，并通过加权软间隔排名损失优化匹配结果^[43]。Sun 等人基于 ResNet 骨干网络和胶囊结构设计 GeoCapsNet，以

增强模型对高级语义关系的表达能力^[44]。Ding 等人提出 LCM 模型，将图像检索问题转化为分类问题，在 University-1652 数据集上取得了较好的定位效果^[20]。Wang 等人提出局部模式网络（Local Pattern Network, LPN），通过显式建模目标区域及其上下文信息增强图像局部特征表达，在多个跨视角定位数据集上表现出较好的性能^[45]。Deuser 等人提出 Sample4Geo 框架，通过硬负样本采样和对称 InfoNCE 损失优化跨视角特征嵌入空间，进一步提升了图像检索性能^[46, 47]。

随着注意力机制和 Transformer 结构的发展，研究者开始进一步增强模型的全局上下文建模能力。Cai 等人将注意力机制引入跨视角图像地理定位任务，利用空间和通道注意力增强显著区域特征，并通过重加权损失改善难样本训练效果^[48]。Zhuang 等人提出 MSBA 模型，通过多尺度图像分块和自注意力机制提升跨视角特征表达能力^[24]。Yang 等人提出 L2LTR 模型，将 Transformer 结构引入跨视角地理定位任务，利用自注意力机制建模全局依赖关系并减少视觉模糊性^[49]。Dai 等人提出 FSRA 方法，通过 Transformer 结构增强模型对上下文信息和实例分布的理解能力^[23]。Zhu 等人提出 TransGeo 模型，充分利用 Transformer 在全局信息建模和位置编码方面的优势，并通过注意力机制筛选有效图像块以降低计算成本^[50]。Zhang 等人提出 GeoDTR 模型，将几何信息从原始视觉特征中分离出来，并利用几何布局提取模块和反事实训练策略提升跨视角匹配性能^[51, 52]。

总体来看，无视角对齐处理的方法通过深度网络显著增强了图像特征的判别能力和上下文表达能力，但其通常更强调特征空间中的相似性学习，对不同视角图像之间的空间结构差异缺乏显式处理。当跨视角外观差异较大时，仅依靠特征判别性学习仍可能难以充分消除视角差异带来的影响。

(2) 基于传统图像变换的图像配准地理定位方法

与无视角对齐处理的方法相比，基于传统图像变换的方法更加关注不同视角图像之间的几何关系。该方法通常通过方向编码、极坐标变换、透视投影变换等方式，将原始图像或中间特征映射到更易匹配的空间表达形式，以降低视角差异对图像匹配的影响。

Liu 和 Li 注意到跨视角定位网络中方向信息的重要性，利用球面角度和极坐标对地面全景图与卫星图像中的像素方向进行编码，使网络能够同时学习图像外观特征和几何方向信息。Shi 等人将极坐标变换引入跨视角图像匹配任务，并结合空间注意力机制，使变换后的航空图像特征与地面图像特征在嵌入空间中更加接近^[53]。在此基础上，Shi 等人进一步分析了地面全景图与航空图像之间的几何对应关系，认为地面图像中的水平线和垂直线可以分别近似对应为航空图像中的同心圆和径向线，并据此提出动态相似度匹配网络（Dynamic Similarity Matching, DSM），实现地理位置和拍摄方向的联合估计^[53]。Tian 等人提出的 PCL 方法则首先利用透视投影变换（Perspective Projection Transform, PPT）将无人机斜视图转换为更接近垂直视角的图像，再结合后续定位网络进行跨视角匹配^[54]。

基于传统图像变换的方法具有几何意义明确、实现方式相对直观和可解释性较强等优点，在一定程度上能够缓解不同视角图像之间的空间差异。然而，这类方法通常依赖预设的几何假设或固定变换形式，对场景结构变化和复杂成像条件的适应能力有限。当图像中存在较强透视变形、遮挡或局部结构差异时，固定的空间变换可能无法充分描述真实的跨视角对应关系。此外，传统图像变换可能引入一定的图像扭曲或分辨率损失，从而影响后续特征提取和匹配结果。

(3) 基于图像生成的图像配准地理定位方法

随着生成式模型的发展，部分研究开始尝试利用图像生成方法缩小不同视角图像之间的外观差异。基于图像生成的跨视角地理定位方法通常通过生成式对抗网络（Generative Adversarial Network, GAN）或条件生成式对抗网络（Conditional Generative Adversarial Network, CGAN）学习不同视角图像之间的映射关系，将一种视角下的图像转换为另一种视角下的近似表示，再利用生成图像或其特征进行匹配^[54-56]。

Deng 等人较早将 CGAN 用于跨视角图像生成任务，通过生成给定俯视图像位置的地面图像辅助土地覆盖分类，证明了生成式视角转换在跨视角场景理解中的应用价值^[54]。Regmi 和 Shah 尝试利用 CGAN 从地面图像生成对应的空视图像，并将生成结果作为原始图像的补充特征与数据库中的空视图像进行匹配，以减小不同视角之间的外观差异。Toker 等人结合极坐标变换与 GAN 模型，将卫星影像转换为合成街景影像，并以端到端方式完成查询图像定位^[55]。Tian 等人提出的 PCL 方法将跨视角合成模块与地理定位模块进行联合设计，先通过 PPT 将无人机斜视图转换为垂直视图，再利用 CGAN 合成垂直视图风格的无人机图像，最后通过定位网络完成跨视角图像匹配^[56]。

基于图像生成的方法能够在一定程度上缓解不同视角图像之间的外观差异，为跨视角匹配提供更接近目标视角的视觉表示。然而，该类方法通常对训练数据规模和成对样本质量要求较高，且生成图像可能难以完整保留真实场景中的细粒度结构信息。当场景几何关系复杂或图像内容存在明显遮挡、动态变化时，生成结果的不确定性可能进一步影响后续匹配的稳定性。因此，如何在保持跨视角转换能力的同时保证特征表达的准确性，仍是该类方法需要进一步研究的问题。

综上所述，基于传统方法的图像配准地理定位技术为跨视角匹配提供了早期基础，但其特征表达能力和复杂场景适应能力有限；基于深度学习的方法显著提升了跨视角图像特征学习和匹配性能，并逐渐形成了无视角对齐处理、传统图像变换和图像生成等多种技术路线。现有研究虽然在跨视角图像地理定位任务中取得了较大进展，但在复杂场景下仍存在特征表达、空间对应和匹配鲁棒性等方面的不足。因此，如何进一步提升跨视角图像特征的一致性、判别性和稳定性，仍是该领域值得深入研究的重要问题。

1.3 论文组织架构

本文围绕无人机自定位中的城市大视角差异与城郊特征稀疏两类关键难题展开研

究。对于城市大视角（空间、尺度及语义层面）差异引发的特征不一致问题，第三章提出了一种基于视图校正与尺度自适应的定位方法。该方法通过视图校正、多尺度自适应与跨视图语义对齐技术，有效消除两类视图的表征差异；对于城郊场景（弱纹理与关键地物占比不足），第四章提出了一种基于特征补全与特征增强的定位方法。该方法通过引入法线先验补全稀疏特征，利用空间结构信息引导特征增强，并采用频域分离技术抑制背景噪声，显著提升了稀疏前景的信噪比。上述两种方法相辅相成，共同服务于复杂场景下的无人机高精度自定位任务。本文的整体章节安排如图 1-2 所示。

第一章为绪论部分，主要阐述本文的研究背景与意义，分析 GPS 受限环境下无人机视觉定位面临的现实需求，并梳理无人机-卫星跨视角图像地理定位领域的国内外研究现状。在此基础上，归纳现有方法在跨视图特征一致性、有效特征表达和工程部署方面存在的不足，进一步引出本文的研究内容与章节安排。

第二章为相关理论基础与技术，为后续的研究工作打下坚实的理论基础。该部分详细介绍了本文算法所依赖的核心网络与技术，包括 ConvNeXt 网络、Lite Transformer Encoder (LTE) 轻量级编码器、Spatial Transformer Network (STN) 空间变换网络、基于 Omnidata 的法线生成方法以及小波变换理论。同时，介绍了本文实验所采用的 University-1652 和 SUES-200 数据集及相关的评价指标。

第三章围绕无人机与卫星影像因成像机理与观测模式差异导致的跨视图特征不一致难题展开研究。提出基于视图校正与尺度自适应的图像配准地理定位方法。该方法利用语义引导视图校正模块引入语义先验驱动空间仿射变换，对无人机倾斜视角特征进行正射投影以消除几何错位，并设计尺度自适应特征校准模块动态匹配有效的语义粒度并动态校正空间布局偏移以缓解特征尺度差异。此外，设计跨视角语义对齐模块，通过参考视图的静态上下文过滤非共视动态干扰并自适应强化共有语义特征，最终克服跨视角表征差异实现高精度的图像配准与地理定位。

第四章围绕无人机与卫星视图复杂环境下纹理信息薄弱、关键地理目标占比不足导致的特征稀疏难题展开研究。提出基于特征补全与特征增强的图像配准地理定位方法。该方法利用多尺度几何结构编码器引入几何先验信息，对弱纹理区域进行特征补全以构建结构化表征，并设计空间引导语义增强模块以动态校准特征通道定向增强关键语义特征。此外，设计频域感知背景抑制模块，通过小波变换卷积在频域解耦特征并自适应抑制背景噪声，最终提高弱纹理等特征稀疏场景下的配准鲁棒性与定位有效性。

第五章从工程应用角度出发，围绕视觉定位算法在真实无人飞行器上部署面临的算力限制与实时性问题，设计并实现了一套基于昇腾架构的视觉定位算法部署与加速方案。本章重点阐述了将前述算法模型移植至 Atlas 边缘计算平台的过程，通过算法模型量化与硬件流水线并行加速等技术验证了算法在资源受限条件下的实时推理能力与工程应用可行性。




图 1-2 论文组织架构图

第六章是全文总结与展望。该章节概述论文的主要研究成果，并强调基于视觉配准的无人飞行器自定位技术研究的意义。同时，全面分析上述研究存在的不足之处并提出未来潜在的研究方向。

第2章 相关理论基础与技术

2.1 ConvNeXt 网络

ConvNeXt^[57]是一种基于标准卷积神经网络（CNN^[58]）的网络架构，其在处理速度和准确率方面能够达到与视觉 Transformer 网络相似的出色性能，且整体的网络设计更为简单。无人机视图与卫星视图虽然存在明显视角差异，但二者均包含建筑、道路、植被等地物结构信息，具有一定的视觉结构共性。因此，本文采用权值共享的 ConvNeXt 作为双分支骨干网络，以提取兼具局部纹理细节与高层语义信息的多尺度特征表示。

在具体的网络结构与处理流程方面，给定输入图像为 $x \in \mathbb{R}^{H \times W \times C}$ ，其中 H 、 W 和 C 分别代表图像的高度、宽度和通道数。如图 2-1 所示，输入图像 x 首先会经过一个卷积层（Convolution Layer）和层归一化（Layer Norm）进行初始处理，生成维度为输入尺寸四分之一的特征图。随后，这些特征将依次通过四个不同的阶段，每个阶段均由一个下采样层（Downsample Layer）以及 B_i 个 ConvNeXt 块（ConvNeXt Block）组成，其中 $i \in \{1, 2, 3, 4\}$ ，而 C_i 则代表特征在每个阶段对应的通道数。




图 2-1 ConvNeXt 网络结构图

针对不同的应用场景和计算需求，ConvNeXt 架构在不同变体中的网络参数会有所不同。例如，ConvNeXt-Tiny 变体的结构参数配置为 $B_1 = 3$ 、 $B_2 = 3$ 、 $B_3 = 9$ 以及 $B_4 = 3$ ，而 ConvNeXt-Small 变体的参数配置为 $B_1 = 3$ 、 $B_2 = 3$ 、 $B_3 = 27$ 以及 $B_4 = 3$ 。当输入图像的尺寸为 224×224 时，以上两种网络变体在四个阶段的通道数均固定设置为 $C_1 = 96$ 、 $C_2 = 192$ 、 $C_3 = 384$ 以及 $C_4 = 768$ 。

ConvNeXt 能够实现优越性能的核心原因在于它采用了分割-转换-合并的策略，该策略充分结合并发挥了 ResNet^[59]模型与 Inception^[60]模型的优势。在具体的网络层设计

上, ConvNeXt 引入了跳跃连接, 并使用分组卷积和深度卷积替代了标准的卷积层。这些设计改进不仅有效地减少了模型的参数量, 还显著提高了网络在训练过程中的稳定性, 最终构建出了一个高效且性能出色的网络架构。

ConvNeXt 主要作为无人机视图与卫星视图的共享特征提取骨干网络使用。一方面, 在第三章提出的 VCSEA-Net 中, ConvNeXt 用于提取两类视图的多层级特征金字塔, 为后续视图校正、尺度校准和语义对齐提供基础特征表示; 另一方面, 在第四章提出的 FCFE-Net 中, ConvNeXt 继续承担 RGB 图像与法线图像的基础特征提取任务, 为语义-几何特征交互和特征增强提供多分辨率表征。

2.2 Lite Transformer Encoder

Vision Transformer^[61]等网络在建立全局上下文依赖方面表现卓越。然而, 标准的 Transformer 编码器依赖于传统的点积自注意力机制, 其在计算相似度矩阵 QK^T 时, 时间与空间复杂度均与序列长度 N 呈平方关系, 即 $O(N^2)$ 。在处理高分辨率视觉任务时, 提取多尺度、高分辨率的特征图会导致输入 Token 数量剧增, 从而产生极大的计算与内存开销。

为突破这一计算瓶颈, 引入了轻量化 Transformer 编码器 (Lite Transformer Encoder, LTE)。LTE 的核心在于利用线性注意力机制替代标准点积注意力, 将自注意力计算的复杂度有效降低至线性。具体而言, LTE 摒弃了传统的 Softmax 归一化操作, 转而采用指数线性单元 (ELU) 作为核映射函数^[62] $\phi(x)$, 对查询矩阵 Q 和键矩阵 K 进行非线性映射。其核映射函数定义为:

$$\phi(x) = \text{elu}(x) + 1 \quad (2-1)$$

通过矩阵乘法结合律, LTE 将注意力计算顺序由先构建完整的令牌间相似度矩阵, 转变为先对键和值进行全局聚合, 再与查询进行交互, 从而避免显式生成规模为 $N \times N$ 的注意力矩阵。该机制使注意力计算不再直接依赖二次规模的令牌两两匹配过程, 能够将整体计算复杂度由标准注意力的 $O(N^2)$ 降低至近似线性复杂度。考虑到高分辨率视觉特征通常具有较大的令牌数量, LTE 在降低算力消耗和显存占用的同时, 仍能够保持对长距离全局依赖关系的建模能力。




图 2-2 Lite Transformer Encoder (LTE) 整体结构图

在具体的网络拓扑设计上, LTE 的整体结构如图 2-2 所示。LTE 保留了标准

Transformer 的经典组件，主要由线性注意力层、多层感知机 MLP 以及残差连接构成。输入特征首先经过线性注意力层完成全局特征的自适应交互，随后进入 MLP 模块进行高维特征的非线性整合，并在每个子模块中结合残差结构输出增强后的特征。这种轻量且高效的结构设计，为处理高分辨率的视觉任务提供了理论支撑。

LTE 主要用于第三章语义引导视图校正模块中的全局引导增强流 GGF。GGF 需要在多尺度特征金字塔中建立低层纹理细节与高层宏观语义之间的双向交互关系，从而生成能够表征场景整体布局的全局引导特征。若直接采用标准 Transformer 编码器进行高低层特征交互，随着特征令牌数量增加，其二次复杂度会带来较高的计算和显存开销。LTE 通过线性注意力机制降低全局建模过程的计算复杂度，使 GGF 能够以较低开销完成高层语义与低层语义的交互增强。

2.3 Spatial Transformer Network

传统的卷积神经网络（CNN）由于采用固定的卷积核与池化操作，其对平移具有一定的鲁棒性，但缺乏对图像旋转、缩放以及更复杂的仿射变换的内在空间不变性。为了克服这一局限性，Jaderberg 等人提出了空间变换网络^[63]（Spatial Transformer Network, STN）。STN 是一种可微分的、即插即用的动态机制，能够赋予网络在没有额外空间位置监督的情况下，自适应地对特征图进行空间变换（如裁剪、平移、缩放、旋转及仿射变换）的能力。STN 作为一个独立的模块，可以无缝嵌入到现有的卷积神经网络中。如图 2-3 所示，从结构上看，标准的设计主要由三个核心组件构成：定位网络（Localization Network）、网格生成器（Grid Generator）和采样器（Sampler）。




图 2-3 STN 整体结构图

2.3.1 定位网络

定位网络的主要作用是预测输入特征图所需执行的空间变换参数。设输入特征图为 $U \in \mathbb{R}^{H \times W \times C}$ （其中 H, W, C 分别代表高度、宽度和通道数），定位网络通常由若干个卷积层或全连接层组成，并在最后一层通过回归层输出变换参数 θ 。 θ 的维度取决于所选用的空间变换类型。在实际应用中，二维仿射变换最为常用，其变换参数 θ 是一个 2×3 的矩阵，包含 6 个可学习的参数：

$$\theta = \begin{bmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{bmatrix} \quad (2-2)$$

该参数矩阵包含了图像在二维空间中进行缩放、旋转、平移和剪切所需的所有几何映射信息。

2.3.2 网格生成器

在获取空间变换参数 θ 后，网格生成器负责构建一个规范化的坐标网格，用于计算输出特征图中每个像素点对应于输入特征图中的确切坐标位置。为了确保输出特征图的所有像素均能被正确赋值，STN 采用的是逆向映射策略。

对于仿射变换，设输出特征图（变换后的特征图）上的规范化网格坐标为 (x_i^t, y_i^t) ，其映射回输入特征图上的采样坐标为 (x_i^s, y_i^s) ，两者之间的几何映射关系可表示为：

$$\begin{pmatrix} x_i^s \\ y_i^s \end{pmatrix} = \begin{bmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{bmatrix} \begin{pmatrix} x_i^t \\ y_i^t \\ 1 \end{pmatrix} \quad (2-3)$$

通过这一网格生成过程，网络确定了输出图像的每个像素点应该从输入图像的哪个位置获取特征值。

2.3.3 采样器

通过网格生成器计算得到的源坐标 (x_i^s, y_i^s) 通常是连续的浮点数，而输入特征图 U 的空间坐标是离散的整数格点。因此，采样器需要利用插值算法在输入特征图上进行重采样，以生成最终的输出特征图 $V \in \mathbb{R}^{H' \times W' \times C}$ 。

为了保证整个网络的反向传播能够顺利进行，采样操作必须是可导的。STN 最常采用的插值方式是双线性插值，其数学表达式为：

$$V_i^c = \sum_{n=1}^H \sum_{m=1}^W U_{nm}^c \max(0, 1 - |x_i^s - m|) \max(0, 1 - |y_i^s - n|) \quad (2-4)$$

其中， U_{nm}^c 表示输入特征图在通道 c 、空间位置 (n, m) 处的特征值； V_i^c 表示输出特征图在第 i 个像素位置、通道 c 的输出值。

综上所述，STN 模块通过定位参数预测、采样网格生成、可微特征插值的端到端计算流程，使得深度神经网络能够根据整体任务的损失函数反向传播，自主学习到最佳的几何形变参数。这种机制有效提升了网络对图像空间形变的鲁棒性。

在本文中，STN 是第三章语义引导视图校正模块的重要理论基础。无人机倾斜视图与卫星正射视图之间存在明显的透视投影差异，导致同一地物在两类视图中的空间位置和形态难以直接对应。基于 STN 的定位参数预测、网格生成和双线性插值采样机制，第三章中的几何空间对齐子模块能够在端到端训练过程中自适应回归仿射变换参数，将无人机倾斜视角特征重映射至接近卫星正射视角的空间表征，从而为跨视图几何对齐提供理论基础。

2.4 基于 Omnidata 预训练模型的法线生成方法

在特征稀疏场景中的基于图像配准的地理任务依赖稳定且具备区分度的 3D 几何特征（法线特征）。基于这一需求，本文引入了在 Omnidata^[64]数据集上充分训练的表面法线预训练模型，从而生成场景的表面法线图像。该预训练模型以 DPT-Hybrid^[65]为核心网络架构，能够发挥 Transformer 的全局感受野与卷积网络的局部特征提取优势。在无需额外微调的情况下，该模型即可对全新视角的图像进行像素级法线推理。本节将详细阐述该方法的两个核心环节：首先介绍生成大规模训练数据的 Omnidata 数据管线，然后深入解析法线估计模型的网络架构及其工作机制。

2.4.1 Omnidata 数据管线生成方法

具备一致性的 RGB 与法线成对数据是训练深度学习模型的基础。Omnidata 设计了一套可扩展的自动化 3D 渲染管线来完成这一数据构建任务。如图 2-4 所示，该管线的数据生成过程主要涵盖输入网格、泊松圆盘相机采样、兴趣点采样以及单张图像线索生成四个步骤。




图 2-4 Omnidata 数据生成管线概述

Omnidata 数据管线以真实世界扫描得到的带纹理三维网格为基础，通过泊松圆盘采样在可通行空间中生成相机位置，并在网格表面采样目标观察点。为保证多视图一致性，管线对观察点进行可见性约束过滤，使同一目标区域能够被多个视角稳定观测。最终，系统在固定相机朝向后渲染 RGB 图像及其对应表面法线图像，从而构建具备几何一致性的成对训练数据。

通过该管线，Omnidata 构建了一个包含约 1450 万张图像的大规模多任务数据集。该数据集涵盖了 Replica 等室内场景以及 BlendedMVG^[66]等室外与航空场景，多样化的数据来源增强了预训练模型对室内、室外及航空视角场景的适应能力，使其能够为本文跨视角图像配准任务提供较稳定的几何先验。

2.4.2 法线估计模型的网络结构与训练

本研究所使用的表面法线预训练模型基于 DPT-Hybrid 架构。面对表面法线估计这类密集的像素级预测任务，该模型展现出良好的特征提取与多尺度融合能力。其网络结构如图 2-5 所示，主要由图像嵌入层、Transformer 骨干网络、特征重组模块(Reassemble_s)以及特征融合与预测头四个阶段构成。




图 2-5 DPT-Hybrid 表面法线估计网络架构

首先，输入的单张 RGB 图像进入基于 ResNet-50^[59]的嵌入层，网络利用深度残差结构提取初始特征，随后将其展平并转换为一维的词向量序列。在此序列中，网络会额外加入一个特殊标记（Readout Token）用于汇总全局上下文信息。随后，该序列进入 Transformer 层进行处理，网络在其不同深度提取出四个不同层次的特征序列，并送入对应的特征重组模块中。

由于法线预测依赖二维的空间结构，重组模块负责将一维序列重新映射回不同分辨率的二维特征图：在该模块内部，序列依次经过组合全局标记、折叠拼接为三维特征张量以及空间重采样等操作，输出四个不同尺度的特征图。解码器部分采用了自顶向下的特征融合结构。网络接收来自上一层输出的语义特征和当前尺度的重组特征，两者通过残差卷积单元处理后相加融合，并逐层进行上采样传递。这种机制将深层的全局语义与浅层的局部几何细节进行了有效结合。最终，特征图进入预测头，映射为通道数为 3 的图像，输出场景中每个像素对应的三维空间法线向量。

在模型训练方面，该模型结合角度损失和 L1 损失进行端到端的监督训练，前者约束了预测法线在三维空间中的方向一致性，后者则降低了像素级的绝对误差。此外，该模型在保持约可控参数规模的同时展现出较高的推理效率，满足了实际跨视角匹配任务对时效性的需求。

在本文中，Omnidata 法线生成方法主要应用于第四章提出的 FCFE-Net 方法。针对城郊弱纹理场景中可见光图像缺乏稳定纹理线索的问题，本文利用 Omnidata 预训练模型为无人机视图和卫星视图生成对应的表面法线图像，并将其作为几何先验输入多尺度几何结构编码器 MGSE。该几何先验能够补充 RGB 图像中难以表达的三维结构信息，引导网络关注建筑轮廓、道路边界等相对稳定的地物结构，从而缓解弱纹理区域有效特征不足的问题。

2.5 小波变换

在图像处理与计算机视觉领域，傅里叶变换常被用于将信号分解为全局的频率分量，但该方法在分析具有强空间局部性（如边缘和纹理模式）的图像特征时存在明显的局限

性。傅里叶变换缺乏空间定位能力,在处理非平稳图像信号(如目标边界处的频率突变)时,只能得到整体聚集的频谱,而无法指示高频边缘分量在图像中的具体空间分布。小波变换^[67]有效克服了这一基本限制,它能够通过其高频子带直接编码信号的空间位置信息(即图像坐标)。与傅里叶分析不同,小波分解天然地生成了一种金字塔结构的表示形式,从而促进了层次化、由粗到细的特征提取,这种多分辨率特性使其非常适合目标检测、图像配准等计算机视觉任务。

在深度学习与图像分析中,常采用 2D Haar Wavelet 作为基函数来进行图像特征的频域分解。对于给定的输入图像 X ,其离散小波变换过程可以通过步长为 2 的深度卷积操作等效实现,并使用以下四组不同的滤波器核进行计算,公式如下所示:

$$f_{LL} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, f_{LH} = \frac{1}{2} \begin{bmatrix} 1 & -1 \\ 1 & -1 \end{bmatrix}, f_{HL} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix}, f_{HH} = \frac{1}{2} \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} \quad (2-5)$$

其中, f_{LL} 作为低通滤波器,而 f_{LH} 、 f_{HL} 和 f_{HH} 则构成了互补的高通滤波器。对输入图像的每个通道进行卷积操作后,公式如下所示:

$$[X_{LL}, X_{LH}, X_{HL}, X_{HH}] = \text{Conv}([f_{LL}, f_{LH}, f_{HL}, f_{HH}], X) \quad (2-6)$$

该操作输出的四个通道分量分别提取了图像不同频域的特征信息。其中, X_{LL} 代表低频近似分量,包含了图像的基本形态和全局结构等基础信息; X_{LH} 代表水平高频细节分量,主要突出了垂直方向的纹理特征; X_{HL} 代表垂直高频细节分量,主要突出了水平方向的边缘特征;而 X_{HH} 则代表对角线高频细节分量,用于捕捉对角线方向的微观结构与局部细节模式。

此外,由于滤波器的正交性质,二维哈尔小波变换是完全可逆的,在神经网络中能够通过转置卷积实现信号的精确逆向重构(即逆小波变换):

$$X = \text{ConvTranspose}([f_{LL}, f_{LH}, f_{HL}, f_{HH}], [X_{LL}, X_{LH}, X_{HL}, X_{HH}]) \quad (2-7)$$

通过对低频分量 X_{LL} 进行递归应用,还可以实现级联的多级小波分解。这种层次化的处理过程在逐步降低低频分量空间分辨率的同时,进一步增强了特征在频率域的感受野和表达能力,为后续复杂的视觉任务提供了高效的多频段特征表示。

在本文中,小波变换主要为第四章中的小波变换卷积 WTConv 提供理论基础。WTConv 利用小波变换的多分辨率分解与可逆重构能力,在不同频率成分上提取和整合图像特征,从而为后续背景干扰抑制提供支撑。

2.6 数据集及评价指标

2.6.1 数据集

如图 2-6 所示,University-1652 数据集作为首个涵盖无人机(UAV)、卫星与地面街景多视图的综合性地理定位基准,包含来自全球 72 所大学的 1652 栋目标建筑。该数据集通过采集多角度、多高度的无人机飞行轨迹图像,引入了复杂的几何形变与视角差异,适用于验证模型在非限制性视角变换下的匹配性能;同时,该数据集中存在的表面

纹理单一的大型场馆（如体育场、平顶建筑）及被相似植被包围的结构物等城市特征稀疏场景，其中部分样本包含弱纹理或相似结构区域，可用于辅助分析模型在特征稀疏条件下的匹配表现。实验采用标准检索模式进行评估，并将数据集严格划分为训练集与测试集：训练集覆盖 33 所大学的 701 栋建筑，包含 37,854 张无人机图像与 701 张卫星图像；测试集覆盖其余 39 所大学的 951 栋建筑，其中 37,855 张无人机图像作为查询样本（Query），951 张卫星图像作为图库样本（Gallery）。




图 2-6 University-1652 数据集 Drone 和 Satellite 关系图




图 2-7 SUES-200 数据集展示图

SUES-200^[68]数据集主要用于评估模型在多飞行高度和尺度变化条件下的跨视角匹配能力。如图 2-7 所示,该数据集采集于上海工程技术大学周边的 200 个不同地理位置,其独特之处在于无人机图像严格采集于 150m、200m、250m 和 300m 四个离散飞行高度。这种严格的高度分层特性导致同一地物在图像平面上的投影面积发生非线性波动,构建了具有挑战性的多尺度测试场景。此外,该数据集中因低空视场受限以及大面积自然背景主导所构成的特征稀疏场景,也能够有效验证第四章算法在复杂环境下的配准有效性与鲁棒性。SUES-200 的训练集包含 120 个地点的 12,000 张无人机图像与 120 张卫星图像;测试集则包含剩余 80 个地点的 8,000 张无人机图像与 80 张卫星图像。

2.6.2 评价指标

在跨视角图像配准与地理定位任务中,本文主要采用召回率(Recall@K, 简称 R@K)和平均精度(Average Precision, 简称 AP)作为评估模型匹配性能的核心指标。

(1) 召回率(Recall@K)

Recall@K 用于表示正确匹配的图像出现在检索结果排名前K个当中的概率。其中, Recall@1 (即 R@1) 对首个正确匹配的图像在匹配结果排序中的位置极为敏感。通常而言, Recall@K 数值越高,表示正确匹配样本越可能出现在检索结果的前 K 个候选项中,模型的跨视角检索能力越强。Recall@K 的具体定义如下:

$$Recall@K = \begin{cases} 1, & \text{if } order_{true} < K + 1 \\ 0, & \text{otherwise} \end{cases} \quad (2-8)$$

(2) 平均精度(Average Precision, AP)

AP 衡量的是精确率-召回率(Precision-Recall, PR)曲线下的面积,该指标在评估过程中充分考虑了所有正确匹配的图像在最终检索结果中的位置信息。AP 的计算公式如下:

$$AP = \frac{1}{m} \sum_{h=1}^m \frac{p_{h-1} + p_h}{2} \quad (2-9)$$

其中, $p_0 = 1$, 且 p_h 定义为:

$$p_h = \frac{T_h + 1}{T_h + F_h} \quad (2-10)$$

在上述公式中, m 表示针对某一查询图像的正确匹配图像的总数量; T_h 和 F_h 则分别代表在匹配结果排序列表中,位于第 $h + 1$ 个正确匹配图像之前的正确匹配图像数量与错误(假)匹配图像数量。

2.7 本章小结

本章围绕无人机-卫星跨视角图像配准定位任务,介绍了本文算法设计与实验验证所依赖的相关理论基础和关键技术。首先, ConvNeXt 网络用于构建无人机视图与卫星

视图的共享特征提取骨干，为第三章和第四章的双分支特征建模提供多尺度视觉表征；Lite Transformer Encoder 通过线性注意力机制降低全局上下文建模开销，支撑第三章中多尺度语义交互与全局引导特征构建；Spatial Transformer Network 通过可微空间变换机制为第三章中的视图校正与几何对齐提供理论依据。其次，基于 Omnidata 预训练模型的法线生成方法能够为弱纹理区域补充几何结构先验，是第四章特征补全与几何增强的重要基础；小波变换则利用多频段分解与可逆重构特性，为第四章频域感知背景抑制模块提供前景结构与背景冗余解耦的实现依据。最后，本章介绍了 University-1652 和 SUES-200 两个跨视角地理定位数据集，以及 Recall@K 和 AP 等评价指标，为后续实验设计、性能对比和消融分析奠定基础。

第3章 基于视图校正与尺度自适应的图像配准的地理定位方法

3.1 引言

基于视觉配准的无人飞行器定位是保障无人机在 GPS 拒止环境下实现自主航行与任务执行的关键技术，该方法旨在通过建立无人机实时查询图像与预存卫星参考图像之间的特征对应关系，实现高精度的无人机自定位。然而，受限于成像机理与观测模式的本质不同，两类图像在视觉表征上存在显著差异，这种跨视图差异直接导致了多层面的跨视图特征不一致问题。

具体而言，大视角差异条件下的跨视图特征不一致主要体现在几何、尺度和语义三个层面。在空间几何层面，无人机倾斜成像与卫星正射成像之间存在明显透视差异，使同一地物在两类视图中的投影形态、空间位置和局部结构发生偏移，进而削弱跨视图几何对应关系的稳定性。在尺度表征层面，卫星图像的宏观观测特性与无人机图像的近距离成像特性存在固有差异，叠加无人机飞行高度变化，使同一目标在不同视图中的尺度分布和分辨率表现不一致，增加了跨视图特征对齐难度。在语义内容层面，无人机实时视图中往往包含车辆、行人等瞬时动态目标，而卫星参考图像通常反映相对稳定的静态地理环境，二者之间的内容非对称性容易引入非共视语义噪声，干扰共有地物特征的匹配。尽管现有的视觉配准方法取得了一定进展，但它们往往隐式地处理某方面差异，现有方法难以协同处理上述多层面的表征差异，从而制约了图像配准与地理定位的精度提升。

为解决上述问题，本章提出基于视图校正与尺度自适应的图像配准的地理定位方法。首先，针对空间层面的几何错位，设计语义引导视图校正模块（**Semantic-guided View Rectification Module, VRM**）。该模块利用语义先验引导空间仿射变换，将倾斜视角无人机特征显式投影至近似正射空间，从而建立准确的跨视图几何对应关系。随后，针对尺度层面的特征差异，提出尺度自适应特征校准模块（**Scale Adaptive Feature Calibration Module, SAM**）。该模块分别作用于单侧视图，通过构建多梯次感受野动态匹配当前观测高度的最佳语义粒度，并结合空间约束自适应校准特征空间布局的相对偏移，保证了特征的尺度鲁棒性，为跨视图尺度对齐提供统一的度量基准。最后，针对内容层面的语义不一致问题，构建跨视角语义对齐模块（**Cross-view Semantic Alignment Module, CSM**）。该模块通过级联的局部与全局交互机制，抑制非共有动态区域的特征响应并且强化共有静态地理语义，从而建立可靠的跨视图语义对应关系。实验结果表明，本章所提出的方法对跨视图异构特征的配准与无人机高精度定位效果更佳。

3.2 总体结构

本章所提出的基于视图校正与尺度自适应的图像配准网络（**View Correction and Scale-Adaptive Network, VCSA-Net**），其整体结构如图 3-1 所示。该网络旨在构建一个

端到端的跨视角特征对齐框架，整体架构依照数据处理的级联逻辑，划分为四个递进的处理阶段：主干特征提取、基于视图校正的空间对齐、基于多尺度感知的尺度对齐，以及基于跨视图交互的语义对齐。特征流在这四个阶段间依次传递，实现从底层像素空间到高层联合度量空间的精准跨视图映射。




图 3-1 基于视图校正与尺度自适应的图像配准网络 VCSA-Net 结构图

在主干特征提取阶段，给定无人机查询图像与卫星参考图像，网络前端采用权值共享的 ConvNeXt 网络作为特征提取网络。输入图像经由层次化的卷积操作被映射为多分辨率的特征金字塔 ($S_1 \sim S_4$)，构建出兼具底层纹理细节与高层抽象语义的初始特征。

在视图几何校正阶段，无人机分支引入语义引导视图校正模块 VRM。该模块首先通过全局引导增强流 (Global Guided Enhancement Flow, GGF) 建模宏观场景布局的拓扑先验，并以此为条件提示，驱动局部重构增强流 (Local Reconstruction Enhancement Flow, LRF) 重构出纯净的高频局部纹理特征；随后，几何空间对齐子模块 (Geometric

Spatial Alignment Module, GSAM) 协同全局先验与局部内容回归仿射变换矩阵, 显式地执行空间重采样, 输出几何校正后的正射对齐特征 F_{uav}^{spa} 。同时, 由于卫星视图呈俯视正射投影, 其骨干网络提取的不同层级特征 ($S_1 \sim S_4$) 将被直接进行特征聚合操作, 即统一分辨率后在通道维度进行聚合, 构建出上下文丰富的卫星特征 F_{sat}^{spa} 。

在尺度自适应校准阶段, 空间对齐阶段输出的无人机校正特征 F_{uav}^{spa} 与卫星聚合特征 F_{sat}^{spa} 分别独立进入尺度自适应特征校准模块 SAM。该模块集成多尺度感知子模块 (Multi-Scale Perception Module, MSCM) 与空间坐标注意力 (Spatial Coordinate Attention, SCA), 对特征处理后分别输出尺度自适应校准后的特征 F_{uav} 与 F_{sat} 。从而为后续 InfoNCE 对比损失^[69]的计算提供了统一的度量基准, 促进跨视图特征的尺度对齐。

在跨视角语义对齐阶段, 尺度校准后的双路特征进入跨视角语义对齐模块 CSM。该模块依次通过跨视角局部交互子模块 (Cross-view Local Interaction Module, CLIM) 与跨视角全局交互子模块 (Cross-view Global Interaction Module, CGIM) 执行双向语义交互和语义对齐, 输出高判别力的全局描述符 g_{uav} 与 g_{sat} 。

在模型训练与参数优化阶段, 本模型采用端到端的联合监督机制。网络基于 SAM 模块输出的中间层特征计算对比损失, 以在特征空间中建立稳健的相对距离约束; 同时, 基于 CSM 模块输出的全局描述符计算交叉熵分类损失。两部分损失经加权求和后, 通过统一的反向传播驱动双流网络完成参数更新。

3.3 语义引导视图校正模块 VRM

无人机倾斜视图与卫星正射视图之间存在本质的成像几何差异, 引发显著的特征空间错位现象。针对该现象导致的跨视图的几何不一致, 语义引导视图校正模块 VRM 引入语义先验知识, 对无人机视图的透视投影引发的几何形变执行校正操作, 在特征层面消除跨视图的几何空间差异, 从而建立可靠的几何空间对应关系。

如图 3-2 所示, VRM 以无人机分支骨干网络输出的多尺度特征金字塔 ($S_1 - S_4$) 为输入, 通过并行部署的全局引导增强流 GGF 与局部重构增强流 LRF 处理各层级特征。GGF 对特征金字塔执行双向交互操作, 利用高层特征的拓扑结构聚合多尺度细节, 提取编码宏观场景布局的全局引导特征 F_{guide} , 同时, F_{guide} 被重塑为全局提示注入 LRF 中。LRF 在此宏观语义先验的引导下, 滤除底层冗余噪声并聚合多感受野信息, 重构出包含丰富纹理的局部内容特征 $F_{content}$ 。最终, 几何空间对齐子模块 GSAM 同步接收上述两路特征, 通过交叉注意力机制构建倾斜内容与正射几何的空间对应关系。GSAM 据此回归仿射变换参数, 构建逆向坐标采样网格, 将局部特征重映射至标准正射投影空间, 实现对倾斜无人机视图的几何空间校正。




图 3-2 语义引导空间校正模块 VRM 模块结构图

3.3.1 全局引导增强流 GGF

全局引导增强流 GGF 用于建立底层纹理细节与高层宏观语义的双向交互，从而提取出包含场景宏观拓扑的全局引导特征。GGF 直接接收主干网络输出的多层级特征金字塔 $S = \{S_1, S_2, S_3, S_4\}$ ，并将其划分为包含纹理细节的低层特征 $\{S_1\}$ 与表征深层语义的高层特征 $\{S_2, S_3, S_4\}$ 。




图 3-3 全局引导增强流 GGF 结构图

对于低层特征 S_1 ，GGF 通过金字塔池化采样^[70]机制（PPS）在 $\{1, 3, 6, 8\}$ 多个尺度下执行自适应平均池化以捕获多尺度上下文信息，随后利用 1×1 卷积进行通道投影对齐，并将其展平拼接为包含 110 个特征令牌的低层序列 F_L ；对于高层特征，将 $S_2 \sim S_4$ 分别展平为一维序列后，经通道对齐后在令牌序列维度上进行拼接，从而生成初始的高层特征令牌序列 F_H 。

为实现两类特征之间的信息互补，如图 3-3 所示，GGF 引入了第二章中所述的轻量化 Transformer 编码器（LTE），通过高层语义与低层细节的双向流动实现特征的深度耦合。网络执行高层语义流的深度增强，以高层特征 F_H 蕴含的全局语义拓扑为查询条件，主动聚合低层多尺度细节信息。计算过程定义如下：

$$Q_H = F_H W_{Q_H}, K_L = F_L W_{K_L}, V_L = F_L W_{V_L} \quad (3-1)$$

$$X_H = \text{LTE}(Q_H, K_L, V_L) \quad (3-2)$$

其中, Q_H 为高层特征的查询向量, K_L 与 V_L 为低层特征投影生成的键和值向量; $W_{Q_H}, W_{K_L}, W_{V_L}$ 分别表示对应的可学习线性投影权重矩阵; X_H 表示聚合了底层细节后增强的高层特征序列。

在此基础上, 如图 3-3 所示, 网络进一步对低层细节特征执行深度增强。此交互步骤以低层特征 F_L 构建查询矩阵, 并将增强后的高层特征 X_H 映射为键与值矩阵。网络利用 LTE 机制驱动低层特征自适应地检索并融合高层序列中的宏观拓扑结构, 实现低层特征维度的有效增强。具体计算公式如下:

$$Q_L = F_L W_{Q_L}, K_H = X_H W_{K_H}, V_H = X_H W_{V_H} \quad (3-3)$$

$$X_L = \text{LTE}(Q_L, K_H, V_H) \quad (3-4)$$

其中, Q_L 表示低层特征的查询矩阵, K_H 与 V_H 分别代表经由增强后高层特征投影生成的键矩阵与值矩阵; $W_{Q_L}, W_{K_H}, W_{V_H}$ 对应各自的可学习线性投影权重矩阵; X_L 标识重构后完成特征增强的低层特征序列。

经过双向交互后, 高层增强序列 X_H 与低层增强序列 X_L 在通道维度进行融合, 并重塑为空间特征图, 得到全局引导特征 F_{guide} 。该特征深度耦合了全局拓扑结构与关键局部细节, 作为核心的语义锚点支撑后续空间校正任务, 并被重塑为多尺度全局提示注入局部重构增强流 LRF 中。

3.3.2 局部重构增强流 LRF

局部重构增强流 LRF 的网络结构如图 3-4 所示。该流通过全局提示注意力块(Global Prompt Attention Block, GPAB) 构建跨尺度的语义映射关系。GGF 输出的全局引导特征 F_{guide} 经投影操作, 重塑为与各层级局部特征 S_i 空间分辨率严格匹配的全局提示图 G_i , 该提示图提供了场景的宏观语义布局先验, 并在 GPAB 内部分别沿通道与空间维度生成正交的显著性分布权重。

具体而言, GPAB 利用池化与卷积操作从全局提示图 G_i 中提取通道与空间注意力权重, 以此将宏观的通道语义先验和全局空间布局拓扑注入到局部特征中。获取由全局先验驱动的正交权重后, LRF 采用 3×3 卷积层和残差结构对原始局部特征 S_i 深度重构, 此过程利用全局语义一致性约束对微观纹理特征进行加权调制, 促使网络自适应聚焦与全局结构相呼应的局部有效细节, 并滤除底层冗余噪声。经过该语义注入机制处理, 得到精炼特征 F_{ref}^i 。

$$F_{\text{ref}}^i = F_{\text{conv}3 \times 3}^i(S_i \odot \sigma(F_{\text{conv}}(P_{\text{avg}}(G_i))) \odot \sigma(F_{\text{conv}}(P_{\text{max}}(G_i))) + S_i) \quad (3-5)$$

其中, σ 表示 Sigmoid 激活函数, F_{conv} 与 $F_{\text{conv}3 \times 3}^i$ 分别表示常规卷积与第 i 尺度的 3×3 卷积运算, P_{avg} 和 P_{max} 分别代表平均池化与最大池化, $\odot$ 表示逐元素相乘。




图 3-4 局部重构增强流 LRF 网络结构图

之后，LRF 进一步执行多尺度特征聚合，构建兼具微观细节与宏观语义布局的完整表征。特征金字塔各层级 F_{ref}^i 经双线性插值上采样映射至统一的高分辨率空间，各层特征在通道维度堆叠，并经 1×1 卷积层聚合，生成局部内容特征 $F_{content}$ ，公式如下所示：

$$F_{content} = F_{conv1 \times 1}(Cat(F_{ref1}, Up(F_{ref2}), Up(F_{ref3}), Up(F_{ref4}))) \quad (3-6)$$

其中， $Cat(\cdot)$ 表示特征在通道维度的拼接操作， $Up(\cdot)$ 表示双线性插值上采样操作， $F_{conv1 \times 1}$ 表示 1×1 卷积运算。

3.3.3 几何空间对齐子模块 GSAM

几何空间对齐子模块 GSAM 的内部结构如图 3-5 所示。该模块同步接收两路特征输入：包含视图整体拓扑结构的全局引导特征 $F_{guide} \in \mathbb{R}^{C \times H \times W}$ 与包含细粒度纹理信息的局部内容特征 $F_{content} \in \mathbb{R}^{C \times H \times W}$ 。

首先，模块将特征图注入二维位置编码信息以构建全局结构与局部纹理在特征空间中的对应关系，并将其展平为序列形式 $X_{guide}, X_{content}$ 。进一步，本模块引入交叉注意力机制执行特征交互。将待校正的内容特征 $X_{content}$ 映射为查询向量 Q ，而将蕴含全局结构先验的 X_{guide} 映射为键 K 和值 V 。获取编码几何形变感知信息的增强特征 F_{attn} 。计算过程如下：

$$Q = X_{content}W_Q, K = X_{guide}W_K, V = X_{guide}W_V \quad (3-7)$$

$$F_{attn} = \text{Softmax}\left(\frac{Q \cdot K^T}{\sqrt{d_k}}\right) \cdot V \quad (3-8)$$

其中, d_k 代表键的维度。 W_Q, W_K, W_V 可学习的投影权重矩阵。




图 3-5 几何空间对齐子模块 GSAM 模块结构图

在获取融合全局先验的序列 F_{attn} 后, F_{attn} 被重塑回二维空间维度特征 $F'_{attn} \in \mathbb{R}^{C \times H \times W}$, 并被输入至第二章所述的空间变换网络 (STN) 的定位子网络中。定位子网络通过多层卷积与全连接映射, 从包含结构偏差信息的特征中解码并回归出二维仿射变换参数矩阵 θ 。在此基础上, 网络利用 STN 内置的网格生成器与双线性插值采样机制, 以预测的仿射参数 θ 为引导, 对原始的局部内容特征 $F_{content}$ 执行逆向扭曲与空间重映射, 从而输出几何校正后的无人机空间特征 F_{uav}^{spa} 。

3.4 尺度自适应特征校准模块 SAM

在跨视角图像配准任务中, 无人机的微观动态观测与卫星的宏观固定观测之间存在显著的高度差异以及无人机飞行高度波动, 导致跨视角特征面临尺度不一致的挑战。这种尺度不一致使得同一地物在特征空间中, 呈现出明显的特征尺度失配与空间布局偏移。为应对上述问题, 本节提出了尺度自适应特征校准模块 SAM。该模块分别独立作用于无人机与卫星的特征分支, 该模块通过多尺度感知子模块 MSCM 构建自适应感受野, 动态匹配各自视图内部的语义粒度; 同时利用空间坐标注意力 SCA 获取空间先验权重, 显式校准特征图中的相对位置偏移。经过双侧分支 SAM 的独立校准后, 获得具备尺度自适应能力的鲁棒特征, 为 InfoNCE 对比损失函数在联合空间中实现跨视图的尺度对齐提供了统一的度量基准。

如图 3-1 的 SAM 结构所示, SAM 构建了多维特征并行感知与全局空间联合校准的

整体结构。输入特征为 F_{in} ，该模块采用了三条并行的特征感知路径以实现多维信息的自适应聚合：第一条路径作为全局路径，通过全局池化提取场景级的宏观上下文向量 F_{glob} ；第二条路径利用 MSCM 自适应捕捉相应粒度的语义特征 F_{mscm} ；第三条路径则作为局部路径，直接保留原始特征的底层细节与局部纹理信息 F_{loc} 。随后，这三路特征在通道维度进行拼接，生成融合了丰富尺度、全局语义与局部细节的聚合特征 F_{cat} 。 F_{cat} 再经过一层卷积处理后，送入空间坐标注意力模块 SCA，通过位置编码处理，输出坐标感知的全局特征图 F_{sca} 。

3.4.1 多尺度感知子模块 MSCM

面对无人机与卫星视图观测高度差异所引发的特征粒度失配问题，本节提出了多尺度感知子模块 MSCM。该模块构建了基于多路并行空洞卷积的特征感知结构，利用差异化的空洞卷积膨胀率模拟不同观测距离下的有效视场。通过在深层特征空间内构建与不同地物尺度相匹配的梯次感受野分布，MSCM 能够自适应地捕获从微观纹理到宏观拓扑的多粒度视觉信息，从而在特征感知层面校准并缓解特征粒度失配的问题。




图 3-6 多尺度感知子模块 MSCM 模块结构图

如图 3-6 所示，在具体的网络实现中，令输入特征张量表示为 $F_{in} \in \mathbb{R}^{C \times H \times W}$ ，设置了三条并行的感知分支，其膨胀率分别设定为 $r \in \{1, 3, 5\}$ 。这种差异化的参数配置确立了层级化的特征捕获范围：低膨胀率分支($r = 1$)保持最小感受野，专注于精确编码纹理与边缘细节，以适配低空飞行时的近景特征；而随着膨胀率增加至 $r = 5$ ，有效感受野显著扩大，分支能够完整覆盖宏观的几何结构，确保在高空大范围场景下特征的全局连通性。各分支首先通过 3×3 空洞卷积处理输入特征，然后进入挤压-激励模块(SE-Block^[71])，在通道维度对特征重校准。SE-Block 建模通道间的非线性依赖关系，对特征通道进行基于尺度的自适应加权，以增强各自分支几何感受野相匹配的特征响应。紧接着，各分支经由 1×1 卷积层进行维度的统一与压缩，生成三个尺度的中间特征表征 P_1, P_3, P_5 。第 r 分支的

计算过程形式化为，公式如下所示：

$$P_r = \text{Conv}_{1 \times 1} \left(\Psi_{SE} \left(\text{Conv}_{3 \times 3, r} (F_{in}) \right) \right), r \in \{1, 3, 5\} \quad (3-9)$$

其中， $\text{Conv}_{3 \times 3, r}$ 表示膨胀率为 r 的空洞卷积， Ψ_{SE} 表示 SE-Block 的通道加权操作。

MSCM 采用像素级跨尺度上下文自适应门控机制以实现多尺度特征的有效整合。如图 3-6 所示，三个尺度的特征 P_1, P_3, P_5 ，在通道维度进行拼接，构建包含丰富尺度信息的联合特征张量。该张量随即通过一个共享的 3×3 卷积层感知局部空间上下文，并经由 Softmax 函数进行归一化，生成三个对应的空间注意力权重图 α, β, γ 。这一过程实质上是在像素级动态评估不同尺度特征对于当前场景的语义重要性，赋予了模型根据无人机视角的远近自动调节各分支激活程度的能力。权重生成与最终的特征聚合，公式如下：

$$[\alpha, \beta, \gamma] = \text{Split} \left(\text{Softmax} \left(\text{Conv}_{3 \times 3} (\text{Concat}(P_1, P_3, P_5)) \right) \right) \quad (3-10)$$

$$F_{mscm} = \alpha \odot P_1 + \beta \odot P_3 + \gamma \odot P_5 \quad (3-11)$$

其中，Split 表示沿通道维度的切分操作，权重满足 $\alpha + \beta + \gamma = 1$ ， $\odot$ 表示逐元素相乘。该机制通过动态优选最匹配当前视角的感受野特征，生成具备尺度适应性的聚合特征 F_{mscm} ，实现特征感知层面的动态尺度校准。

3.4.2 空间坐标注意力 SCA

尽管 MSCM 模块缓解了特征粒度失配，但跨视图尺度差异还会导致同一地物在不同视角下产生显著的空间布局偏移。为此，本节在特征融合后接入了空间坐标注意力模块 SCA。如图 3-7 所示，该模块整合位置编码（Position Encoding）、多分支自注意力 MSA 与非对称级联融合策略，分别沿水平和垂直方向建立长距离依赖，实现特征空间位置偏移的自适应校准。




图 3-7 空间坐标注意力 SCA 结构图

输入特征 F_{mscm} 经位置编码处理生成特征 X_{pe} ，该操作赋予特征显式的绝对空间参考

坐标，提升模型对布局偏移的敏感度。此后，特征流被划分为三条并行分支。水平（ X ）与垂直（ Y ）分支分别执行对应方向的一维全局平均池化、卷积与批量归一化，沿特定坐标轴对全局分布聚合，初步提取地物在不同维度的偏移信息，分别生成方向初始特征 Z^x 与 Z^y 。

在空间布局偏移的场景中，跨越物理距离的上下文依赖建模尤为关键。上述方向初始特征分别进入多组并行的自注意力子网络。水平分支设置 8 个并行的卷积与 MSA 级联单元（ $N = 8$ ），垂直分支设置 4 个并行的卷积与 MSA 级联单元（ $N = 4$ ）。不对称的多分支机制在多个表示子空间中同步提取长距离空间关联，促使网络跨越空间偏移距离建立稳定的特征交互。各分支的内部输出在通道维度完成拼接，生成具备方向感知与空间偏移鲁棒性的高维特征 V^x 和 V^y ，公式如下所示：

$$V^x = \text{Concat}_{i=1}^8 \left(\text{MSA}_i(\text{Conv}_i(Z^x)) \right) \quad (3-12)$$

$$V^y = \text{Concat}_{j=1}^4 \left(\text{MSA}_j(\text{Conv}_j(Z^y)) \right) \quad (3-13)$$

其中， Z^x 与 Z^y 分别代表经过基础池化与归一化处理后的水平与垂直方向初始特征， Concat 表示通道维度的拼接操作， i 与 j 分别为对应方向并行分支的索引序号。

特征融合阶段采用两阶段非对称级联乘法架构执行空间坐标的重校准。第一阶段校准将水平增强特征 V^x 与含有绝对坐标信息的直连分支 X_{pe} 进行逐元素相乘，随后经卷积与 ReLU 激活生成中间空间权重图。此过程利用全局位置先验对水平方向的偏移特征施加初步约束。第二阶段校准将该中间权重图与垂直增强特征 V^y 再次进行逐元素相乘。该过程利用已约束的水平先验指导垂直方向的特征重构，实现对整体空间布局偏移的自适应校准，输出空间坐标注意力增强特征 F_{sca} ，公式如下所示：

$$F_{sca} = \text{ReLU} \left(\text{Conv}(V^x \otimes X_{pe}) \right) \otimes V^y \quad (3-14)$$

其中， $\otimes$ 表示张量的逐元素相乘操作， ReLU 为非线性激活函数。

3.5 跨视角语义对齐模块 CSM

在跨视角地理定位中，无人机实时图像可能包含静态地物和车辆、行人等瞬时动态目标，而卫星参考图像通常以稳定地理场景为主。两类视图在内容分布上的非对称性会引入动态目标，影响共有地物特征的匹配稳定性。针对该问题，本章提出了跨视角语义对齐模块 CSM，旨在利用参考视图中稳定的静态语义特征作为基准，对查询视图特征进行针对性的筛选与重组。通过构建全局与局部的交互机制，该模块抑制无人机视图中非共有区域的动态干扰，同时聚焦并强化双方共有的静态地物特征，从而确立跨视角视图在语义层面的一致性。

如图 3-1 的 CSM 结构所示，CSM 接收经由 SAM 模块校准后的两路特征 F_{uav} 与 F_{sat} 。该模块采用级联的局部与全局交互，实现跨视角语义的深度对齐与融合。首先，在跨视角局部交互子模块 CLIM 中，模块利用跨视角特征交互块（Cross-view Feature Interaction

Block, CFIB) 在空间维度上计算两路特征的局部相关性。两分支经过跨视角注意力机制能够相互捕捉对方视角下的共有局部地物特征, 从而在局部尺度上实现细粒度的语义对齐, 并初步削弱非共有动态区域的特征响应。随后, 特征流转至跨视角全局交互子模块 CGIM, 该子模块采用全局聚合操作提取特征图的全局上下文信息, 利用全局描述对局部交互后的特征进行进一步的加权与映射。CGIM 从全局角度强化具有辨识度的共有特征表达, 消除局部语义不一致带来的偏差。经过局部交互与全局聚合的协同处理, 最终输出语义对齐的全局描述向量 g_{uav} 与 g_{sat} 用于后续的配准定位。

3.5.1 跨视角局部交互子模块 CLIM

跨视角局部交互子模块, 基于对称的跨视角注意力机制促进双端视图的空间交互与上下文对齐。如图 3-1 的 CLIM 模块结构所示, 模块通过两个结构对称的 CFIB 分支, 实现无人机特征与卫星特征之间的双向局部交互。

在无人机特征更新分支中, 无人机特征 F_{uav} 作为当前待增强特征, 卫星特征 F_{sat} 作为参考特征, 二者分别对应图 3-8 中的 F_A 和 F_B , 即 $F_A = F_{uav}$, $F_B = F_{sat}$ 。该分支利用卫星视图中相对稳定的地物上下文信息增强无人机特征, 并抑制无人机视图中动态目标和非共视区域带来的局部干扰。

在卫星特征更新分支中, 两路输入特征的角色互换, 即 $F_A = F_{sat}$, $F_B = F_{uav}$ 。此时, 卫星特征作为当前待增强特征, 无人机特征作为参考特征, 用于引入无人机视图中更丰富的局部纹理与细节信息, 引导卫星特征关注与查询视图一致的关键目标区域。通过上述两个对称分支, CLIM 分别得到局部增强后的无人机特征和卫星特征。




图 3-8 CFIB 跨视图特征交互块结构图

如图 3-8 所示, CFIB 基于交叉注意力机制构建跨视角注意力。其中, F_A 表示当前待增强的视图特征, F_B 表示另一视图提供的参考特征。输入特征 F_A 经线性映射生成查询向量 Q , 输入特征 F_B 经线性映射生成键向量 K 和值向量 V 。随后, 通过计算 Q 与 K 之间的相似性, 建立当前视图特征与参考视图特征之间的局部关联, 并根据该关联关系对 V 中的上下文信息进行加权聚合。其交叉注意力计算过程可表示为:

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3-15)$$

其中, d_k 表示键向量的特征维度, $\sqrt{d_k}$ 用于缩放点积注意力得分, 避免注意力权重分布过于集中。之后, 交互后的特征经过拼接、线性映射、归一化、前馈网络和残差连接, 输出增强后的当前视图特征。经由两个 CFIB 分支的双向交互, 输出的特征序列被重塑回二维格式, 得到局部增强特征 F_{uav}^L 和 F_{sat}^L 。

3.5.2 跨视角全局交互子模块 CGIM

如图 3-9 所示, 模块输入为经局部交互后的特征 F_{uav}^L 与 F_{sat}^L 。为了有效抑制无人机与卫星视图中非共有的特征响应, 并增强其共有的静态地物特征响应, 本模块采用跨视角全局交互策略, 对双分支特征进行全局范围的深度交互, 并基于交互结果分别输出语义对齐的聚合特征。




图 3-9 跨视角全局交互子模块 (CGIM) 结构图

首先, 对输入特征 F_{uav}^L 和 F_{sat}^L 沿通道维度执行线性投影与分割, 生成分割特征组 $F_{uav}^{q'}, F_{sat}^{q'} \in \mathbb{R}^{\frac{C}{2} \times H \times W} (q \in \{1, 2\})$ 。将所得特征组进行交叉拼接, 以此构建无人机与卫星视角的初始特征交互空间。随后, 并行应用通道级平均池化与最大池化操作 $P(\cdot)$ 提取空间对应关系, 并利用卷积映射 $C(\cdot)$ 与 Sigmoid 激活函数 $S(\cdot)$, 计算跨分支空间交互权重 SW_{uav}, SW_{sat} 。该权重显式度量了跨视角空间区域内地物分布的一致性, 公式如下所示:

$$[SW_{uav}; SW_{sat}] = S \left(C^{2 \rightarrow 2} (P([F_{uav}^{1'}, F_{sat}^{1'}; F_{uav}^{2'}, F_{sat}^{2'}])) \right) \quad (3-16)$$

进一步, 将交互权重 SW_{uav}, SW_{sat} 沿通道切分为 $SW_{uav}^q, SW_{sat}^q \in \mathbb{R}^{1 \times H \times W} (q \in \{1, 2\})$, 分别与对应的分割特征图 $F_{uav}^{i'}, F_{sat}^{j'}$ 和执行逐元素乘法及加和操作。结合通道级投影变换 $F_c^{\frac{C}{2} \rightarrow C}(\cdot)$, 生成跨视角的全局交互注意力掩码 GW_{uav}, GW_{sat} 。该注意力机制在特征空间中自适应削弱非共有动态区域的特征响应, 并提高静态拓扑结构的响应权重, 公式如下所示:

$$GW_{uav} = F_c^{\frac{C}{2} \rightarrow C} (SW_{uav}^1 \times F_{uav}^{1'} + SW_{uav}^2 \times F_{uav}^{2'}) \quad (3-17)$$

$$GW_{sat} = F_c^{\frac{C}{2} \rightarrow C} (SW_{sat}^1 \times F_{sat}^{1'} + SW_{sat}^2 \times F_{sat}^{2'}) \quad (3-18)$$

其中, $GW_{uav}, GW_{sat} \in \mathbb{R}^{D \times H \times W}$ 。

将上述注意力掩码分别与输入特征图 F_{uav}^L, F_{sat}^L 逐元素相乘，并引入残差连接结构，输出双分支全局交互特征图 $F_{uav}^G, F_{sat}^G \in \mathbb{R}^{C \times H \times W}$ 。该操作在保留原始空间细节的同时，促使网络聚焦于共有的判别性区域。最后，将特征图沿空间维度展平，依次经过空间线性映射 $F_s^{H \times W \rightarrow d}$ 、通道展平操作及 L2 正则化 $Norm_{L_2}$ 处理，输出全局交互聚合向量 g_{uav}, g_{sat} 。公式如下所示：

$$[g_{uav}; g_{sat}] = Norm_{L_2} \left(Flatten \left(F_s^{H \times W \rightarrow d} ([F_{uav}^G; F_{sat}^G]) \right) \right) \quad (3-19)$$

其中， $g_{uav}, g_{sat} \in \mathbb{R}^{d \times C}$ ， d 表征空间映射维度。所输出的聚合向量实现了对动态干扰的有效过滤与稳健特征的联合编码，提供具备视角不变性的跨视角表征。

3.6 损失函数

为了在跨视角的无人机与卫星视图间建立稳健的跨视角映射关系，并有效利用每个批次内的正负样本，本文采用对称 InfoNCE 损失进行网络监督，同时结合交叉熵 Cross-Entropy 损失提升分类准确性，构建双损失联合优化目标。

(1) InfoNCE 对比损失

InfoNCE 损失是对比学习中常用的损失函数，用于量化查询图像与参考图像集之间的相似度，推动模型学习具有判别力的跨视图特征表示。其核心思想是最大化查询图像与对应正样本的相似度，同时最小化与负样本的相似度，公式定义如下：

$$L(q, R)_{InfoNCE} = -\log \left(\frac{\exp\left(\frac{q \cdot r^+}{\tau}\right)}{\sum_{i=0}^R \exp\left(\frac{q \cdot r_i}{\tau}\right)} \right) \quad (3-20)$$

其中， q 为查询图像的特征向量， R 为当前训练批次内参考图像（卫星视图）的特征向量集合； r^+ 是参考集中与 q 对应的唯一正样本，其余为负样本； τ 为温度系数，用于调节相似度分数的缩放比例； q 与 r_i 的点积运算用于度量特征向量间的相似度。该损失函数的对称形式能够促进视图间的有效特征交互与双向信息流动，使模型在训练过程中充分挖掘不同视角下地理场景的共性特征，增强跨视图表征的鲁棒性。

(2) Cross-Entropy 交叉熵损失

在跨视图地理定位任务中，同一地理场景的不同视角图像被划分为同一类别，本质上可视为多分类问题。为提升模型的分类准确性，本文引入交叉熵损失，最大化真实类别对应的预测概率。首先，计算模型对输入图像 x 的类别预测概率：

$$\hat{p}(y|x) = \frac{\exp(l_p(y))}{\sum_{c=1}^N \exp(l_c)} \quad (3-21)$$

其中， y 为输入图像 x 的真实类别标签， $l_p(y)$ 为模型对真实类别 y 的预测对数概率， N 为训练集中的地理类别总数， l_c 为模型对第 c 类的预测类别分数。

$$L_{CE} = -\log \hat{p}(y|x) \quad (3-22)$$

(3) 联合优化目标

在具体的联合优化策略上,考虑到无人机与卫星图像之间的跨视角配准本质上属于图像检索与度量学习任务,本文以 InfoNCE 对比损失作为主要优化目标,用于约束无人机视图与卫星视图之间的正负样本相似度关系,使同一地理位置的跨视角样本在特征空间中更加接近,并推动不同地理位置的负样本对相互远离。同时,交叉熵损失作为辅助监督参与参数更新,从地点身份判别角度增强最终输出特征的类别可分性,缓解外观相似地理区域之间的误匹配问题。两类损失协同作用,能够在保持跨视角度量空间结构稳定的基础上,进一步强化全局特征的判别能力。最终的模型优化目标定义如下:

$$Loss = L_{InfoNCE} + \lambda L_{CE} \quad (3-23)$$

其中, $L_{InfoNCE}$ 表示对称 InfoNCE 对比损失, L_{CE} 表示交叉熵分类损失, λ 为交叉熵损失的权重系数,用于控制身份判别监督在联合优化过程中的贡献程度。由于 λ 的取值会直接影响度量学习约束与分类判别约束之间的平衡,本文在后续实验中通过参数敏感性分析确定其最终取值。

3.7 实验与分析

3.7.1 实验环境与参数设置

本方法的消融实验和对比实验均在统一的软硬件环境下完成,具体配置如表 3-1 所示。为从不同场景特征和视角变化条件下评估模型的跨视图配准能力,本文选取 University-1652 与 SUES-200 两个公开基准数据集作为实验对象。其中, University-1652 包含多视角、多尺度和复杂城市结构场景,能够用于验证模型在无人机视图与卫星视图存在显著视角差异时的匹配能力; SUES-200 则包含不同飞行高度下的无人机图像,适用于评估模型在尺度变化和视场范围变化条件下的定位性能。

表 3-1 实验环境详情表

名称	型号/参数
中央处理器 (CPU)	13th Gen Intel(R) Core(TM) i9-13900KF
图形处理器 (GPU)	GeForce RTX 4090
内存	32G
深度学习框架	PyTorch1.12.1
开发语言	Python3.8
CUDA 版本	11.3

本文在训练阶段对数据预处理、网络初始化、优化策略和损失函数权重进行统一设置,以保证模型训练过程和实验评估结果的可复现性。在数据预处理阶段, University-1652 和 SUES-200 中的所有输入图像,包括无人机视图与卫星视图,均被调整至 384×384 像素分辨率,以消除不同数据源之间的输入尺度差异,并为跨视角特征提取提供一致的

空间尺寸基础。相较于较低分辨率输入，384×384 的图像尺寸能够更充分地保留建筑轮廓、道路边界、区域纹理和局部地物结构等关键视觉线索；同时，相较于更高分辨率输入，该设置能够控制显存占用和训练计算开销，在特征表达能力与计算负担之间保持较好的平衡。特征提取骨干网络选用在 ImageNet 上预训练的 ConvNeXt 模型，以增强模型对复杂场景中层次化语义特征和局部结构特征的提取能力。损失函数采用 InfoNCE 对比损失与交叉熵损失联合优化，其中交叉熵损失的权重超参数 λ 根据第 3.7.2 节中的敏感性分析结果设为 0.1，用于平衡跨视角度量学习约束与地点身份判别监督。网络优化采用随机梯度下降（SGD）算法，动量因子设定为 0.9，以降低参数更新过程中的震荡；权重衰减设定为 5×10^{-4} ，用于约束模型参数规模并缓解过拟合。训练全过程持续 120 个 Epoch，批次大小设定为 8，该设置综合考虑了显存占用、训练稳定性和对比学习中正负样本构造需求。学习率调度策略采用多步衰减机制，初始学习率设为 0.01，并在第 40、70 和 90 个 Epoch 时分别衰减至当前值的 0.1 倍，使模型在训练前期保持较快的特征空间收敛速度，并在训练后期逐步降低参数更新幅度，从而获得更加稳定的特征嵌入分布。上述超参数设置围绕跨视角地理定位任务的特征表达需求、模型收敛稳定性和计算开销控制进行确定，在保证不同实验设置一致性的基础上，为后续消融实验和对比实验提供统一的训练条件。

在推理与测试阶段，为了全方位验证模型在异构视角下的泛化性能与实际应用价值，本研究构建了双向跨视图检索模式：执行无人机视图检索卫星视图（Drone→Satellite）任务，旨在模拟 GPS 拒止环境下的无人机自定位场景，即利用无人机视图在卫星图库中查询最匹配的地图以确定自身坐标；另一方面，执行卫星视图检索无人机视图（Satellite→Drone）任务，旨在模拟基于视觉指引的无人机导航场景，即根据卫星图像到无人机图库中检索最匹配的无人机图像以实现导航。

在具体的推理过程中，模型首先将输入的查询集（Query）与候选图库（Gallery）图像映射至统一的联合度量空间，并分别提取出高维的全局特征描述符。随后，通过计算查询图像的特征向量与候选图库中所有图像特征向量之间的余弦相似度，量化两者在度量空间中的距离。系统根据计算得到的相似度得分，对图库中的所有候选图像按从高到低的顺序进行排列，从而输出最终的检索匹配列表。

为综合评估模型在图像配准精度与地理定位准确性方面的性能，本研究选取第二章介绍的召回率（Recall@K, R@K）与平均精度（Average Precision, AP）作为核心量化指标。其中，R@K 表示在生成的检索列表中，排名前 K 个结果内包含正确匹配图像的查询所占的百分比；特别是 R@1 指标，直接反映了模型最高置信度预测（Top-1）的绝对匹配准确率。AP 则是对检索列表整体质量的全局性度量，它不仅要求正确匹配项被召回，还严格考量了正确匹配项在候选列表中的排序位置（位置越靠前，AP 得分越高）。在双向检索任务中，R@1 和 AP 的数值越高，证明模型克服跨视角物理差异、特征空间

对齐的能力越强。

3.7.2 消融实验

为了系统性地验证本文提出的 VCSA-Net 网络中核心模块在跨视角地理定位任务中的有效性与必要性, 本文在 University-1652 和 SUES-200 数据集上设计并开展了详尽的消融实验。实验的 Baseline 采用权值共享的 ConvNeXt 双分支结构, 并在最终全局特征上进行 InfoNCE 对比损失与交叉熵损失联合监督, 并在此基础上, 通过逐步叠加语义引导视图校正模块 VRM、尺度自适应特征校准模块 SAM 以及跨视角语义对齐模块 CSM, 量化分析各核心组件在无人机自定位 (Drone→Satellite) 与无人机导航 (Satellite→Drone) 两大核心任务中的具体贡献。

(1) University-1652 数据集核心模块有效性分析

为了验证本文所提出的语义引导视图校正模块 (VRM)、尺度自适应特征校准模块 (SAM) 以及跨视角语义对齐模块 (CSM) 在跨视图图像配准任务中的有效性, 本节在 University-1652 数据集上开展核心模块消融实验。实验以基础双流特征匹配网络作为 Baseline, 并在此基础上分别引入单一模块及不同模块组合, 评估各模块在无人机自定位 (Drone→Satellite) 与无人机导航 (Satellite→Drone) 双向检索任务中的作用。具体结果如表 3-2 所示。

表 3-2 University-1652 数据集主要模块的消融实验结果

	VRM	SAM	CSM	Drone→Satellite		Satellite→Drone	
				R@1	AP	R@1	AP
1				88.47	89.82	92.95	89.15
2	√			90.13	89.51	94.06	88.78
3		√		88.94	91.18	93.61	90.14
4			√	89.26	90.43	93.82	89.87
5	√	√		90.61	91.94	94.68	91.07
6	√		√	90.82	91.03	94.29	89.66
7		√	√	89.78	92.09	94.81	90.46
8	√	√	√	91.27	92.89	95.35	91.64

由表 3-2 可知, 在 Baseline 基础上单独引入 VRM 后, Drone→Satellite 任务的 R@1 由 88.47% 提升至 90.13%, Satellite→Drone 任务的 R@1 由 92.95% 提升至 94.06%。这一结果表明, VRM 对跨视图空间结构差异具有较强的校正作用。University-1652 数据集中, 无人机图像通常由倾斜视角获取, 而卫星图像更接近正射视角, 同一建筑或场景区域在两类视图中的空间位置、轮廓形态和局部结构分布存在明显差异。VRM 通过全局引导增强流提取场景整体语义布局, 并结合局部重构增强流保留局部纹理与边界信息, 使几何空间对齐子模块能够在语义约束下学习更加合理的空间变换关系。因此, VRM 带来的性能提升主要来源于对无人机倾斜视图与卫星正射视图之间几何错位的缓解, 使两类视图的空间表征更加接近。

但从表中也可以看到,单独加入 VRM 后, Drone→Satellite 任务的 AP 由 89.82% 下降至 89.51%, Satellite→Drone 任务的 AP 也由 89.15% 下降至 88.78%。这说明仅依靠视图校正并不能完全解决跨视图匹配问题。其原因在于, VRM 侧重于对无人机视图特征进行空间重映射,能够改善宏观空间结构的不一致,但在重映射过程中,局部区域的尺度关系和细粒度纹理分布仍可能发生变化。对于候选图像中外观相似、布局接近的样本,仅完成空间校正还不足以保证特征表达的稳定性。因此, VRM 更主要解决跨视角几何错位问题,而尺度差异和局部区域响应偏移仍需要后续模块进一步处理。

单独引入 SAM 后, Drone→Satellite 任务的 AP 由 89.82% 提升至 91.18%, Satellite→Drone 任务的 AP 由 89.15% 提升至 90.14%。由此可见, SAM 对跨视图尺度表达的一致性具有明显改善作用。由于无人机拍摄高度、视场范围和目标成像尺度与卫星图像并不完全一致,同一地物在两类视图中的尺度大小、上下文范围和空间响应位置可能存在差异。SAM 中的多尺度感知子模块通过不同感受野提取局部结构与较大范围上下文信息,使网络能够在多尺度特征中选择更适合当前样本的表达;空间坐标注意力进一步引入位置信息,对尺度变化引起的空间响应偏移进行校准。因此, SAM 的性能增益主要来源于对跨视图尺度差异和空间布局偏移的修正,使无人机视图与卫星视图在特征粒度层面更加一致。

单独引入 CSM 后, Drone→Satellite 任务的 R@1 和 AP 分别提升至 89.26% 和 90.43%, Satellite→Drone 任务的 R@1 和 AP 分别提升至 93.82% 和 89.87%。这是因为跨视角语义交互能够进一步增强两类视图之间的共有语义表达。无人机图像中可能包含车辆、行人、临时设施等动态或非共有区域,而卫星图像更多反映建筑、道路、广场等相对稳定的地理结构。如果直接进行特征匹配,非共有语义信息容易干扰相似性度量。CSM 通过跨视角局部交互建模局部区域之间的对应关系,并利用跨视角全局交互增强整体语义一致性,使模型更加关注两类视图中共有且稳定的地物线索。因此, CSM 的作用并不是单纯增强所有特征,而是通过跨视图语义交互提高有效语义区域的一致性,降低非共有区域对匹配结果的影响。

从模块组合结果来看, VRM 与 SAM 联合使用后, Drone→Satellite 任务的 R@1 和 AP 分别达到 90.61% 和 91.94%, Satellite→Drone 任务分别达到 94.68% 和 91.07%, 相比单独使用 VRM 或 SAM 均取得更稳定的提升。这一现象说明二者在作用机制上具有互补关系。VRM 主要从视角几何层面对无人机特征进行校正,缓解倾斜视角与正射视角之间的空间错位; SAM 则在此基础上进一步处理由拍摄高度、视场范围和目标尺度变化带来的尺度不一致问题。二者结合后能够同时改善几何结构与尺度粒度两个层面的特征一致性。

当 VRM、SAM 与 CSM 三个模块共同引入后,模型在两个方向的检索任务中均取得最优结果。其中, Drone→Satellite 任务的 R@1 和 AP 分别达到 91.27% 和 92.89%, 相

较 Baseline 分别提升 2.80%和 3.07%; Satellite→Drone 任务的 R@1 和 AP 分别达到 95.35%和 91.64%, 相较 Baseline 分别提升 2.40%和 2.49%。该结果表明, 三类模块围绕跨视图特征不一致问题形成了逐层递进的优化过程: VRM 首先缓解无人机视图与卫星视图之间的空间几何错位, SAM 进一步校准不同视角和尺度条件下的特征粒度差异, CSM 最后通过跨视角交互增强共有静态地物语义并削弱非共有区域干扰。经过几何、尺度和语义三个层面的连续校准后, 模型能够获得更加一致且具有判别性的跨视图特征表示, 从而提升图像配准与地理定位性能。

(2)SUES-200 数据集核心模块的多高度定位性能分析

为了进一步探究本文提出的各个核心模块 (VRM、SAM、CSM) 在不同飞行高度下的定位性能及相互作用机制, 我们在 SUES-200 数据集上进行了详细的多高度消融实验。SUES-200 数据集包含了 150m、200m、250m 和 300m 四个不同高度梯度的无人机图像, 这为验证模型在应对剧烈尺度变化和视角差异时的鲁棒性提供了测试场景。各模块在无人机到卫星 (Drone → Satellite) 不同高度下的定位消融实验结果如表 3-3 所示, 在卫星到无人机 (Satellite→Drone) 任务下的测试结果如表 3-4 所示:

表 3-3 SUES-200 数据集主要模块在 Drone→Satellite 的不同高度消融实验结果

	VRM	SAM	CSM	150m		200m		250m		300m	
				R@1	AP	R@1	AP	R@1	AP	R@1	AP
1				88.15	90.54	90.22	91.85	90.85	92.15	91.68	92.54
2	√			89.42	90.28	91.68	91.93	92.18	92.31	93.1	92.83
3		√		88.76	91.81	90.79	93.21	91.37	93.48	92.46	93.97
4			√	88.93	91.17	91.14	92.76	91.72	92.89	92.51	93.36
5	√	√		90.61	92.73	92.36	93.88	92.91	93.76	93.89	94.38
6	√		√	90.87	91.62	92.62	93.11	93.06	93.18	94.14	93.82
7		√	√	89.78	92.94	91.82	94.18	92.41	94.13	93.23	94.67
8	√	√	√	91.24	93.68	93.10	94.82	93.64	94.52	94.51	95.23

表 3-4 SUES-200 数据集主要模块在 Satellite→Drone 的不同高度消融实验结果

	VRM	SAM	CSM	150m		200m		250m		300m	
				R@1	AP	R@1	AP	R@1	AP	R@1	AP
1				91.54	91.25	93.68	92.16	94.12	93.24	94.87	93.82
2	√			92.87	91.18	95.04	91.92	95.48	93.02	96.21	93.59
3		√		91.92	92.63	94.31	93.58	94.83	94.91	95.34	95.28
4			√	92.41	92.11	94.73	93.12	95.07	94.36	95.73	94.84
5	√	√		93.74	93.31	95.89	94.17	96.19	95.43	96.82	95.81
6	√		√	94.12	92.79	96.22	93.73	96.52	94.79	97.43	95.42
7		√	√	93.04	93.84	95.34	94.49	95.61	94.84	96.58	96.37
8	√	√	√	94.53	94.29	96.73	94.82	96.91	96.11	97.82	96.91

由表 3-3 可知, 在 Drone→Satellite 任务中, Baseline 在 150m、200m、250m 和 300m 高度下的 R@1 分别为 88.15%、90.22%、90.85%和 91.68%, AP 分别为 90.54%、91.85%、

92.15%和 92.54%。随着高度升高,无人机图像的视场范围逐渐扩大,场景中的道路、建筑轮廓和区域结构信息更加完整,因此基础模型的定位性能也呈现一定提升趋势。然而,在 150m 和 200m 等较低高度下,由于视场范围较小、局部地物尺度变化更明显,无人机视图与卫星视图之间仍存在较强的尺度差异和空间布局差异,导致 Baseline 的性能相对受限。

在引入本文所提出的核心模块后,模型在各高度下均取得稳定提升。完整模型在 Drone→Satellite 任务中,于 150m、200m、250m 和 300m 高度下的 R@1 分别达到 91.24%、93.10%、93.64%和 94.51%,相较 Baseline 分别提升 3.09%、2.88%、2.79%和 2.83%; AP 分别达到 93.68%、94.82%、94.52%和 95.23%,相较 Baseline 分别提升 3.14%、2.97%、2.37%和 2.69%。其中,150m 低空场景下的提升幅度相对更明显,说明在局部地物占比更大、跨视图尺度差异更突出的情况下,视图校正、尺度校准和语义对齐的联合建模能够有效缓解低空视角带来的特征不一致问题。

从模块组合结果来看,VRM 与 SAM 联合使用后,模型在四个高度下均明显优于 Baseline,这一现象说明几何校正与尺度校准对多高度定位具有互补作用。VRM 主要缓解无人机倾斜视图与卫星正射视图之间的空间错位,SAM 则进一步校准不同高度下由视场范围和地物成像尺度变化引起的尺度差异。进一步加入 CSM 后,完整模型在各高度下取得最优结果,表明在几何和尺度差异得到缓解后,跨视角语义一致性仍然会影响定位性能。CSM 通过增强两类视图中的共有静态地物语义,进一步降低非共有区域对匹配结果的干扰。

由表 3-4 可知,在 Satellite→Drone 任务中,完整模型同样保持稳定优势。相较于 Baseline,完整模型在 150m 高度下的 R@1 由 91.54%提升至 94.53%,AP 由 91.25%提升至 94.29%;在 300m 高度下的 R@1 由 94.87%提升至 97.82%,AP 由 93.82%提升至 96.91%。该变化反映出所提方法不仅能够提升无人机图像到卫星图像的定位性能,也能够从卫星图像检索不同高度无人机图像的反向任务中保持较好的稳定性。由于该任务需要同时区分地理区域差异和高度尺度差异,完整模型的稳定提升进一步说明其具有较好的多高度适应能力。

综上,SUES-200 数据集上的多高度消融实验表明,本文方法在不同飞行高度下均能够获得稳定性能提升。VRM、SAM 和 CSM 分别从几何结构、尺度表达和语义一致性三个层面对跨视图特征进行校准,使模型能够更好地适应高度变化带来的视场范围变化、尺度差异和空间布局差异,从而提升多高度无人机视觉定位的稳定性。

(3) 无人机视图数量的分析

本节基于 University-1652 数据集,全面分析了无人机视图数量对跨视角定位性能的影响。如表 3-5 所示,实验结果表明,无论是在无人机自定位(Drone→Satellite)还是无人机导航(Satellite→Drone)任务中,增加无人机视图数量均能提升检索精度。在自定

位任务中，当输入查询的无人机视图数量从单视图增加至 54 个视图时， $R@1$ 精度由 85.57% 提升至 91.27%。这是由于联合多视角的特征表达能够有效弥补单一视角下固有的物理遮挡与视角局限，通过引入空间观测的互补性，构建出更为完整、鲁棒的目标全局表征，从而优化了无人机视图与卫星基准图的特征对齐质量。同理，在导航任务中，将图库内的无人机候选样本密度从单视图扩展至 54 视图， $R@1$ 精度也从 93.26% 稳步提升至 95.35%。增加图库的多方位样本密度，本质上是在物理层面为目标地物构建了覆盖更全面的三维离散化观测空间，这有效增加了无人机视角候选样本中与宏观正射卫星图视觉结构高度契合的图像概率，进一步证实了多视图信息的完备性对提升视觉定位精度具有关键作用。

表 3-5 University-1652 数据集的无人机视图图像数量的消融实验结果

Drone-view image number	Drone→Satellite		Satellite→Drone	
	$R@1$	AP	$R@1$	AP
1	85.57	87.42	93.26	84.62
3	89.48	90.23	94.53	88.72
9	90.61	91.25	94.76	90.34
18	90.96	91.57	94.88	90.89
27	91.08	92.43	95.01	90.97
54	91.27	92.89	95.35	91.64

(4) 损失函数权重敏感性分析

为进一步分析联合损失函数中权重系数设置对模型性能的影响，本文在 University-1652 数据集上对交叉熵损失权重 λ 进行了敏感性实验。在实验过程中，保持网络结构、输入图像尺寸、优化器、学习率、训练轮数以及其他训练参数设置不变，仅改变 λ 的取值，以验证不同分类监督强度下模型跨视角检索性能的变化。实验结果如表 3-6 所示。

表 3-6 λ 敏感性分析实验结果

λ	Drone→Satellite		Satellite→Drone	
	$R@1$	AP	$R@1$	AP
0.01	90.74	92.21	94.82	91.02
0.05	91.03	92.56	95.12	91.37
0.10	91.27	92.89	95.35	91.64
0.20	91.16	92.73	94.88	90.89
0.50	91.08	92.43	95.21	91.49
1.00	90.31	91.84	94.54	91.64

由表 3-6 可知，当 λ 取值较小时，交叉熵损失在联合优化中的贡献相对有限，模型主要依赖 InfoNCE 损失约束跨视角正负样本之间的相似性关系。该设置虽然能够实现基本的度量空间学习，但地点身份判别监督不足，使得外观相似地理区域之间的特征边界仍不够清晰，导致 $R@1$ 和 AP 指标相对受限。随着 λ 逐渐增大，交叉熵损失对全局判别特征的约束作用增强，有助于提升不同地理位置样本之间的类别可分性，使特征空间分布

更加稳定, 因此模型在两个检索方向上的首位检索准确率和整体排序质量均得到提升。

当 $\lambda=0.1$ 时, 模型在 Drone $\rightarrow$ Satellite 和 Satellite $\rightarrow$ Drone 两个检索方向上均取得最优结果, 说明适度引入交叉熵损失能够有效增强地理位置身份判别能力, 并与 InfoNCE 对比损失形成互补。进一步增大 λ 后, 分类监督在联合损失中的相对贡献持续增强, 模型优化过程更容易偏向训练集地点身份分类边界的拟合, 从而削弱无人机视图与卫星视图之间细粒度相似性排序关系的建模能力, 导致检索性能出现下降。综合不同 λ 取值下的 R@1 与 AP 表现, 本文最终选取 $\lambda=0.1$ 作为默认权重配置, 使模型能够在跨视角度量学习约束与地点身份判别约束之间保持较为稳定的优化平衡。

(5) 可视化分析

为了进一步探究本文所提模块在应对跨视图特征不一致时的内在机理。本节基于 University-1652 数据集选取典型的多方位角测试样本, 通过特征激活热力图直观呈现 VCSA-Net 在跨视角图像配准中的视觉特征演化现象。图 3-10 记录了同一地理目标在多无人机观测方位下的视图物理状态与热力图响应分布。图中各行依次定义为: (a)原始多视角无人机查询图像与卫星参考图像; (b)经语义引导视图校正模块 (VRM) 校正后的无人机视图; (c)视图校正后的无人机和卫星特征激活热力图; (d)模型处理后的最终特征激活热力图。




图 3-10 跨视角场景下特征热力图演变与几何校正的可视化效果图

观察图 3-10 的视图特征响应演化过程可以发现, 原始的倾斜无人机图像(a)受拍摄方位影响存在透视形变。经过 VRM 视图校正处理后, (b)行和(c)行显示无人机视图已被有效映射至近似正射空间, 初步消除了跨视角的物理错位, 网络注意力开始向建筑物主体转移; 但此时热力图表征的部分区域仍受干扰, 响应区域存在一定发散。随后经过进一步的深层特征精炼, 如(d)行的最终结果所示, 经过 SAM 和 CSM 处理后, 模型抑制了多视角下非共有区域特征响应。此时, 高强度特征激活区域表现出较强的内聚性, 不

仅较为准确、稳定地聚焦于核心建筑等共有的静态地物上方，而且边界与实际物理轮廓高度贴合。这一逐阶段的可视化结果直观地证明，模型层层递进克服了跨视图的空间差异，通过抑制非共有的地物特征响应，模型较为稳定地聚焦于核心建筑区域，展现出了模型较好的聚焦稳定性与视角鲁棒性。

3.7.3 对比实验

为了客观评估 VCSA-Net 在跨视角地理定位任务中的综合性能，我们在 University-1652 和 SUES-200 两个主流基准数据集上与当前领域内的先进方法进行了横向对比。对比算法涵盖了基于卷积神经网络的经典方法、基于视觉 Transformer 的方法以及近期针对跨视角差异优化的前沿方法。

(1) University-1652 数据集跨视角定位性能对比

为进一步验证本文所提出 VCSA-Net 在大视角差异场景下的跨视角图像配准能力，本文在 University-1652 数据集上与现有代表性方法进行了对比实验。University-1652 数据集包含无人机视图、卫星视图和地面视图等多源图像，其中无人机图像具有多角度、多高度采集特点，能够较好地反映无人机倾斜视图与卫星正射视图之间的几何错位、尺度变化和语义差异。实验分别从 Drone→Satellite 和 Satellite→Drone 两个检索方向评估模型性能，结果如表 3-7 所示，其中，最佳结果以红色突出显示、次佳结果以蓝色突出显示。

表 3-7 本算法与其他算法在 University-1652 数据集上的对比实验结果

Method	Year	Parameters/M	GFLOPs	Drone→Satellite		Satellite→Drone	
				R@1	AP	R@1	AP
MuSe-Net ^[21]	2024	50.47	-	74.48	77.83	88.02	75.10
LPN ^[45]	2021	62.39	36.78	75.93	79.14	86.45	74.79
FSRA ^[23]	2022	51.80	12.29	82.25	84.82	87.87	81.53
MCCG ^[72]	2023	56.65	51.04	89.64	91.32	94.30	89.39
SDPL ^[73]	2024	42.56	69.71	90.16	91.64	93.58	89.45
TransFG ^[22]	2024	> 86.00	-	84.01	86.31	90.16	84.61
SeGCN ^[74]	2024	-	-	89.18	90.89	94.29	89.65
MFJR ^[75]	2024	>88.00	-	91.87	93.15	95.29	91.51
QDFL ^[77]	2025	108.87	123.19	95.00	95.83	97.15	94.57
Ours	-	43.86	47.23	91.27	92.89	95.35	91.64

考虑到无人机视觉定位算法最终需要部署于算力、存储和功耗均受限的机载边缘平台，仅从检索精度评价模型性能难以全面反映方法的工程适用性。因此，本文在对比实验中进一步补充 Parameters 和 GFLOPs 指标，用于衡量不同方法的模型规模与计算复杂度。通过同时分析定位精度、参数量和计算开销，可以更全面地评价不同方法在无人机端侧视觉定位任务中的综合适用性。

由表 3-7 可知,在 Drone→Satellite 任务中,本文方法取得了 91.27%的 R@1 和 92.89%的 AP。与 MuSe-Net、LPN、FSRA、MCCG、SDPL、TransFG 和 SeGCN 等方法相比,本文方法在首位检索准确率和整体排序质量上均取得了更高结果。相比 MCCG,本文方法在 R@1 和 AP 上分别提升 1.63%和 1.57%;相比 SeGCN,分别提升 2.09%和 2.00%。该性能增益主要来源于 VCSA-Net 对跨视图特征不一致问题的针对性建模:首先通过视图校正缓解无人机倾斜视图与卫星正射视图之间的空间几何错位,随后利用尺度自适应特征校准改善不同视角下的尺度表征差异,最后通过跨视角语义交互增强两类视图中的共有稳定地物特征,从而提升无人机图像检索卫星图像时的匹配稳定性。

与 MFJR 和 QDFL 等高精度方法相比,本文方法在 Drone→Satellite 方向上的 R@1 和 AP 仍存在一定差距。其中,QDFL 在该方向取得了 95.00%的 R@1 和 95.83%的 AP, MFJR 达到了 91.87%的 R@1 和 93.15%的 AP,均高于本文方法。该差距反映出最新高性能方法在细粒度判别特征挖掘和检索排序优化方面仍具有优势。本文方法并不追求在单一精度指标上取得最高结果,而是更侧重于在较低模型复杂度下获得稳定且具有竞争力的跨视角定位性能。

在 Satellite→Drone 任务中,本文方法取得了 95.35%的 R@1 和 91.64%的 AP,在该方向上仅低于 QDFL,均为表中次优结果。与 MFJR 相比,本文方法在 R@1 和 AP 上分别提升 0.06%和 0.13%;与 MCCG 相比,分别提升 1.05%和 2.25%;与 SeGCN 相比,分别提升 1.06%和 1.99%。Satellite→Drone 任务需要从多个无人机候选视角中检索与卫星图像对应的目标区域,模型需要同时适应无人机拍摄角度、局部视场范围和尺度变化带来的表征偏移。本文方法在该方向上取得次优结果,体现出其在反向跨视图检索中的特征对齐能力和尺度适应能力。

进一步结合模型复杂度进行分析可以发现,部分最新方法虽然在精度上取得了更高结果,但通常伴随更大的参数规模和计算开销。例如,QDFL 在两个检索方向上取得了最优精度,但其参数量和计算复杂度分别达到 108.87M 和 123.19G。相比之下,本文方法的参数量和 GFLOPs 分别为 43.86M 和 47.23G,仅约为 QDFL 的 40.3%和 38.3%。在模型规模和计算开销显著降低的情况下,本文方法仍在 Satellite→Drone 方向取得次优性能,并在 Drone→Satellite 方向超过多数对比方法,具备较好的精度—复杂度平衡。

与 SDPL 相比,本文方法的参数量略高,但在 Drone→Satellite 任务中 R@1 和 AP 分别提升 1.11%和 1.25%,在 Satellite→Drone 任务中 R@1 和 AP 分别提升 1.77%和 2.19%。在相对可控的参数规模下,本文方法获得了更稳定的跨视角定位性能。与 LPN、FSRA 等计算量较低的方法相比,本文方法虽然计算复杂度有所增加,但双向检索精度均有明显提升,额外计算开销主要服务于跨视图几何校正、尺度校准和语义对齐等关键环节,并带来了相应的定位性能收益。

综上所述,VCSA-Net 在 University-1652 数据集上表现出较好的跨视角图像配准能

力。虽然与 QDFL 等最新高精度方法相比,本文方法在部分精度指标上仍存在一定差距,但其能够在较低参数量和较低计算复杂度条件下实现稳定的定位性能,尤其在 Satellite→Drone 方向取得了次优结果。结合本文面向无人飞行器端侧视觉定位的应用目标,该方法在大视角差异场景下具有较好的综合性能和工程部署价值。

(2) SUES-200 数据集不同高度定位性能对比

为进一步验证本文方法在多高度场景下的适应能力,本文在 SUES-200 数据集上进行对比实验。该数据集包含 150m、200m、250m 和 300m 四个飞行高度的无人机图像,不同高度下无人机图像的视场范围、地物尺度和局部空间布局均存在差异,因此能够用于评估模型在高度变化条件下的跨视图定位性能。Drone→Satellite 和 Satellite→Drone 两个方向的实验结果分别如表 3-8 和表 3-9 所示。

由表 3-8 可知,在 Drone→Satellite 任务中,本文方法在 150m、200m、250m 和 300m 高度下的 R@1 分别为 91.24%、93.10%、93.64%和 94.51%, AP 分别为 93.68%、94.82%、94.52%和 95.23%。与 SUES-200Baseline、LCM、LPN 和 FSRA 等方法相比,本文方法在各高度下均取得了明显提升,说明所提方法能够有效适应不同飞行高度下的图像配准需求。尤其在 150m 和 200m 等较低高度下,无人机视图覆盖范围较小,局部地物占比较大,与卫星图像之间存在更明显的尺度差异和内容范围差异,本文方法仍然取得了较高的 R@1 和 AP,表明视图校正与尺度自适应机制能够有效缓解低空视角下的空间表征差异。

需要说明的是,在 250m 和 300m 等较高高度下, MCCG 在部分指标上取得了较高结果,例如 300m 高度下 MCCG 的 R@1 和 AP 分别为 95.07%和 96.20%,高于本文方法的 94.51%和 95.23%。这表明当飞行高度升高、无人机视图覆盖范围逐渐接近卫星视图时,基于跨视图关系建模的方法也能够获得较强的匹配效果。相比之下,本文方法在不同高度下的优势主要体现在整体稳定性和低空至中空场景的连续适应能力上。也就是说, VCSA-Net 更关注由视角变化、尺度变化和语义差异共同造成的跨视图特征不一致问题,因此在高度变化较明显、尺度差异较突出的场景下具有较好的适应性。

表 3-8 本算法与其他算法在 SUES-200 数据集上 Drone→Satellite 的对比实验结果

Method	150m		200m		250m		300m	
	R@1	AP	R@1	AP	R@1	AP	R@1	AP
SUES-200	55.65	61.92	66.78	71.55	72.07	76.43	74.05	78.26
LCM	43.42	49.65	49.42	55.91	54.47	60.31	60.43	64.78
LPN	61.58	67.23	70.85	75.86	80.38	83.80	81.47	84.53
FSRA	59.18	65.28	74.88	79.20	82.67	85.76	88.88	90.82
MBF	85.62	88.21	87.43	90.02	90.65	92.53	92.12	93.63
MCCG	82.22	85.47	89.38	91.41	93.82	95.04	95.07	96.20
SeGCN	90.80	92.32	91.93	93.41	92.53	93.90	93.33	94.61
VCSA-Net(Ours)	91.24	93.68	93.10	94.82	93.64	94.52	94.51	95.23

由表 3-9 可知, 在 Satellite→Drone 任务中, 本文方法在 150m、200m、250m 和 300m 高度下的 R@1 分别为 94.53%、96.73%、96.91%和 97.82%, AP 分别为 94.29%、94.82%、96.11%和 96.91%。相较于 SUES-200Baseline、LCM、LPN、FSRA 和 MBF 等方法, 本文方法在不同高度下均保持较高性能。与 SeGCN 相比, 本文方法在 150m 和 200m 高度下的 R@1 和 AP 均有所提升, 说明在低空和中低空场景中, 几何结构校正与尺度表达校准能够有效提高卫星图像到无人机图像的匹配稳定性。

同时也可以看到, 在 Satellite→Drone 的 300m 高度下, MCCG 的 R@1 为 98.75%, 高于本文方法的 97.82%, 但本文方法的 AP 为 96.91%, 略高于 MCCG 的 96.64%。这一结果说明, 在高空场景中, 部分对比方法能够在 R@1 上取得较强表现, 而本文方法在检索结果整体排序方面仍保持较好的稳定性。结合 Drone→Satellite 和 Satellite→Drone 两个方向的结果可以看出, 本文方法并非在所有单项指标上都绝对最优, 但在多高度、多方向实验中整体表现稳定, 表明其对飞行高度变化引起的尺度差异和空间布局变化具有较好的适应能力。

表 3-9 本算法与其他方法在 SUES-200 数据集上 Satellite→Drone 的对比实验结果

Method	150m		200m		250m		300m	
	R@1	AP	R@1	AP	R@1	AP	R@1	AP
SUES-200 Baseline	75.00	55.46	85.00	66.05	86.25	69.94	88.75	74.46
LCM	57.50	38.11	68.75	49.19	72.50	47.94	75.00	59.36
LPN	83.75	66.78	88.75	75.01	92.50	81.34	92.50	85.72
FSRA	73.75	63.70	86.25	78.02	91.25	84.83	93.25	89.88
MBF	88.75	84.74	91.25	89.95	93.65	90.65	96.25	91.60
MCCG	93.75	89.72	93.75	92.21	96.26	96.14	98.75	96.64
SeGCN	93.75	92.45	95.00	93.65	96.25	94.39	97.50	94.55
VCSA-Net(Ours)	94.53	94.29	96.73	94.82	96.91	96.11	97.82	96.91

总体而言, SUES-200 数据集上的实验结果表明, VCSA-Net 能够较好适应无人机飞行高度变化带来的视场范围、目标尺度和空间布局差异。该方法在多数高度条件下取得了具有竞争力的检索性能, 并在双向检索任务中保持较平稳的指标变化, 体现出其在多高度跨视角定位场景中的稳定性和应用潜力。

(3)场景一：无人机不同倾斜角度的测试场景

图 3-11 与图 3-12 分别展示了本文方法与对比方法在 University-1652 数据集上的 Top-1 检索结果对比与特征关注热力图。该场景包含同一地理目标在不同环绕方位角和倾斜观测角度下的无人机图像, 主要用于验证模型在无人机倾斜视图与卫星正射视图存在显著几何投影差异时的空间对齐能力。



图 3-11 不同拍摄视角下的无人机自定位 Top-1 检索结果可视化对比




图 3-12 不同拍摄视角下的特征关注热力图可视化对比

由图 3-11 可知，当无人机视图发生明显倾斜变化时，同一建筑物在无人机图像与卫

星图像中的投影形态、空间位置和局部轮廓会产生较大差异，导致跨视图特征匹配难度增加。FSRA、LPN 等方法主要依赖全局或局部特征聚合，对倾斜视图与正射视图之间的空间错位缺乏充分约束，因此在部分大角度观测样本中容易检索到外观相似但地理位置错误的卫星图像。SeGCN、MCCG 等方法虽然增强了跨视图特征关系建模能力，但在无人机视角变化较大时，仍可能受到空间布局偏移的影响而出现误匹配。相比之下，本文方法能够在多个倾斜视角下保持正确匹配，说明其能够较好地缓解倾斜成像带来的空间投影差异，使无人机视图与卫星视图在空间结构层面建立更加稳定的对应关系。

图 3-12 的特征热力图进一步验证了上述结论。对比方法的高响应区域在不同倾斜角度下存在一定偏移，部分响应扩散至周边背景区域，说明其对目标主体的空间关注不够稳定。本文方法的热力图则能够较为稳定地聚焦于建筑主体及其关键结构区域，且不同无人机观测方位下的响应位置具有较好的一致性。这表明本文方法能够在较大视角差异条件下保持相对稳定的目标关注区域，从而提升跨视图特征匹配的可靠性。

同时，从图 3-11 中的失败样例可以看出，当无人机视角倾斜程度过大、目标主体仅局部可见，或有效共视区域严重不足时，跨视图图像之间的空间对应关系仍会被削弱，模型可能受到候选卫星图像中相似建筑布局的干扰而产生误匹配。这说明本文方法能够有效缓解常规倾斜视角下的几何错位问题，但在极端视角变化和共视信息不足的条件下仍存在一定局限。

综合检索结果与热力图表现可以看出，本文方法通过增强跨视图空间结构一致性，在不同拍摄角度下表现出较好的视角鲁棒性和图像配准稳定性。

(4) 场景二：不同高度下跨视图尺度自适应的测试场景

图 3-13 与图 3-14 分别展示了本文方法与对比方法在 SUES-200 数据集上的 Top-1 检索结果对比与特征关注热力图。该场景包含 150m、200m、250m 和 300m 四个不同飞行高度下的无人机图像。随着飞行高度变化，无人机图像的视场范围、目标成像尺度和局部空间布局均会发生明显变化，因此该场景主要用于验证模型在高度变化条件下的尺度适应能力。

由图 3-13 可知，在 150m 低空场景下，无人机图像覆盖范围较小，目标区域往往只呈现局部结构，难以与卫星图像中的完整场景建立稳定对应关系。FSRA、LPN 等方法在低空场景中容易受到局部纹理和背景区域干扰，检索到具有相似颜色或纹理分布的错误卫星图像。SeGCN、MCCG 等方法在部分高度下能够取得较好结果，但面对低空视场受限和尺度差异明显的样本时，仍存在一定误匹配现象。相比之下，本文方法在多个高度下均能保持较稳定的检索表现，说明其能够有效缓解不同飞行高度引起的目标尺度变化和空间响应偏移问题。



图 3-13 不同飞行高度下的无人机自定位 Top-1 检索结果可视化对比




图 3-14 不同飞行高度下无人机与卫星视角的特征关注热力图可视化对比图

图 3-14 的热力图进一步展示了不同高度下模型特征关注区域的变化情况。在低空

高度下,对比方法的激活区域容易分散到周边道路、植被或无关背景区域,说明其对局部视场中的关键地物缺乏稳定聚焦能力。随着高度升高,目标区域在图像中的空间范围和上下文信息逐渐完整,对比方法的表现有所改善,但其响应区域仍存在边界发散或关注不集中的情况。本文方法则能够根据飞行高度变化保持相对合理的特征响应范围,在低空场景中关注局部有效结构,在高空场景中聚焦更完整的地物主体,从而提升不同高度条件下无人机图像与卫星图像之间的匹配稳定性。

这一现象表明,本文方法并非简单依赖某一固定尺度特征进行匹配,而是能够适应不同高度下的视觉观测范围变化,使跨视图特征在尺度表达上较好地保持一致性。尤其在低空和中低空场景中,无人机图像与卫星图像之间的尺度差异更加明显,本文方法仍能获得较稳定的检索结果,体现出较好的尺度鲁棒性。

(5) 场景三:跨视图语义不一致的测试场景

在无人机视觉定位实际应用中,无人机实时采集图像与离线卫星底图之间通常存在时间差异,因此两类视图在语义内容上并不完全一致。无人机图像中可能非共有区域、跨视图语义差异区域,而卫星图像通常反映相对稳定的地理场景。这类非共有目标会在跨视图匹配过程中引入语义干扰,影响建筑、道路等稳定地物特征的表达。图 3-15 展示了语义不一致场景下不同方法的 Top-1 检索结果对比。

由图 3-15 可知,在无人机查询图像中,道路区域存在数量较多的车辆或行人等动态目标。这些目标在无人机视图中存在局部响应,但在对应卫星图像中通常不存在相应的语义区域。如果模型直接将这些动态目标作为显著特征进行匹配,就容易破坏无人机视图与卫星视图之间的语义一致性,导致检索结果偏向局部外观相似但地理位置错误的候选图像。FSRA、LPN、SeGCN 和 MCCG 等方法在该场景中均不同程度受到非共视区域干扰,证明了仅依赖特征增强或全局关系建模,难以充分过滤跨视图之间的非共有语义特征。

相比之下,本文方法能够在语义不一致的情况下检索到正确的卫星图像,表明能更有效地利用两类视图之间共有的稳定地理线索。具体而言,模型在特征匹配过程中更加关注道路结构、建筑轮廓和场景布局等具有跨视图一致性的静态地物,而不是过度依赖车辆等非共有动态目标。因此,在动态目标干扰较明显的场景中,本文方法仍能够保持较好的图像配准效果和地理定位精度。

同时,图 3-15 中的失败样例也表明,当动态目标被弱化后,模型主要依赖剩余静态地理特征进行匹配。如果场景中静态特征本身区分度不足,或者候选卫星图像在道路走向、建筑分布和背景结构上高度相似,模型仍可能出现误匹配。这说明抑制非共有语义干扰有助于提升匹配稳定性,但跨视图定位最终仍依赖稳定静态地物是否具有足够判别性。



图 3-15 语义不一致场景下无人机自定位 Top-1 检索结果可视化对比

总体而言,该场景验证了本文方法在语义层面对跨视图特征不一致问题的处理能力。本文方法能够在无人机实时图像和卫星参考图像之间建立更加可靠的共有语义对应关系,降低动态目标和非共有区域造成的干扰,从而提升跨视图图像配准与无人机地理定位的鲁棒性。

3.8 本章小结

针对无人机倾斜视图与卫星正射视图间存在的几何错位、尺度差异及语义差异导致的跨视图特征不一致问题,本章提出一种基于视图校正与尺度自适应的图像配准地理定位方法。实验结果表明,所提出方法在跨视角地理定位数据集上有效克服了跨视图差异,提升了跨视图的图像配准精度,进而实现了更高精度的无人机自定位。

本方法的主要贡献可概述如下:

(1) 提出语义引导的视图校正模块 **VRM**。该模块通过语义先验知识引导空间仿射变换,将无人机倾斜视角的局部特征显式地重投影至标准的正射投影空间,从特征层面上消除了由透视投影引发的几何空间错位现象,建立了更为准确的跨视图几何对应关系。

(2) 设计尺度自适应特征校准模块 **SAM**,该模块利用多尺度感知机制动态匹配有效的语义粒度,并结合空间约束校准布局偏移,有效提升单侧视图的尺度鲁棒性,为跨视角尺度对齐提供了统一的度量基准。

(3) 构建跨视角语义对齐模块 **CSM**,该模块通过双向语义交互机制,利用卫星静态上下文抑制无人机非共有动态区域的特征响应,同时借助无人机细粒度纹理引导卫星聚焦共有目标,从而有效保证跨视图之间的语义一致性。

第4章 基于特征补全与特征增强的图像配准的地理定位方法

4.1 引言

第三章所提出的方法有效克服了跨视图的几何错位与尺度差异，在城市大视角差异场景下取得了优异的图像配准性能。然而，在实际的无人机作业中，环境往往更加复杂多变，常面临城市中表面纹理单一的建筑群，以及郊区大面积地表覆盖同质化（如广阔的水域、植被）和人工建筑物分布稀疏的非结构化场景。在这类场景中，跨视角特征配准主要面临两大严峻挑战：一方面，背景纹理信息薄弱，地表覆盖呈现出较高的同质性，缺乏差异化的纹理；另一方面，关键地理目标占比不足，可用于定位的显著地物（如孤立建筑、道路交汇处等）分布稀疏，在整体图像视场中占据的像素比例较低。这两大因素共同导致无人机视图与卫星视图之间可用于配准的有效特征信息匮乏，引发特征稀疏难题。这种特征稀疏使得现有的主流方法面临适应性瓶颈：以 MCCG 为代表的注意力机制方法在关键目标信号微弱且缺乏明确结构引导时，容易受环境中占据主导地位的低频背景噪声干扰而产生误匹配；而以 SeGCN 为代表的拓扑推理方法因缺乏足够的显著地标支撑，难以构建有效的图结构表征。

针对上述纹理信息薄弱和关键目标占比不足导致的特征稀疏问题，本章提出一种基于特征补全与特征增强的图像配准地理定位方法（FCFE-Net）。该方法通过多尺度几何结构编码器（Multi-scale Geometric Structure Encoder, MGSE）、空间引导语义增强模块（Spatial-Guided Semantic Enhancement Module, SEM）与频域感知背景抑制模块（Frequency-Domain-Aware Background Suppression Module, FSM）的协同作用，解决特征稀疏带来的配准难题。具体而言，首先，针对可见光图像在弱纹理区域几何结构表征能力不足的问题，通过引入由 Omnidata 框架生成的法线图像作为几何先验，对 RGB 图像中缺失的几何结构特征进行特征补全，建立结构化特征基础；随后，针对关键地理目标占比不足导致的特征响应微弱的情况，SEM 模块利用空间结构信息作为引导，对特征图中的关键稀疏语义特征进行定向增强与激活；最后，考虑到增强过程中会同步放大环境中的背景噪声，FSM 模块利用频域解耦技术 WTConv 分离前景与背景特征，对非结构化背景特征进行自适应抑制，进而提升稀疏前景特征在全局描述符中的显著度，实现复杂环境下的精确配准。

4.2 总体结构

本文提出的基于特征补全与特征增强的图像配准地理定位网络（Feature Completion and Feature Enhancement Network, FCFE-Net）采用了参数共享的孪生神经网络（Siamese Network）架构。如图 4-1 所示，整个网络呈现端到端的双流并行结构。为有效应对特征稀疏问题，该网络输入端采用了可见光-法线的双流设计：在常规可见光图像的基础上，

并行引入 Omnidata 框架生成的法线图像作为几何先验。




图 4-1 FCFE-Net 网络框架结构图

在具体的特征处理流程中，各自视角的可见光图像及其对应的法线图像，分别输入至参数共享的骨干网络中提取多尺度特征。随后，提取出的多尺度可见光语义特征与法线几何特征被同步送入多尺度几何结构编码器 MGSE，以应对弱纹理区域的特征缺失问题。在 MGSE 内部，语义-几何特征交互模块（Semantic-Geometry Feature Interaction Module, SGIM）利用法线特征的几何不变性，对可见光特征进行特征补全；进而，多尺度特征聚合模块（Multi-scale Feature Aggregation Module, MSFA）对层级特征进行空间与通道的联合重构，输出聚合的结构化特征图 F_{struct} 。

获取结构化特征 F_{struct} 后，特征流转至空间引导语义增强模块 SEM。该模块通过两个子模块协同增强结构化特征 F_{struct} 。空间结构感知子模块（Spatial Structure Perception Module, SSPM）先提取多尺度的空间结构信息，构建尺度感知的空间结构先验；语义特征增强子模块（Semantic Feature Enhancement Module, SFEM）则以此先验为引导，沿通道维度动态校准特征，激活并增强稀疏目标的语义响应，输出增强特征 V_{SEM} 。

由于语义增强过程易同步放大环境背景噪声，增强后的特征 V_{SEM} 流入频域感知背景抑制模块（FSM）进行过滤。进入该模块后，特征首先经过上采样（UpSample）操作以恢复空间分辨率，再输入至小波变换卷积 WTConv 子模块，WTConv 利用离散小波变换将特征流正交化，在物理频域显式解耦前景结构与背景冗余；随后，自适应背景抑制注意力（Adaptive Background Suppression Attention, ABS）对频域解耦后的特征执行自适

应的掩膜过滤，抑制低频背景噪声，输出高纯净度的特征图 V_{final} 。在网络训练阶段，FCFE-Net 采用与第三章一致的端到端联合监督机制。网络将 InfoNCE 对比损失与 Cross-Entropy 交叉熵损失加权联合，通过统一的反向传播驱动参数更新。该策略确保模型在特征稀疏场景下，能够强化关键稀疏特征且有效抑制背景噪声。

4.3 多尺度几何结构编码器 MGSE

在无人机与卫星跨视角地理定位任务中，弱纹理和同质化区域普遍存在的特征稀疏问题，制约了仅依赖可见光图像的特征表征能力，进而影响了可靠跨视角匹配关系的建立。为解决该问题，本章提出多尺度几何结构编码器 MGSE。MGSE 利用法线图像中几何结构的不变性先验，对可见光图像中缺失的纹理特征进行特征补全，引导网络挖掘地物的视角不变性几何信息，从而构建对纹理稀疏具有鲁棒性的结构化表征。具体而言，MGSE 包含语义-几何特征交互模块 SGIM 与多尺度特征聚合模块 MSFA 两个核心组件。SGIM 负责利用法线图像特征对微弱的可见光纹理特征进行校准与补全，实现几何先验与语义特征的深度交互；而 MSFA 则用于整合经过交互的多层级特征，生成兼具局部细粒度几何细节与全局语义上下文的统一特征描述符。

如图 4-1 的 MGSE 的结构所示，MGSE 的整体架构采用了全尺度并行交互与统一聚合的策略。该模块充分利用 Backbone 四个阶段（Stage1 至 Stage4）输出的多尺度特征，涵盖了从底层高分辨率纹理细节到高层语义信息的完整特征谱。这四组不同尺度 RGB 语义特征与 Normal 几何特征被分别送入独立的 SGIM，在各自的分辨率层级上并行执行几何先验对语义特征的补全。MSFA 接收四个并行 SGIM 模块的输出特征后，对多层级信息进行统一聚合，生成结构化特征描述符 F_{struct} 。

4.3.1 语义-几何特征交互模块 SGIM

如图 4-2 所示，语义-几何特征交互模块 SGIM 分别接收来自骨干网络不同层级的多尺度可见光语义特征图 $F_{rgb} \in \mathbb{R}^{C \times H \times W}$ 和法线几何特征图 $F_{geo} \in \mathbb{R}^{C \times H \times W}$ 。该模块进行语义特征与几何结构特征之间的深层交互，其核心是利用法线特征中蕴含的几何结构不变性作为物理约束，对可见光图像中在弱纹理的特征稀疏区域缺失的语义特征进行补全。通过这种补全机制，模块消除可见光图像在弱纹理导致的特征稀疏环境下的表征局限，构建对弱纹理环境下具有鲁棒性的结构化表征。




图 4-2 语义-几何特征交互模块 SGIM 结构图

为了降低后续模块的计算负载并保留关键特征，对可见光和几何特征图分别应用带有可学习参数的自适应池化（Adaptive Pooling）。这一过程能够有效整合不同池化操作的优势，增强各特征图的表征能力。其计算过程描述如下：

$$F_{rgb}^p = \alpha_{rgb} \cdot AvgPool(F_{rgb}) + \beta_{rgb} \cdot MaxPool(F_{rgb}) \quad (4-1)$$

$$F_{geo}^p = \alpha_{geo} \cdot AvgPool(F_{geo}) + \beta_{geo} \cdot MaxPool(F_{geo}) \quad (4-2)$$

其中， F_{rgb} 代表语义特征图， F_{geo} 代表几何特征图，AvgPool 表示平均池化，MaxPool 表示最大池化。 α 和 β 是用于平衡两种不同池化类型贡献的可学习系数。

之后，将每个特征图展平为一组 Token，并添加可学习的位置嵌入。位置嵌入是一个维度为 $HW \times C$ 的可训练参数，以编码不同 Token 之间的空间位置信息。然后，获得一组带有位置嵌入的令牌 $X_{rgb}, X_{geo} \in \mathbb{R}^{HW \times C}$ ，分别作为语义优先注意力子模块（Semantic Priority Attention Module, SPAM）和几何优先注意力子模块（Geometric Priority Attention Module, GPAM）的输入，其模块结构如下图所示。




图 4-3 语义优先注意力模块与几何优先注意力模块结构图

SPAM 和 GPAM 的细节如下。首先，通过以下方程将语义和几何 Token 投影为查询、键和值，公式如下所示：

$$Q_{rgb} = X_{rgb} W_Q^{rgb}, K_{rgb} = X_{rgb} W_K^{rgb}, V_{rgb} = X_{rgb} W_V^{rgb} \quad (4-3)$$

$$Q_{geo} = X_{geo} W_Q^{geo}, K_{geo} = X_{geo} W_K^{geo}, V_{geo} = X_{geo} W_V^{geo} \quad (4-4)$$

其中， $W_Q, W_K, W_V \in \mathbb{R}^{C \times C}$ 分别表示查询、键和值的投影权重矩阵。接下来，通过点积操作计算相关性注意力矩阵，并对相关性分数进行归一化。再将注意力矩阵与相应的值相乘来获得精炼特征。该过程定义如下：

$$A_{rgb} = \text{Softmax} \left(\frac{Q_{geo} K_{rgb}^T}{\sqrt{d_k}} \right) \cdot V_{rgb} \quad (4-5)$$

$$A_{geo} = \text{Softmax} \left(\frac{Q_{rgb} K_{geo}^T}{\sqrt{d_k}} \right) \cdot V_{geo} \quad (4-6)$$

其中， d_k 代表键的维度。 A_{rgb} 和 A_{geo} 是通过从全局视角利用语义-几何相似特征而得到的精炼特征。具体而言， A_{rgb} 利用几何特征作为参考引导可见光语义特征的加权重构，从而在几何结构不变性的约束下重构可见光语义特征； A_{geo} 则反之，利用语义特征丰富几何表征。

之后，这些特征通过非线性变换重新投影回原始空间，并通过残差连接添加到输入序列中。然后，通过两个带有残差连接的并行 MLP 来聚合来自 SPAM 和 GPAM 的特征，从而获得交互特征 P_{rgb} 和 P_{geo} 。该过程公式化如下：

$$\hat{X}_{rgb} = \gamma_{rgb} \cdot X_{rgb} + \delta_{rgb} \cdot A_{rgb} W_O^{rgb} \quad (4-7)$$

$$\hat{X}_{geo} = \gamma_{geo} \cdot X_{geo} + \delta_{geo} \cdot A_{geo} W_O^{geo} \quad (4-8)$$

$$P_{rgb} = \lambda_{rgb} \cdot \hat{X}_{rgb} + \mu_{rgb} \cdot \text{MLP}(\hat{X}_{rgb}) \quad (4-9)$$

$$P_{geo} = \lambda_{geo} \cdot \hat{X}_{geo} + \mu_{geo} \cdot \text{MLP}(\hat{X}_{geo}) \quad (4-10)$$

其中， $W_O \in \mathbb{R}^{C \times C}$ 表示 MLP 层之前的输出权重矩阵。可学习系数 $\gamma, \delta, \lambda, \mu$ 应用于残差连接的每个分支，以自适应地从不同分支学习，从而实现更佳性能。随后，增强特征 P_{rgb} 和 P_{geo} 被上采样 *Upsample* 至原始特征图的大小，然后与原始特征相加，公式如下：

$$\hat{F}_{rgb} = F_{rgb} + \text{Upsample}(P_{rgb}) \quad (4-11)$$

$$\hat{F}_{geo} = F_{geo} + \text{Upsample}(P_{geo}) \quad (4-12)$$

为了构建兼具几何结构稳定性与视觉语义判别力的统一表征，本模块将交互增强后的特征 $\hat{F}_{rgb}$ 与 $\hat{F}_{geo}$ 在通道维度上进行拼接，并使用卷积网络对语义和几何特征进行聚合：

$$F_{SGIM} = \mathcal{F}_{conv}(\text{Concat}[\hat{F}_{rgb}, \hat{F}_{geo}]) \quad (4-13)$$

其中, F_{SGIM} 是 SGIM 的最终输出特征, $\mathcal{F}_{conv}$ 表示包含卷积操作的非线性映射函数。该策略通过融合法线图的几何先验, 生成了对同质化的弱纹理环境具有显著鲁棒性的结构化特征。

4.3.2 多尺度特征聚合模块 MSFA

经过语义-几何特征交互模块 SGIM 的处理, 网络在不同分辨率上获取了融合几何结构的层级特征。为了对不同尺度的交互后特征进行统一聚合, 本文设计了多尺度特征聚合模块 (MSFA), 其网络结构如图 4-4 所示。该模块采用双流并行分支, 包含多尺度空间聚合分支与通道聚合分支, 该模块接收来自骨干网络四个阶段的语义-几何交互后特征, 将其进行级联操作后的输入特征 F_{in} , 通过并行的多尺度空间特征重构与通道语义自适应调制, 对层级特征进行深度的联合优化。




图 4-4 MSFA 模块结构图

输入特征 F_{in} 经 1×1 卷积降维得到投影特征 F_{proj} 。然后, 该特征被送入三路并行的卷积组: 第一路采用 3×3 卷积保留细微纹理与边缘; 第二路串联 1×5 与 5×1 非对称卷积, 以低参数量捕捉正交方向的长距离依赖; 第三路利用可变形卷积 DCN^[78] 自适应调整感受野。三路特征经通道级联生成多尺度特征 F_{multi} , 公式如下所示:

$$F_{multi} = \text{Concat} \left(\text{Conv}_{3 \times 3}(F_{proj}), \text{Conv}_{5 \times 1} \left(\text{Conv}_{1 \times 5}(F_{proj}) \right), \text{DCN}(F_{proj}) \right) \quad (4-14)$$

其中, DCN 表示可变形卷积操作, Concat 表示通道维度的拼接操作。

为进一步滤除特征拼接过程中引入的空间冗余, 并强化通道结构, 该分支引入了基于广义平均池化 GeM^[79] 的特征自适应重制。GeM 压缩后的空间描述符经 7×7 大核卷积建模宽邻域相关性, 生成空间重校准权重并动态反作用于多尺度特征 F_{multi} , 最终经线性映射输出空间聚合特征 $F_{spatial}$, 公式如下所示:

$$F_{spatial} = \text{Conv}_{1 \times 1} \left(F_{multi} \otimes \sigma \left(\text{Conv}_{7 \times 7}(\text{GeM}(F_{multi})) \right) \right) \quad (4-15)$$

其中, σ 表示 Sigmoid 激活函数, $\otimes$ 代表元素级乘法。

与此同时, 考虑到级联特征 F_{in} 融合了浅层纹理与深层语义, 各通道对配准性能的贡献度存在显著的分布差异。通道聚合分支专注于在全局视野下建立通道间的长程依赖。该分支直接利用全局平均池化 (AvgPool) 提取全局上下文, 随后通过极简的双层瓶颈结构 (Bottleneck) 进行非线性压缩与激励, 直接生成表征通道重要性的语义调制权重 $W_{channel}$, 公式如下所示:

$$W_{channel} = Conv_{1 \times 1} \left(\delta \left(Conv_{1 \times 1} (AvgPool(F_{in})) \right) \right) \quad (4-16)$$

其中, δ 为 ReLU 激活函数。

最后, 模块通过元素级乘法实现多尺度空间特征与通道权重的协同调制, 并引入残差连接与原始输入 F_{in} 进行叠加, 公式如下所示:

$$F_{struct} = F_{spatial} \otimes W_{channel} + F_{in} \quad (4-17)$$

4.4 空间引导语义增强模块 SEM

尽管多尺度几何结构编码器 MGSE 通过引入几何先验, 有效实现了对弱纹理区域稀疏特征的补全。然而, 在跨视角地理定位任务中, 地标建筑、道路网络等关键地理实体因在图像视场中空间占比有限, 导致其在高维特征空间中依然面临特征响应强度薄弱、有效语义特征稀疏、判别性特征不足的挑战。为此, 在特征补全的基础上, 本文进一步提出空间引导语义增强模块 SEM, 对稀疏特征进行定向增强, 从而解决由关键地理目标占比不足引发的特征响应微弱的问题。

如图 4-5 所示, 该模块遵循空间引导语义的协同设计范式, 由空间结构感知子模块 (Spatial Structure Perception Module, SSPM) 与语义特征增强子模块 (Semantic Feature Enhancement Module, SFEM) 构成。具体而言, SEM 接收由 MGSE 输出的结构化特征图 F_{struct} 作为输入。首先, SSPM 利用多尺度深度卷积挖掘从细粒度纹理到全局几何轮廓的丰富结构信息, 构建尺度感知的空间结构先验; 随后, SFEM 则以该空间结构先验为引导, 沿通道维度对特征进行动态重校准, 在稀疏的特征分布中激活并增强关键地理实体的语义响应。两个子模块通过空间结构先验感知与稀疏语义特征精炼的深度协同, 完成了空间信息向通道语义空间的有效映射。其整体计算过程可形式化定义为:

$$V_{SEM} = SEM(F_{struct}) = SFEM(SSPM(F_{struct})) \quad (4-18)$$

通过上述协同处理, SEM 最终生成了具有高辨识度的稀疏特征增强描述符 V_{SEM} , 该描述符有效克服了关键地理实体特征信号微弱与判别性缺失的难题, 为后续建立高精度的跨视角特征匹配提供了鲁棒且统一的表征基底。




图 4-5 空间引导语义增强 SEM 模块结构图

4.4.1 空间结构感知子模块 SSPM

在视觉特征的几何分布维度，单一感受野难以兼顾狭长道路与建筑等多尺度实体，SSPM 模块致力于挖掘丰富的多尺度空间结构信息以构建尺度不变性先验。在降低计算复杂度的同时保留地理实体的几何拓扑，模块基于一维序列分解思想，将输入特征 $F_{struct} \in \mathbb{R}^{B \times C \times H \times W}$ 沿垂直与水平方向进行解耦。通过在各维度应用全局平均池化，生成两个单向的正交特征向量 $X_H \in \mathbb{R}^{B \times C \times H}$ 与 $X_W \in \mathbb{R}^{B \times C \times W}$ 。考虑到地理实体包含多种几何分布模式，如图 4-5 所示，模块将特征划分为 K 个大小相同的独立子特征组（本文设定 $K = 4$ ），每个子特征组包含 C/K 个通道。第 i 个子特征的划分过程表述为：

$$X_H^i = X_H \left[:, (i-1) \times \frac{C}{K} : i \times \frac{C}{K}, : \right] \quad (4-19)$$

$$X_W^i = X_W \left[:, (i-1) \times \frac{C}{K} : i \times \frac{C}{K}, : \right] \quad (4-20)$$

其中， X^i 表示第 i 个独立子特征， $i \in [1, K]$ 。

针对划分后的四个独立子特征组，为解决维度解耦导致感受野受限的问题，采用并行多尺度轻量级卷积 MS-DWConv1d 来实现维度间的特征对齐与隐式依赖建模。具体而言，分别并行应用核大小为 3,5,7,9 的一维深度卷积 $DWConv1d_{\frac{C}{K}}^{\frac{C}{K}}(.)$ 。这一设计旨在模拟不同尺度的地理实体在特征图上的跨度，其计算公式如下所示：

$$\widetilde{X}_H^i = DWConv1d_{\frac{C}{K}}^{\frac{C}{K}}(X_H^i) \quad (4-21)$$

$$\widetilde{X}_W^i = DWConv1d_{\frac{C}{K}}^{\frac{C}{K}}(X_W^i) \quad (4-22)$$

其中， $\widetilde{X}_H^i$ 与 $\widetilde{X}_W^i$ 分别表示第 i 个子特征在高、宽方向经多尺度卷积后的输出向量，卷积核

尺寸 $k_i \in \{3,5,7,9\}$ 。

在此基础上,为了有效整合不同感受野下捕获的空间上下文信息,实现局部细节与全局结构的统一,本模块沿通道维度将各子特征拼接,并通过 1×1 卷积进行跨尺度的特征交互与融合。在特征正则化阶段,考虑到关键地理实体的空间响应相对微弱且分布稀疏,常规的批归一化 (BN) 容易引入批次间统计量的波动,从而对这些稀疏特征产生干扰。因此,本文采用分组归一化 (GN) 进行处理,以更好地维持特征分布的稳定性。经过上述聚合与正则化处理后,模块提取出沿高度和宽度方向的空间权重,并将其协同作用于原始输入特征 F_{struct} 上,进而构建出融合了多尺度的空间先验特征 X_s 。该特征聚合与先验生成过程可统一描述为,公式如下所示:

$$Attn_H = \sigma \left(GN \left(Conv_{1 \times 1} \left(Concat[X_H^i]_{i=1}^K \right) \right) \right) \quad (4-23)$$

$$Attn_W = \sigma \left(GN \left(Conv_{1 \times 1} \left(Concat[X_W^i]_{i=1}^K \right) \right) \right) \quad (4-24)$$

$$X_s = SSPM(F_{struct}) = Attn_H \times Attn_W \times F_{struct} \quad (4-25)$$

其中, σ 代表 Sigmoid 激活函数; $Attn_H$ 与 $Attn_W$ 分别表示网络在高度和宽度方向上生成的空间注意力权重图。

4.4.2 语义特征增强子模块 SFEM

在通过 SSPM 获得空间结构先验后, SFEM 利用该先验引导特征通道维度的动态调制,旨在解决因关键地理实体几何占比有限而导致的特征信号微弱与有效语义稀疏的问题。对于地理实体稀疏性导致的平均池化信号平滑问题,模块引入混合池化策略。通过并行应用最大池化与平均池化,分别捕捉局部高频响应峰值与全局特征分布,并经元素级叠加实现优势互补,构建出兼顾局部显著性与全局强度的聚合表征 X_p , 公式如下所示:

$$X_p = AvgPool(X_s) + MaxPool(X_s) \quad (4-26)$$

随后,为了能够表征关键地理语义(如地标纹理、道路拓扑)的特征通道维度分布高度稀疏的特性,模块引入输入感知的单头自注意力机制来建模通道间的长距离依赖。该机制旨在从数百个冗余通道中,识别并锁定那些编码了核心几何信息的特定通道子集。通过 1×1 卷积投影 $DWConv2d_{(1,1)}^{\vec{c} \rightarrow \vec{c}}$ 生成查询 Q 、键 K 和值 V , 其计算公式如下:

$$Q = F_{proj}^Q(X_p), K = F_{proj}^K(X_p), V = F_{proj}^V(X_p) \quad (4-27)$$

$$X_{attn} = Attn(Q, K, V) = Softmax(QK^T)V \quad (4-28)$$

其中, $Q, K, V \in \mathbb{R}^{B \times C \times N'}$, 此处自注意力是沿通道维度计算的,通过通道间的相关性矩阵生成自注意力图 X_{attn} , 该图显式地反映了不同通道对于构建关键语义表征的贡献度权重。

SFEM 的核心在于先验引导的协同交互。具体而言,模块将前置 SSPM 获取的空间结构先验作为强有力的引导信号,动态指导特征权重的计算与分配。通过将自注意力机

制生成的通道特征图恢复至原始维度，并以逐元素相乘的方式直接作用于输入特征 X_s 。该过程准确聚焦并激活了那些编码关键地理实体（如地标纹理、道路拓扑）的稀疏语义通道，进而放大了核心语义特征在高维空间中的响应强度。通过上述深度交互，模块生成定向语义增强的特征图 V_{SEM} ，其计算过程如下所示：

$$V_{SEM} = SFEM(X_s) = X_s \times \sigma \left(Pool_{(H',W') \rightarrow (1,1)}(X_{attn}) \right) \quad (4-29)$$

其中， X_s 为输入的空间结构先验特征， X_{attn} 为自注意力机制生成的通道特征图， $Pool_{(H',W') \rightarrow (1,1)}$ 表示全局空间池化操作， σ 代表 Sigmoid 激活函数。

4.5 频域感知背景抑制模块 FSM

空间引导语义增强模块（SEM）在强化关键地理实体特征响应的同时，大面积非结构化背景中的复杂纹理信号也会被同步激活。由于目标实体在空间分布上具有稀疏性，而冗余背景占据主导视场，这种分布差异使得有限的前景结构线索易受低频背景冗余信号的干扰，导致特征空间内的信噪比失衡，削弱了稀疏特征的判别力。针对这种由特征稀疏与背景主导引发的表征失衡问题，本章提出了频域感知背景抑制模块，如图 4-1 的 FSM 模块结构所示，利用小波变换卷积（WTConv）利用多级小波分解将特征流正交化为不同的频率分量，在频域层面分离出表征地理实体的前景结构信息与环境背景的冗余分量。随后，自适应背景抑制注意力（ABS）在像素、通道、空间维度动态识别并降低背景区域的权重响应，从而在特征层面有效遏制大面积冗余背景噪声的干扰，以确保稀疏前景特征的显著度与判别力。

4.5.1 小波变换卷积 WTConv

WTConv 单元构建了频域和空域的联合转换机制，旨在物理频域层面显式解耦前景结构与背景冗余。WTConv 单元的具体网络结构与特征转换流程如图 4-6 所示，对于输入空间区特征张量 $X \in \mathbb{R}^{C \times H \times W}$ （其中 C, H, W 分别表示通道数、高度与宽度），WTConv 的核心处理流程依次包括离散小波变换分解、频域深度卷积及逆小波变换。该闭环过程的通用数学定义如下：

$$Y = IWT \left(\text{Conv}(W, WT(X)) \right) \quad (4-30)$$

其中， X 表示输入特征张量； W 代表 $k \times k$ 深度卷积（Depth-wise Convolution）核的权重张量，且其输入通道数为 X 的四倍。 $WT(\cdot)$ 与 $IWT(\cdot)$ 分别表示离散小波变换与逆小波变换， Y 为经过频域解耦与空域重构后输出的特征张量。




图 4-6 小波变换卷积神经网络的工作原理示意图

具体而言,为了实现深度的频率解耦与多尺度处理,模块采用了级联小波分解策略。设 $X_{LL}^{(0)}$ 为初始输入特征(即 X),第 i 级的分解输出包含四个正交的频率子带。其中,大面积的环境背景(如植被、水体)主要能量集中在低频近似分量 $X_{LL}^{(i)}$ 中,而对于视觉配准至关重要的几何结构细节(如道路边缘、建筑轮廓)则被编码于水平 $X_{LH}^{(i)}$ 、垂直 $X_{HL}^{(i)}$ 及对角 $X_{HH}^{(i)}$ 三个高频分量中。该递归分解过程定义为:

$$\begin{bmatrix} X_{LL}^{(i)} \\ X_{LH}^{(i)} \\ X_{HL}^{(i)} \\ X_{HH}^{(i)} \end{bmatrix} = WT \left(X_{LL}^{(i-1)} \right) \quad (4-31)$$

其中, $X_{LL}^{(i-1)}$ 表示上一级分解获取的低频近似分量。

随后,模块对各个独立频率子带应用 $k=3$ 的深度卷积。这一步骤利用 3×3 小卷积核在频域特征上的强特征提取能力,在保持参数量线性的同时实现了感受野的指数级扩大。例如,在2级分解下,频域的 3×3 卷积等效于原始图像上 12×12 的感受野,从而能够捕捉更广域的背景上下文以辅助背景抑制。处理后的频域子带 $Y_{sub}^{(i)}$ 计算如下:

$$Y_{sub}^{(i)} = \text{Conv} \left(W_{sub}^{(i)}, X_{sub}^{(i)} \right), sub \in \{LL, LH, HL, HH\} \quad (4-32)$$

其中, $W_{sub}^{(i)}$ 表示作用于对应频率子带的深度卷积核权重。

最后,模块通过递归的多级逆向聚合将跨尺度特征融合,并映射回统一的空域维度。该重构过程在特征空间中实现了前景结构与背景冗余的显式物理解耦,使得原本与稀疏前景高度混杂的背景噪声清晰分离。第 i 级逆向聚合与重构过程的数学表达可具体化为:

$$Z^{(i)} = IWT \left(Y_{LL}^{(i)} + Z^{(i+1)}, Y_{LH}^{(i)}, Y_{HL}^{(i)}, Y_{HH}^{(i)} \right) \quad (4-33)$$

其中, $IWT(\cdot)$ 表示逆离散小波变换; $Y_{LL}^{(i)}$ 以及 $Y_{LH}^{(i)}, Y_{HL}^{(i)}, Y_{HH}^{(i)}$ 分别表示第 i 级经过频域深度卷积处理后的低频近似分量与三个高频细节分量; $Z^{(i+1)}$ 代表来自更深一层(第 $i+1$ 级)

传递而来的重构特征。尤其，对于分解的最深层 l ，其初始重构条件设定为 $Z_{l+1} = 0$ 。

4.5.2 自适应背景抑制注意力 ABS

针对 WTConv 频域解耦后的非结构化背景噪声干扰，ABS 模块通过构建多维并行的协同抑制机制，在特征空间内对已分离的背景冗余特征分量执行动态权重削减，从而确保深层网络的表征空间聚焦于高判别力的稀疏前景特征。如图 4-7 所示，该模块针对解耦后的特征流，通过三路并行的注意力分支实施精细化抑制处理。




图 4-7 自适应背景抑制注意力 ABS 模块结构图

ABS 接收频域解耦后的输入特征 F_{wt} ，对其进行批归一化处理，得到特征 F_{bn} 以加速网络收敛并防止梯度弥散。特征 F_{bn} 被送入三个并行注意力不同维度捕捉并过滤背景干扰。

简单像素注意力分支 SPA 采用轻量级操作快速定位高响应的背景噪声区域。它由特征变换分支 PF_s 和空间注意力门 PA_s 组成。其中，特征变换分支明确采用 3×3 深度卷积来捕获局部上下文，二者通过元素级乘法生成初步的空间抑制特征 F_s 。其计算过程表示为：

$$PF_s = \text{Conv}_{3 \times 3}(\text{PWConv}(F_{bn})) \quad (4-34)$$

$$PA_s = \sigma(\text{PWConv}(F_{bn})) \quad (4-35)$$

$$F_s = PF_s \odot PA_s \quad (4-36)$$

其中，PWConv表示点卷积操作， σ 表示 Sigmoid 激活函数， $\odot$ 表示元素级乘法。

像素注意力分支 PA 引入更深层的非线性变换来生成精细的空间掩膜，以区分混入纹理中的细微背景噪声。该分支首先生成细粒度权重 A_p ，随后对输入特征进行动态加权，从而准确抑制背景环境噪声。细粒度权重 A_p 与精炼特征 F_p 的计算公式如下：

$$A_p = \sigma(\text{PWConv}(\text{GELU}(\text{PWConv}(F_{bn})))) \quad (4-37)$$

$$F_p = F_{bn} \odot A_p \quad (4-38)$$

其中, σ 代表 Sigmoid 激活函数, PWConv表示点卷积操作, GELU表示激活函数, F_{bn} 代表注意力的输入特征, $\odot$ 表示矩阵的元素级相乘。

通道注意力分支 CA 对特征通道级调制提供全局环境建模并利用全局平均池化 GAP 聚合空间信息, 自适应地识别并抑制那些对大面积环境冗余(如植被、水体)具有高激活响应的通道。计算公式如下:

$$CA_c = \sigma(\text{PWConv}(\text{GELU}(\text{PWConv}(\text{GAP}(\hat{x})))) \quad (4-39)$$

$$F_c = F_{bn} \odot CA_c \quad (4-40)$$

其中, $\text{GAP}(\cdot)$ 为全局平均池化; PWConv为点卷积; GELU与 σ 为激活函数; CA_c 为通道注意力权重; $\odot$ 为元素级乘法。

最后, ABS 将三个分支的输出特征进行级联, 并通过非线性变换与残差连接将净化后的特征注入原始特征流中, 从而输出背景抑制特征 V_{final} 。其定义如下:

$$V_{final} = F_{wt} + \text{PWConv}\left(\text{GELU}\left(\text{PWConv}\left(\text{Concat}(F_s, F_p, F_c)\right)\right)\right) \quad (4-41)$$

其中, $\text{Concat}(\cdot)$ 为通道级联操作; F_s, F_p, F_c 为三路并行分支的输出特征; F_{wt} 为模块输入特征。

4.6 损失函数

本章提出的网络模型在优化策略上与第三章保持一致, 同样采用以中间层度量、末端分类的联合监督机制进行端到端训练。因此, 本章的联合优化目标依然由 InfoNCE 损失与交叉熵损失加权构成, 具体公式推导详情可参见第 3.6 节, 此处不再赘述。

4.7 实验结果与分析

4.7.1 实验环境与参数设置

为确保实验结果的公平性、客观性与可复现性, 本章验证 FCFE-Net 性能的实验及消融研究均在与第三章相同的软硬件环境下进行。在数据集选择上, 本章实验评估依然选取了 University-1652 与 SUES-200 两个大型公开基准数据集, 旨在全面验证模型在纹理信息薄弱、关键目标占比不足以及背景干扰严重等特征稀疏场景下的配准精度与鲁棒性。

与第三章仅采用无人机 RGB 图像和卫星 RGB 图像作为输入不同, 本章 Backbone 虽然仍采用 ConvNeXt 结构, 但其输入形式扩展为 RGB—Normal 双模态特征提取方式。具体而言, 第三章 Backbone 主要提取无人机视图与卫星视图的可见光语义特征; 第四章 Backbone 则分别对 RGB 图像和由 Omnidata 生成的法线图像进行特征提取, 从而同时获得可见光语义特征与几何结构特征。后续 MGSE 模块在此基础上完成语义—几何特征交互, 用法线图像中的几何先验补全弱纹理区域中缺失的结构信息。因此, 两章

Backbone 的网络架构均为 ConvNeXt，但第四章在输入模态和特征输出用途上与第三章存在差异。

在数据预处理阶段，FCFE-Net 采用可见光图像与法线图像并行输入结构。除常规 RGB 图像外，本文利用预先部署的 Omnidata 框架为所有训练集和测试集样本生成对应的表面法线图像，并将其作为特征补全的几何先验。所有无人机视图、卫星视图的 RGB 图像及其对应法线图像均被统一调整至 384×384 像素分辨率，使语义特征与几何特征在空间尺寸上保持一致。双分支特征提取骨干网络继续选用在 ImageNet 上预训练且参数共享的 ConvNeXt 模型，用于提取多分辨率语义与几何表征。

在网络优化与超参数设定方面，本章沿用第三章的训练策略和参数选择原则，以保证两章实验结果之间的可比性。FCFE-Net 采用与 VCSA-Net 相同的优化器、学习率调度策略、训练轮数和批次大小设置；联合损失函数仍由 InfoNCE 对比损失与交叉熵损失加权构成，其中交叉熵损失权重 λ 采用第三章参数敏感性分析得到的配置。该设置能够在保持跨视角度量学习约束的同时，引入地点身份判别监督，增强特征稀疏场景下的全局判别能力。在推理与测试阶段，本章同样沿用双向跨视图检索模式进行配准定位性能验证。

4.7.2 消融实验

为了验证本文提出的 FCFE-Net 中各核心模块的有效性，本节在 University-1652 和 SUES-200 两个基准数据集上进行了全面的消融研究。为了清晰展示各模块的边际贡献与内在作用机理，实验在基线模型 Baseline 的基础上进行了逐层递进的结构验证：首先在 Baseline 中引入多尺度几何结构编码器 MGSE 构成 Model A；随后在 Model A 的基础上进一步集成空间引导语义增强模块 SEM 构成 Model B；最终联合 MGSE、SEM 以及频域感知背景抑制模块 FSM 三大模块，构建出本文提出的完整网络 FCFE-Net。后续的消融实验表格均基于此命名规则展开对比与分析。

(1) University-1652 数据集核心模块有效性分析

表 4-1 展示了在 University-1652 数据集上逐步引入 MGSE、SEM 和 FSM 后模型性能的变化。由实验结果可以看出，随着各核心模块的加入，模型在 Drone→Satellite 和 Satellite→Drone 两个任务中的 R@1 与 AP 均呈现稳定提升趋势。其中，Baseline 在 Drone→Satellite 任务中的 R@1 和 AP 分别为 90.35% 和 91.52%，完整 FCFE-Net 提升至 93.64% 和 94.85%；在 Satellite→Drone 任务中，Baseline 的 R@1 和 AP 分别为 92.65% 和 89.65%，完整模型提升至 95.92% 和 92.87%。该结果说明，本文所提出的三个模块能够从特征补全、特征增强和背景抑制三个层面缓解跨视图图像中的有效特征稀疏问题。

表 4-1 University-1652 数据集核心模块消融实验结果

模型配置	MGSE	SEM	FSM	Drone→Satellite		Satellite→Drone	
				R@1	AP	R@1	AP
Baseline				90.35	91.52	92.65	89.65
Model A	√			91.45	92.65	93.92	90.75
Model B	√	√		92.56	93.78	94.86	91.82
FCFE-Net	√	√	√	93.64	94.85	95.92	92.87

具体来看,在 Baseline 基础上引入 MGSE 后,Drone→Satellite 任务的 R@1 和 AP 分别提升至 91.45%和 92.65%,Satellite→Drone 任务的 R@1 和 AP 分别提升至 93.92%和 90.75%。这一现象说明,法线图像所包含的几何结构信息能够对可见光图像中的弱纹理区域形成有效补充。在城郊区域、屋顶平面、道路边界和大量同质地表等场景中,仅依赖 RGB 图像容易受到纹理不足和颜色相似性的限制,导致模型难以提取稳定的判别性线索。MGSE 通过语义-几何特征交互和多尺度特征聚合,将法线图像中的结构轮廓、表面朝向和空间边界信息引入特征表达,使模型在纹理信息不足的情况下仍能够获得更完整的结构化表征。因此,MGSE 带来的性能提升主要来源于对弱纹理区域几何信息的补全。

在 ModelA 的基础上进一步引入 SEM 后,Drone→Satellite 任务的 R@1 和 AP 分别提升至 92.56%和 93.78%,Satellite→Drone 任务的 R@1 和 AP 分别提升至 94.86%和 91.82%。该数据表明,仅补充几何结构信息还不足以完全解决特征稀疏问题。在无人机与卫星图像中,真正有助于定位的建筑边缘、道路交叉口、场地边界等关键地理实体往往占比较小,容易被大面积背景区域削弱。SEM 利用空间结构先验对语义特征进行引导,使网络更加关注具有稳定空间结构的关键区域,并增强这些区域的特征响应。因此,SEM 的作用重点不是增加所有区域的响应强度,而是在结构先验约束下突出对定位更有价值的稀疏语义特征。

在进一步引入 FSM 后,完整 FCFE-Net 在两个任务中均取得最优结果。相较于 ModelB,完整模型在 Drone→Satellite 任务中的 R@1 和 AP 分别由 92.56%和 93.78%提升至 93.64%和 94.85%,在 Satellite→Drone 任务中分别由 94.86%和 91.82%提升至 95.92%和 92.87%。由此可见,在完成几何补全和语义增强后,背景噪声仍然会影响跨视图特征匹配。对于大面积树林、草地、道路平面或建筑屋顶等区域,背景纹理可能在局部空间中产生较强响应,但这些响应并不一定具备稳定的地理判别性。FSM 通过频域感知的方式分离前景结构与背景冗余信息,并结合自适应背景抑制机制削弱非关键背景响应,从而提升有限关键地理特征的信噪比。因此,FSM 带来的性能提升主要来源于对增强过程中过度背景响应的抑制,使模型能够获得更纯净的跨视图匹配特征。

综上,University-1652 数据集上的消融实验表明,MGSE、SEM 和 FSM 的性能增益具有明确的递进关系。MGSE 首先利用法线几何先验补全弱纹理区域的结构信息,

SEM 在结构信息基础上增强关键稀疏语义特征，FSM 则进一步抑制背景噪声并提高前景特征信噪比。三者共同作用，使模型能够在特征稀疏场景下获得更稳定、更具判别性的图像表征。

(2) SUES-200 数据集核心模块有效性分析

SUES-200 数据集因其涵盖无人机在 150m 至 300m 的不同高度下城市和郊区的特征稀疏场景。该数据集下的特征稀疏场景主要表现为弱纹理和有效地理实体占比较小。为了全面评估 FCFE-Net 在特征稀疏场景下的尺度鲁棒性，本节分别在无人机自定位 (Drone→Satellite) 与无人机导航 (Satellite→Drone) 双向任务下对各核心模块 (MGSE、SEM、FSM) 进行了不同高度的消融实验分析，实验结果分别如表 4-2 和表 4-3 所示。

表 4-2 SUES-200 数据集核心模块消融实验结果(Drone→Satellite)

模型配置	MGSE	SEM	FSM	150m		200m		250m		300m	
				R@1	AP	R@1	AP	R@1	AP	R@1	AP
Baseline				89.83	90.48	91.73	92.58	93.37	94.43	94.62	94.87
Model A	√			90.82	91.57	92.83	93.68	94.46	95.53	95.68	95.93
Model B	√	√		91.97	92.64	93.87	94.76	95.48	96.53	96.72	96.94
FCFE-Net	√	√	√	92.96	93.61	94.86	95.71	96.47	97.52	97.71	97.95

表 4-3 SUES-200 数据集核心模块消融实验结果(Satellite→Drone)

模型配置	MGSE	SEM	FSM	150m		200m		250m		300m	
				R@1	AP	R@1	AP	R@1	AP	R@1	AP
Baseline				91.68	91.33	94.77	93.57	94.78	94.72	94.83	94.87
Model A	√			92.73	92.38	95.83	94.62	95.84	95.77	95.87	95.91
Model B	√	√		93.78	93.43	96.88	95.66	96.91	96.91	96.93	96.94
FCFE-Net	√	√	√	94.81	94.47	97.91	96.68	97.93	97.88	97.92	97.96

在 Drone→Satellite 自定位任务中，实验结果表明各模块在不同高度下均带来了稳定的性能提升，且其内部机制有效应对了跨尺度匹配的核心痛点。在 150m 的低空场景下，无人机视场受限，图像常被大面积同质化背景占据且特征稀疏，基准模型的 R@1 仅为 89.83%，其 AP 指标也处于相对低位。此时，MGSE 模块发挥了关键的特征补全作用，它通过几何先验修复弱纹理区域的特征缺失，使 R@1 提升至 90.82%，AP 也获得了相应的同步增长；随后，SEM 模块通过定向增强机制，利用空间结构先验激活了有限视场内关键地理实体(如道路交叉口、独立建筑)的语义响应，带动 R@1 进一步跃升至 91.97%，AP 亦稳步跟进；最后，FSM 模块执行了背景抑制功能，在频域内有效过滤了低空场景中容易造成干扰的大面积冗余噪声，保障了关键稀疏特征的主导地位，使完整模型 FCFE-Net 的 R@1 和 AP 最终分别达到了 92.96%和 93.61%。随着飞行高度攀升至 200m 和 250m，视场逐渐扩大，捕获的全局上下文信息更加丰富。在这两个中等高度区间，上述特征补全、定向增强与背景抑制的协同机制依然使模型的 R@1 和 AP 保持了约 2.5% 至 3%的稳定增益，证明了模型对跨尺度变化具有优异的适应能力。当高度达到 300m 时，

宏观地理实体已十分清晰，匹配难度相对降低，但完整模型的 $R@1$ 仍高达 97.71%，AP 亦逼近较高水平，相较基准模型在双项核心指标上实现了全面突破。

在 Satellite→Drone 导航任务中，FCFE-Net 同样展现出优异的泛化能力与鲁棒性。随着飞行高度从 150m 增加至 300m，完整模型的评估指标呈现出稳步上升的趋势，其中 $R@1$ 从 94.81% 增至 97.96%，AP 亦呈现出高度一致的增长曲线。在每个独立的高度区间内，各模块的逐一加入均实现了检索精度的稳步攀升。例如在 150m 高度下，MGSE 和 SEM 不仅各自带来了 $R@1$ 约 1.05% 的提升，同时也有效拉动了 AP 性能的增长；FSM 则进一步巩固了特征判别力，使完整模型的 $R@1$ 达到 94.81%，AP 达到 94.47%，整体表现显著优于基准模型。在中高空区间，即 200m 至 300m，尽管全局信息逐渐丰富，但卫星图与无人机图之间巨大的尺度差异与视角形变依然存在。此时，各模块仍然发挥作用，MGSE 补全纹理特征，SEM 强化关键特征，FSM 抑制背景干扰，使得模型在 $R@1$ 和 AP 两项关键指标上相较基准模型均实现了约 2% 至 3% 的稳定增益。

综上所述，客观实验数据与模块机制分析相互印证。MGSE、SEM 和 FSM 三个模块分别从局部特征修复、关键语义凸显和全局噪声抑制三个维度，系统性地解决了无人机视觉定位中因高度变化导致的特征稀疏与尺度差异问题，在 $R@1$ 和 AP 双重评估维度下显著提升了双向检索任务的整体表现。

(3) 法线图像有效性分析

1) 为严谨论证基于 Omnidata 预训练模型生成的法线图能够支撑无人机-卫星的跨视角定位任务，本文设计了一套包含真实几何重建与重新渲染的基准测试流水线对其有效性进行定量验证。本文采用运动恢复结构 (SfM)^[80] 与多视图立体视觉 (MVS)^[81] 技术，通过对无人机采集的高重叠率图像序列进行三维重建生成目标区域的高精度密集点云及三维三角网格模型。随后，提取三维重建解算出的精确相机内、外参，在三维渲染引擎中恢复每一帧无人机图像的真实物理视角，并使用法线材质通道对 3D Mesh 进行重投影渲染，生成与原始无人机图像绝对像素级对齐的真实表面法线 (n_{gt})。在获取真值后，将 Omnidata 模型生成的预测法线 n_{pred} 与真值 n_{gt} 映射回三维单位向量空间，采用逐像素角度误差 E_{angle} 作为核心评估指标。本文将无人机采集高度划分为 120m、150m、200m、250m 和 300m 五个典型区间，分别统计了平均角度误差、中位数角度误差，以及误差在 11.25°、22.5° 和 30° 容差阈值内的像素占比，定量评估结果如表 4-4 所示。

由表 4-4 可知，随着飞行高度从 120m 升至 300m，法线预测精度出现客观衰减：平均误差 (Mean) 从 22.4° 升至 32.1°，严格阈值 ($<11.25^\circ$) 占比从 35.2% 降至 23.8%。这主要归因于空间分辨率 (GSD) 降低导致的微观高频细节丢失。然而，深入剖析误差分布可发现两个关键现象：其一，各高度下的平均误差均显著高于中位数误差 (Median) (如 300m 时均值为 32.1°，中位数为 27.8°)。这种右偏态分布表明，少数高频细节的极大偏差拉高了均值，而多数像素误差仍保持在较低水平。其二，在宽容阈值 ($<30^\circ$)

下，300m 高度仍保留了 58.3%的有效像素。从跨视角定位的任务导向来看，算法无需毫米级的绝对三维重建精度，损失的高误差像素多为视图中同样被忽略的冗余细节（如树木起伏）。而剩余近 60%的像素已足以锚定场景的低频宏观几何骨架（如区分平坦屋顶与垂直立面），为网络提供稳定的结构线索。然而，当飞行高度攀升至 350m 时，算法触及了其有效感知边界，性能出现急剧退化。具体而言，平均误差剧增至 39.5°，且满足严格阈值（ $<11.25^\circ$ ）的像素占比锐减至 9.8%。这主要归因于图像空间分辨率的过度降低，使得模型难以继续维系场景的宏观三维几何拓扑，进而在生成的法线图像中引发了结构性扭曲与噪声干扰。

表 4-4 不同无人机飞行高度下单目法线估计的定量误差评估表

无人机高度	Angular Error $^\circ$		%Within t°		
	Mean	Median	11.25 $^\circ$	22.5 $^\circ$	30 $^\circ$
120m	22.4 $^\circ$	16.5 $^\circ$	35.2%	62.1%	75.4%
150m	24.1 $^\circ$	18.2 $^\circ$	31.8%	58.4%	71.6%
200m	26.8 $^\circ$	21.0 $^\circ$	29.5%	53.6%	66.8%
250m	29.5 $^\circ$	24.5 $^\circ$	26.3%	48.7%	61.5%
300m	32.1 $^\circ$	27.8 $^\circ$	23.8%	44.5%	58.3%
350m	39.5 $^\circ$	34.2 $^\circ$	9.8%	26.3%	42.1%




图 4-8 不同无人机飞行高度下可见光与法线图像可视化图

通过图 4-8 可以清晰地观察到，在较低飞行高度（120m、150m）下，生成的法线图像色彩分明，能够刻画出建筑物的垂直立面、平坦屋顶以及街道的几何边界；当飞行高度攀升至 250m 甚至 300m 时，受限于图像分辨率，虽然树木、窗户等微小高频细节逐渐变得平滑与模糊（对应了表 4-4 中严格阈值准确率的下降），但场景的宏观几何骨架，例如 300m 视角下环形广场的整体下凹结构、周边建筑群的主要朝向分布依然被网络完整且准确地保留了下来。这直观地展现了当前单目法线估计方法在不同高度（120 米到 300 米以内）无人机视角下稳定输出宏观三维结构表征的能力。

2) 为进一步探究法线图像对 FCFE-Net 跨视角配准精度的实质性贡献，本节在

University-1652 数据集上开展了输入特征的消融实验。实验分别独立评估了单一法线图像 (Normal)、单一可见光图像 (RGB) 以及本文提出的双模态融合图像 (RGB+Normal) 对最终定位性能的影响, 具体结果如表 4-5 所示。

表 4-5 Normal 法线图像有效性消融实验结果

Input	Drone→Satellite		Satellite→Drone	
	R@1	AP	R@1	AP
Normal	48.25	52.14	65.32	59.45
RGB	91.12	92.41	93.55	90.14
RGB+Normal	93.64	94.85	95.92	92.87




图 4-9 城郊弱纹理区域法线特征生成结果可视化图

如表 4-5 所示, 单一输入特征在跨视角配准中存在明显的局限性: 仅依赖法线图像 (Normal) 时整体精度相对较低, 表明纯几何图像输入缺乏必要的光度属性与全局语义; 而仅输入彩色图像 (RGB) 虽具备较高的基准配准能力 (Drone→Satellite 的 R@1 达 91.12%), 但网络受到纹理信息薄弱导致的特征稀疏问题影响。在面对缺乏丰富表观细节的匹配区域时, 纯 RGB 网络难以提取到足够且具有高判别力的特征点, 导致性能提升遭遇瓶颈。相比之下, 本文提出的 FCFE-Net 通过联合提取并融合这两种互补特征, 在所有指标上均达到最优, 其 Drone→Satellite 与 Satellite→Drone 任务的 R@1 和 AP 较 RGB 模型分别提升了 2.52% 和 2.37%。实验结果表明, 法线图像所编码的地表三维几何朝向信息为网络提供了强有力的空间结构约束, 该约束显著弥补了单纯依赖二维图像时因纹理薄弱造成的特征稀疏缺陷, 有效验证了本文可见光-法线特征融合策略在跨视角视觉配准任务中的有效性。

图 4-9 进一步展示了可见光与生成法线图像的定性对比。在城郊弱纹理区域, 纯可见光图像的特征提取较为稀疏; 而生成的法线图像能够准确恢复地表的三维结构趋势, 清晰勾勒建筑轮廓与地形起伏的几何边界。结果表明, 法线特征引入的连续空间结构约束, 有效弥补了可见光图像中纹理薄弱导致的特征缺失, 为跨视角配准提供了更为稳健的匹配依据。

(4) FSM 子模块有效性分析

为了验证频域感知背景抑制模块 (FSM) 内部各组件的有效性, 本节以集成多尺度

几何结构编码器 (MGSE) 和空间引导语义增强模块 (SEM) 的网络 (Model B) 为基准, 在 University-1652 数据集上进行消融实验。实验不仅测试了自适应背景抑制注意力 (ABS) 的作用, 还引入了与小波变换卷积 (WTConv) 通道数及核尺寸一致的常规卷积 (Standard Conv) 作为对照, 以排除参数量变化带来的干扰。定量结果如表 4-6 所示。

表 4-6 的数据表明, 在处理包含复杂背景的无人机视角图像时, 频域解耦机制在特征表达上优于常规空间域操作。在未引入背景抑制注意力机制的条件下, 采用常规卷积使无人机自定位任务的 R@1 和 AP 分别提升了 0.22% 和 0.21%; 而采用 WTConv 则使 R@1 和 AP 分别提升了 0.59% 和 0.67%。该对比结果证明, WTConv 的性能增益并非仅依赖于参数量的增加。常规空间域卷积在局部感受野内进行特征聚合, 易导致前景实体与背景噪声发生特征混叠, 并且不利于分离前景和背景特征; WTConv 则通过离散小波分解, 在频域内将表征大面积背景的低频分量与表征关键几何结构的高频分量进行分离, 从而为图像配准任务构建了边界更为清晰的解耦特征空间。

表 4-6 FSM 子模块消融实验结果

FSM 子模块组合	Drone→Satellite		Satellite→Drone	
	R@1	AP	R@1	AP
	92.56	93.64	94.86	91.82
Conv	92.78	93.85	95.02	92.05
WTConv	93.15	94.31	95.45	92.41
Conv + ABS	93.05	94.12	95.28	92.30
WTConv + ABS	93.64	94.85	95.92	92.87

同时, ABS 模块在特征空间优化中展现出稳定的增益效果, 且与频域特征分离机制存在显著的协同作用。无论前端采用何种卷积组件, 引入 ABS 后网络的配准精度 (R@1 与 AP) 均有所提升。对比常规卷积联合 ABS 的模型, 采用完整 FSM (即 WTConv + ABS) 的网络在无人机自定位任务上取得了 93.64% 的 R@1 与 94.85% 的 AP, 较前者分别提升了 0.67% 和 0.79%。该指标差异证实了 FSM 内部的特征处理逻辑: WTConv 在前端完成了前景与背景的频域解耦, 降低了空间混叠程度; 下游的 ABS 模块直接利用该解耦特征, 通过在空间与通道维度动态分配响应权重, 实现了对背景分量的针对性抑制。频域分离与空间抑制的结合, 有效提高了特征向量的信噪比, 优化了跨视角地理定位的综合匹配性能。

(5) 消融实验可视化分析

为了进一步探究本文所提模块在应对跨视图特征稀疏问题时的内在机理, 本节对 SEM 和 FSM 模块的特征响应分布进行了可视化对比分析。




图 4-10 SEM 模块消融实验可视化热力图




图 4-11 FSM 模块消融实验可视化热力图

针对 SEM 模块，主要验证其在空间先验引导下的特征增强效能。如图 4-10 所示，在跨视图地物特征稀疏的环境中，未引入该模块（w/o SEM）的网络往往面临特征激活不足的困境，难以有效提取高价值的地理信息；此外，其特征热力图易呈现分散状态，错误地聚集于树林等无规则的背景纹理上。引入 SEM 模块（w/ SEM）后，网络在空间先验信息的引导下，实现了对目标特征的有效增强。可视化结果清晰地显示，SEM 模块能够驱动网络将响应区域集中于建筑物等具有显著空间结构信息的地物上且关键地理特征激活响应更为明显，使得视图中占比较小的关键地理特征更为聚焦。

针对 FSM 模块，主要验证其抑制背景干扰、提升特征信噪比的作用。如图 4-11 所示，在包含大面积平坦地面或广阔树林等典型特征稀疏场景中，由于缺乏足够的结构信息，未引入该模块（w/o FSM）的网络极易受到冗余背景噪声的干扰。加入 FSM 模块（w/ FSM）后，网络针对平坦地面与树林等非结构化背景区域的特征响应进行了针对性的削弱与抑制。通过这种背景滤除机制，网络有效提升了有限的关键地理结构特征的信噪比。从可视化结果可以观察到，在排除了背景噪声的干扰后，原本视觉表现稀疏的关键特征在响应图中变得更加清晰明确，从而为后续的跨视图匹配阶段提供了更为纯净的特征。

4.7.3 对比实验

为评估 FCFE-Net 在稀疏场景中跨视角地理定位任务的综合性能与泛化能力，本方法在 University-1652 和 SUES-200 两个主流数据集上，将其与多项前沿算法进行了横向对比。对比算法涵盖了基于注意力机制的特征增强方法、基于图卷积的拓扑推理方法、基于因果推断方法、基于自适应区域消除、基于空间关系学习等方法。本节将从定量与定性两个维度展开评估：首先通过定量分析验证模型在不同数据集下的检索与定位精度；随后针对城市与郊区两类典型的特征稀疏场景进行定性的可视化分析，直观展示本方法的实际效果。

(1) University-1652 数据集跨视角定位性能对比

University-1652 数据集包含无人机视图、卫星视图和地面视图等多源图像，覆盖城市建筑、道路、广场和绿地区域等多类场景。其中，部分区域存在建筑屋顶纹理单一、道路区域外观相似、局部地理目标占比较小等问题，能够用于验证模型在有效视觉线索不足条件下的跨视角定位能力。本文在该数据集上分别进行 Drone→Satellite 和 Satellite→Drone 两个方向的对比实验，结果如表 4-7 所示。其中，最佳结果以红色突出显示、次佳结果以蓝色突出显示。

由表 4-7 可知，FCFE-Net 在 Drone→Satellite 任务中取得了 93.64% 的 R@1 和 94.85% 的 AP，在 Satellite→Drone 任务中取得了 95.92% 的 R@1 和 92.87% 的 AP。相较于 MBF、MCCG、SeGCN 等方法，本文方法在两个检索方向的 R@1 和 AP 指标上均获得明显提升，反映出其在弱纹理区域、背景干扰和关键地理目标占比不足等条件下具备较好的跨

视角匹配能力。与 SDPL 相比, FCFE-Net 在 Drone→Satellite 任务上的 R@1 和 AP 分别提升 3.48%和 3.21%,在 Satellite→Drone 任务上的 R@1 和 AP 分别提升 2.34%和 3.42%。在有效视觉线索相对不足的情况下,常规区域划分或多尺度表征对稳定判别特征的获取仍存在一定局限,而本文方法能够在复杂场景中形成更具区分度的整体图像表征。

表 4-7 本算法 FCFE-Net 与其他算法在 University-1652 数据集上的对比实验结果

Method	Year	Parameters/M	GFLOPs	Drone→Satellite		Satellite→Drone	
				R@1	AP	R@1	AP
MBF ^[82]	2022	-	-	89.05	90.61	93.15	88.17
MCCG ^[72]	2023	56.65	51.04	89.64	91.32	94.30	89.39
SeGCN ^[74]	2024	-	-	89.18	90.89	94.29	89.65
SDPL ^[73]	2024	42.56	69.71	90.16	91.64	93.58	89.45
MFJR ^[75]	2024	>88.00	-	91.87	93.15	95.29	91.51
CCR ^[76]	2024	156.57	160.61	92.54	93.78	95.15	91.80
SRLN ^[83]	2024	193.03	-	92.70	93.77	95.14	91.97
APA-BI ^[84]	2025	-	-	93.57	94.55	95.86	92.88
QDFL ^[77]	2025	108.87	123.19	95.00	95.83	97.15	94.57
Ours	-	58.7	69.1	93.64	94.85	95.92	92.87

与近年来的高性能方法相比, FCFE-Net 同样表现出较强的竞争力。相较于 MFJR, 本文方法在 Drone→Satellite 任务上的 R@1 和 AP 分别提升 1.77%和 1.70%, 在 Satellite→Drone 任务上的 R@1 和 AP 分别提升 0.63%和 1.36%; 相较于 CCR, 本文方法在 Drone→Satellite 任务上的 R@1 和 AP 分别提升 1.10%和 1.07%, 在 Satellite→Drone 任务上的 R@1 和 AP 分别提升 0.77%和 1.07%; 相较于 SRLN, 本文方法在 Drone→Satellite 任务上的 R@1 和 AP 分别提升 0.94%和 1.08%, 在 Satellite→Drone 任务上的 R@1 提升 0.78%。在无人机视图与卫星视图存在较大外观差异、局部结构相似和背景信息干扰的条件下, FCFE-Net 仍能够保持较稳定的检索性能, 体现出较好的跨视角特征表达能力。

同时也需要看到, QDFL 在 University-1652 数据集上取得了表中最高的检索精度, 其 Drone→Satellite 任务的 R@1 和 AP 分别达到 95.00%和 95.83%, Satellite→Drone 任务的 R@1 和 AP 分别达到 97.15%和 94.57%, 均高于本文 FCFE-Net。基于大规模预训练骨干和查询驱动特征学习的最新方法, 在细粒度判别特征挖掘和检索排序优化方面仍具有明显优势。与 QDFL 相比, FCFE-Net 在 Drone→Satellite 任务上的 R@1 和 AP 分别低 1.36%和 0.98%, 在 Satellite→Drone 任务上的 R@1 和 AP 分别低 1.23%和 1.70%。因此, 本文方法并不主张在 University-1652 公开榜单上取得绝对最高指标, 而是更强调在特征稀疏场景适应性、模型规模控制和工程部署可行性之间取得较为均衡的性能。

从模型复杂度角度进一步分析, FCFE-Net 的参数量为 58.7M, 低于 QDFL 的 108.87M、CCR 的 156.57M 和 SRLN 的 193.03M, 也低于 MFJR 所报告的超过 88M 参数量。虽然

FCFE-Net 的计算量高于部分轻量级方法，但相较于多种大规模高性能模型，其参数规模仍处于较可控范围内。与 2025 年的 APA-BI 方法相比，FCFE-Net 在 Drone→Satellite 任务上的 R@1 和 AP 分别提升 0.07% 和 0.30%，在 Satellite→Drone 任务上的 R@1 提升 0.06%，AP 仅低 0.01%，二者整体精度基本处于同一水平。由此可见，本文方法能够在较可控模型规模下取得接近最新方法的跨视角定位性能。

综合来看，FCFE-Net 在 University-1652 数据集上相较多数对比方法取得了更优或更具竞争力的结果。尽管其精度仍低于 QDFL 等最新高性能方法，但在较小参数规模和较稳定检索性能之间取得了较好的平衡，体现出本文方法在复杂特征稀疏场景下的适应性和有效性。

(2) SUES-200 数据集不同高度定位性能对比

SUES-200 数据集包含 150m、200m、250m 和 300m 四个飞行高度的无人机图像。随着飞行高度变化，无人机图像中的场景覆盖范围、地物尺度、背景占比和局部结构信息均会发生变化。低空图像中局部目标占比较大，但整体空间结构线索有限；高空图像中场景范围更完整，但部分关键地理目标在图像中的占比减小。因此，该数据集能够进一步检验模型在多高度特征稀疏场景下的定位能力。Drone→Satellite 和 Satellite→Drone 两个方向的实验结果分别如表 4-8 和表 4-9 所示。

表 4-8 本算法与其他算法在 SUES-200 数据集上 Drone→Satellite 的对比实验结果

Method	150m		200m		250m		300m	
	R@1	AP	R@1	AP	R@1	AP	R@1	AP
MBF	85.62	88.21	87.43	90.02	90.65	92.53	92.12	93.63
MCCG	82.22	85.47	89.30	91.41	93.82	95.04	95.07	96.20
SeGCN	90.80	92.32	91.93	93.41	92.53	93.90	93.33	94.61
MFJR	88.95	91.05	93.60	94.72	95.42	96.28	94.45	97.84
CCR	87.08	89.55	93.57	94.90	95.42	96.28	96.82	97.39
SRLN	89.90	91.90	94.32	95.65	95.92	96.79	96.37	97.21
APA-BI	86.45	88.90	91.85	93.54	95.70	96.62	96.70	97.37
FCFE-Net(Ours)	92.96	93.61	94.86	95.71	96.47	97.52	97.71	97.95

表 4-9 本算法与其他算法在 SUES-200 数据集上 Satellite→Drone 的对比实验结果

Method	150m		200m		250m		300m	
	R@1	AP	R@1	AP	R@1	AP	R@1	AP
MBF	88.75	84.74	91.25	89.95	93.65	90.65	96.25	91.60
MCCG	93.75	89.72	93.75	92.21	96.25	96.14	95.00	92.03
SeGCN	93.75	92.45	95.00	93.65	96.25	94.39	97.50	94.55
MFJR	95.00	89.31	96.25	94.69	97.50	96.92	98.75	97.14
CCR	92.50	88.54	97.50	95.22	97.50	97.10	97.50	97.49
SRLN	93.75	93.01	97.50	95.08	97.50	96.52	97.50	96.71
APA-BI	97.50	86.21	98.75	94.03	98.75	96.95	98.75	97.82
FCFE-Net(Ours)	94.81	94.47	97.91	96.68	97.93	97.88	97.92	97.96

由表 4-8 可知, 在 Drone→Satellite 任务中, FCFE-Net 在 150m、200m、250m 和 300m 高度下的 $R@1$ 分别为 92.96%、94.86%、96.47%和 97.71%, AP 分别为 93.61%、95.71%、97.52%和 97.95%。与 MBF、MCCG、SeGCN、MFJR、CCR、SRLN 以及 APA-BI 等方法相比, 本文方法在四个高度下均取得较优结果。尤其在 150m 和 200m 等低空与中低空场景中, 无人机图像视场范围有限, 局部地物信息不足, 弱纹理区域和背景干扰问题更加明显, 本文方法仍能保持较高的 $R@1$ 和 AP, 说明其能够在有效视觉线索不足的情况下获得更稳定的跨视角特征表示。与 APA-BI 相比, 本文方法在四个高度下的 $R@1$ 分别提升 6.51%、3.01%、0.77%和 1.01%, AP 分别提升 4.71%、2.17%、0.90%和 0.58%, 进一步说明本文方法在无人机图像检索卫星图像的特征稀疏场景中具有较好的适应能力。

由表 4-9 可知, 在 Satellite→Drone 任务中, FCFE-Net 在 150m、200m、250m 和 300m 高度下的 $R@1$ 分别为 94.81%、97.91%、97.93%和 97.92%, AP 分别为 94.47%、96.68%、97.88%和 97.96%。相较于 MBF、MCCG、SeGCN、MFJR、CCR 和 SRLN 等方法, 本文方法在不同高度下整体表现较为稳定。需要注意的是, APA-BI 在该任务中的 $R@1$ 指标较高, 在四个高度下分别达到 97.50%、98.75%、98.75%和 98.75%, 高于本文方法对应结果, 说明其在卫星图像检索无人机图像的首位匹配能力上具有较强竞争力。

然而, 从 AP 指标来看, FCFE-Net 在四个高度下均高于 APA-BI, 其中 150m、200m、250m 和 300m 高度下分别提升 8.26%、2.65%、0.93%和 0.14%。AP 能够综合反映正确匹配样本在检索列表中的整体排序质量, 该结果说明, 虽然 APA-BI 在部分高度下具有更高的首位检索准确率, 本文方法在候选结果整体排序稳定性方面仍具有优势。特别是在 150m 低空场景中, 本文方法对局部视场受限和背景干扰条件下的检索排序质量提升更为明显。

综合表 4-8 和表 4-9 可以看出, FCFE-Net 在 SUES-200 数据集上表现出较好的多高度适应能力。低空场景中, 本文方法能够缓解局部视野下有效地理线索不足的问题; 中高空场景中, 本文方法能够在场景范围扩大、目标尺度变化和背景比例变化的条件下保持较高性能。相比部分方法在某一高度或单一指标上表现突出, FCFE-Net 在两个检索方向和四个飞行高度下均保持较稳定的结果, 说明其对多高度特征稀疏场景具有较好的适应性。

(3) 场景一: 城市特征稀疏场景

如图 4-12 和图 4-13 所示, 本节选取典型的城市特征稀疏场景, 对本文方法与 SRLN、CCR、MFJR、MCCG 等主流方法的 Top-1 检索结果和特征热力图进行对比分析。该类场景主要包括表面纹理较为单一的大型建筑、平顶建筑以及被道路、植被或阴影包围的城市结构物。由于目标区域缺乏丰富的高频纹理细节, 且不同建筑或区域之间在颜色、形状和局部结构上存在一定相似性, 因此跨视角匹配过程中容易出现有效判别特征不足

的问题。



图 4-12 城市特征稀疏场景无人机自定位检索结果对比图




图 4-13 城市特征稀疏场景特征热力图可视化对比图

由图 4-12 可以看出，在城市特征稀疏场景中，对比方法容易受到同质化屋顶、相似道路结构或周边背景区域的干扰，从而检索到外观相近但地理位置错误的卫星图像。

MCCG、MFJR 等方法虽然能够通过特征增强或区域建模提升整体匹配能力，但当目标主体本身纹理较弱、边界不够清晰时，模型仍可能过度依赖颜色分布或局部外观相似性，导致误匹配。CCR 和 SRLN 等方法在一定程度上考虑了特征关系或排序优化，但在可判别地理线索不足的情况下，仍难以稳定区分结构相似的候选区域。相比之下，本文方法能够更准确地检索到对应卫星图像，说明其在弱纹理城市区域中能够获得更稳定的结构化特征表达。

图 4-13 的特征热力图进一步展示了不同方法在特征关注区域上的差异。对比方法的响应区域在部分样本中较为分散，容易扩散至背景道路、绿地或建筑周边无关区域，说明其对关键地理实体的关注不够集中。本文方法的高响应区域则更多聚焦于建筑主体、屋顶边缘和空间轮廓等具有稳定地理意义的区域，能够在纹理信息不足的条件下保留对目标结构的关注。这表明，在城市弱纹理场景中，仅依赖常规可见光外观特征容易受到表面同质化影响，而引入更稳定的空间结构表达有助于缓解特征稀疏带来的匹配不确定性。

同时，图 4-12 中的失败样例也表明，当城市区域中建筑纹理极弱、目标轮廓不明显，且候选卫星图像中存在高度相似的屋顶形态或空间布局时，模型仍可能出现误匹配。这说明本文方法能够增强弱纹理区域中的结构表达能力，但在可见光纹理和几何结构线索均不充分的极端情况下，跨视角检索仍会受到候选样本相似性的限制。

综合检索结果与热力图表现可以看出，本文方法在城市特征稀疏场景中能够更有效地利用建筑轮廓、屋顶边界和空间布局等稳定地理线索，降低同质化纹理和周边背景对匹配结果的干扰，从而提升弱纹理城市区域下的跨视角图像配准稳定性。

(4) 场景二：郊区特征稀疏场景

与城市特征稀疏场景不同，郊区场景中的特征稀疏问题更多来源于关键地理实体占比不足和大量背景冗余干扰。如图 4-14 和图 4-15 所示，郊区或自然环境中常包含大面积植被、水体、农田和裸地等同质化背景，而真正具备定位价值的建筑、道路、交叉口或孤立地物在图像中所占比例较小。这种前景目标稀疏、背景区域占优的分布特征，使得跨视角特征容易被大面积背景纹理主导，从而降低匹配结果的可靠性。

由图 4-14 可以看出，在郊区特征稀疏场景中，SRLN、CCR、MFJR 和 MCCG 等方法容易受到植被、水体或农田等背景区域的影响，检索到背景风格相似但地理位置不一致的卫星图像。这是因为自然背景通常具有较强的颜色一致性和纹理重复性，在全局特征聚合过程中容易占据主导响应，而孤立建筑、窄道路等关键前景地物由于面积较小，其特征贡献容易被削弱。相比之下，本文方法在该类场景中能够更稳定地检索到正确卫星图像，说明其能够在背景冗余较强的情况下突出有限的关键地理线索，降低大面积非结构化背景对跨视角匹配的干扰。



图 4-14 郊区特征稀疏场景自定位检索结果对比图




图 4-15 郊区特征稀疏场景热力图可视化对比图

图 4-15 的热力图进一步验证了上述现象。对比方法的高响应区域在郊区场景中往往呈现明显扩散趋势，部分响应集中于树林、草地、水面等缺乏明确定位意义的背景区域，导致前景地物在整体特征表达中的占比进一步降低。本文方法的响应区域则更加集中于孤立建筑、道路边缘和局部结构变化明显的区域，能够在大面积背景中保持对关键地理实体的关注。这说明在郊区特征稀疏场景下，有效抑制背景冗余并提高稀疏前景特征的信噪比，对于提升跨视角定位性能具有重要作用。

与此同时，图 4-14 中的失败样例也反映出郊区场景仍具有较高挑战性。当图像中前景地理实体过少，而大面积植被、农田或水域背景在候选卫星图像之间高度相似时，模

型可利用的判别性线索会显著减少，仍可能出现误匹配。这表明，对于极端背景同质化和关键目标严重稀疏的区域，仅依靠有限的局部结构信息仍难以完全消除候选区域之间的混淆。

4.8 本章小结

为了解决无人机与卫星视图在复杂环境中纹理信息薄弱和关键目标占比不足导致的特征稀疏与定位误差，本章提出一种基于特征补全与特征增强的图像配准地理定位方法。实验结果表明，所提出方法在弱纹理等特征稀疏场景下的图像配准过程中，展现出了卓越的配准鲁棒性与定位有效性。

本方法的主要贡献可概述如下：

(1) 提出多尺度几何结构编码器 MGSE，引入法线图像的几何先验信息，对可见光图像的弱纹理区域进行特征补全，引导网络挖掘地物的视角不变性几何信息，从而在特征层面丰富了几何结构信息，有效缓解了弱纹理区域信息缺失带来的特征稀疏问题。

(2) 设计空间引导语义增强模块 SEM，利用获取的空间结构先验动态调制特征通道。该模块能够激活并定向增强关键稀疏语义特征的响应，有效克服了因关键地理实体目标占比有限而导致的特征信号微弱与有效语义稀疏的难题。

(3) 构建频域感知背景抑制模块 FSM，通过小波变换卷积在频域层面解耦前景与背景特征。该模块能够自适应分离并抑制大面积非结构化的冗余背景噪声，从而提升了稀疏前景特征的信噪比与特征稀疏场景下配准和定位精度。

第5章 基于图像配准算法的地理定位系统设计与实现

5.1 引言

在本文的前述章节中，重点围绕跨视图图像配准与无人机高精度地理定位的理论算法展开了深入研究，先后提出了基于视图校正与尺度自适应的配准网络（VCSA-Net）以及基于特征补全与特征增强的图像配准网络（FCFE-Net），并通过在公开数据集上的大量对比实验，充分验证了上述算法在复杂环境下的有效性与高精度定位能力。

然而，在无人飞行器的实际工程应用中，理论算法的落地面临着严峻的现实挑战。目前大多数基于深度学习的视觉配准模型均依赖于如 PyTorch 等庞大的深度学习框架，且通常运行在具有极高算力、大内存与高功耗配置的桌面级或服务器级 GPU 上。对于真正在 GPS 拒止等复杂环境下执行任务的无人机而言，机载设备的物理尺寸、有效载荷重量以及电池供电能力受到了极大的限制。同时，无人机的高速动态飞行要求定位系统必须具备较低的计算延迟与高实时性。因此，仅仅停留在实验室高性能计算机上的理论模型，无法直接满足无人飞行器实际作业的系统化需求。

针对上述算法落地痛点，本章致力于实现理论算法向实际工程化部署的有效转化。本文以实际应用为导向，结合国产昇腾（Ascend^[85]）异构计算架构，设计并实现了一套基于 Atlas 200 DK A2 边缘计算平台的无人机视觉定位系统。系统支持两类模型离线部署，其中 VCSA-Net 适用于大视角差异场景，FCFE-Net 则适用于特征稀疏场景，测试阶段分别验证其端侧推理性能。该系统利用边缘端异构硬件底座，通过模型转换与软硬协同优化，实现基于图像配准的定位算法在受限机载端的高效推理与地理位置解算。本章将依次从系统的需求分析、总体架构与流程设计、核心模块的详细设计（包括数据预处理、模型离线转换部署、端侧推理以及后处理可视化）展开详细论述，并在最后对该系统的功能与性能进行全面的测试与评估。

5.2 系统需求分析

在将基于视觉配准的无人机定位算法从实验室环境走向实际工程应用的过程中，必须结合无人飞行器的作业特点和受限的机载计算资源，对系统进行全面的需求分析。本节将从系统的功能需求以及边缘硬件平台的部署约束两个方面展开深入分析。

5.2.1 功能需求分析

根据无人机在 GPS 拒止等复杂环境下执行高精度自定位的任务逻辑，系统需具备完整的数据流转与处理能力，具体功能需求如下：

(1) 实时数据采集与预处理功能：系统需要稳定接收来自无人机机载相机的实时视频流，并具备高效的视频解码与图像预处理能力（如缩放、裁剪、色域转换），确保输

入数据格式与深度学习模型的需求严格对齐。

(2) 离线特征库管理功能：系统需支持离线构建和加载卫星基准特征库，在端侧启动时能够快速将预先提取的卫星特征向量及地理坐标加载至内存。

(3) 模型端侧推理与坐标解算功能：系统需具备运行深度视觉特征提取模型的能力，调用端侧算力执行前向推理。随后，通过相似度比对，筛选出最佳匹配的卫星参考图像，并估计无人机当前对应的二维地理位置。

(4) 定位结果输出功能：将解算出的坐标实时回传给飞控系统辅助导航，并为地面操作人员提供可视化的匹配结果展示。

5.2.2 性能需求分析

与运行在高性能服务器上的算法不同，面向无人飞行器的机载视觉定位系统在体积、重量和功耗方面受到极其严格的限制。本系统既定的工程化部署目标平台为昇腾 Atlas 200 DK A2 边缘开发者套件，因此系统的非功能性需求与架构设计必须与该硬件的物理形态及底层软硬件架构深度契合。

(1) 物理部署与功耗约束需求

系统在无人机机载端部署时，必须适应载荷的物理尺寸与供电限制。如图 5-1 所示为目标部署平台 Atlas 200 DK A2 开发板示意图。



图 5-1 Atlas 200 DK A2 开发板示意图

由于无人机飞行时电池容量有限，系统软件的设计必须满足低功耗运行的需求。开发板接口丰富但算力资源固定，系统必须在有限的功耗预算（通常在几十瓦级别）下，通过软件层面的极致优化，保证持续运行过程中的散热稳定与硬件安全。

(2) 异构计算架构适配需求

为了满足无人机高速飞行时对秒级定位延迟的实时性要求，系统软件架构不能采用传统的纯 CPU 串行计算模式，必须根据开发板的底层异构架构进行针对性的需求分析与适配。Atlas 200 DK A2 的系统架构如图 5-2 所示。



图 5-2 Atlas200 DK A2 系统架构图

结合图 5-2 所示的系统架构，本视觉定位系统的开发需深度适配底层硬件，并满足以下三项核心的资源调度需求。首先是模型轻量化与 NPU 调用需求：复杂的视觉配准网络需先通过 ModelSlim 完成量化校准与精度保持验证，再经由 ATC 工具链转换为适配 Ascend 平台的 OM 离线模型，以满足 AI Core 对模型格式、算子类型和静态图执行方式的要求，进而将高耗时的张量计算从 CPU 卸载至 NPU 高效执行。其次是硬件加速（DVPP）协同需求：系统需调用数字视觉预处理模块完成图像的硬件级解码与缩放，以此释放 CPU 算力，使其专注于坐标解算与数据通信等后处理任务。最后是流水线并行需求：系统需构建软硬件协同的流水线并行处理机制，有效掩盖数据在 CPU 与 NPU 之间的拷贝与传输延迟，实现端到端的高吞吐量与低延迟，最终切实保障无人机定位信息的实时性与连贯性。

5.3 系统总体设计

5.3.1 设计原则

为了克服无人机端侧算力受限、实时性要求高以及飞行环境复杂等工程化挑战，确保深度学习视觉定位算法能够真正在昇腾 Atlas 200 DK A2 平台上落地应用，本系统的总体设计严格遵循以下四个核心原则：

(1) 实时性与高效性原则

为满足高速飞行的低延迟需求，需充分利用底层异构计算资源（如调用 DVPP 进行图像预处理，调度 NPU 执行模型推理），并结合流水线并行机制，实现高吞吐、低延迟的实时端到端定位。

(2) 模块化与低耦合原则

遵循软件工程高内聚、低耦合理念，将系统划分为数据预处理、模型推理、坐标解算等独立模块。这不仅便于开发调试，也为后续算法升级或对接不同飞控系统提供了灵活性。

(3) 轻量化与资源受限适配原则

针对无人机严格的功耗和载荷限制，深度适配底层硬件。利用 ModelSlim 和 ATC 工具链对原始模型量化和转换，并严格控制峰值内存，在低功耗下最大化算力利用率。

(4) 鲁棒性与高可用原则

面对实际飞行环境的干扰以及模型转化带来的精度折损，系统需在后处理阶段设计可靠的异常剔除机制。确保在特征质量下降或资源满载时，仍能输出高置信度的定位结果，保障飞行安全。

5.3.2 系统功能设计

如图 5-3 所示为本系统的功能结构图，结合基于视觉配准的无人飞行器定位任务的实际业务流转过程，本系统的核心功能主要分为数据预处理模块、定位算法推理模块以及定位后处理与可视化模块。

数据预处理模块主要负责接收无人机机载相机实时采集的高清视频流或图像序列，并对输入的媒体数据进行高效的视频解码、图像尺寸缩放、中心裁剪以及色彩空间转换等前置处理操作，从而为后续的深度学习算法提供符合网络输入标准的高质量图像数据。

模型转换部署模块主要负责实现定位算法的工程化落地，包含模型转换与机载部署两个关键环节。在模型转换阶段，利用特定工具链将实验室训练好的原始模型，跨平台编译为与无人机机载硬件架构相匹配的离线模型格式；在模型部署阶段，将生成的离线模型文件及其运行依赖嵌入至机载平台的软件系统中，确保算法能在实际飞行环境中被正确加载与调用。

定位算法推理模块为本系统核心的定位处理单元。该模块负责加载经过模型压缩与离线转换处理后的视觉配准网络（如本文提出的 VCSEA-Net、FCFE-Net），并在接收到预处理后的标准图像数据后，执行深度神经网络的高速前向传播计算，从而实时、准确地提取出无人机当前视角下的高维全局特征描述符。

定位后处理与可视化模块主要负责相似度度量与定位结果输出。该模块通过高效的检索算法，将生成的无人机实时特征与离线构建的卫星基准特征库进行比对，筛选出最佳匹配的卫星参考图像，并进一步解算出无人机当前地理坐标；此外，可视化子模块支持将无人机的实时飞行轨迹、匹配关联对等定位信息直观地叠加渲染在用户交互界面上，为地面操作人员提供便捷的任务监控与模型交互功能。




图 5-3 系统功能设计结构图

5.3.3 系统流程设计




图 5-4 系统流程设计结构图

如图 5-4 所示为本视觉定位系统的执行流程图。系统的整体业务流程主要由地面端与无人机端侧协同完成。系统启动后，无人机端侧首先在后台完成图像配准算法的部署与深度学习模型的加载初始化。随后，操作人员在地面端点击开始并向无人机发射定位指令。无人机端侧在接收到该指令后，随即触发单帧定位算法执行流程：首先通过机载摄像头实时采集当前视角的图像，并将其送入图像预处理模块进行格式转化与标准化清

洗；随后，预处理后的图像数据被输入至前置加载好的神经网络中进行端侧模型推理，提取判别性特征；紧接着，系统基于推理结果进行相似度度量，获取最佳匹配的检索卫星结果图，并据此解算出无人机的地理坐标。最后，无人机端侧将该坐标通过通信链路实时回传，地面端成功接收无人机实时地理位置，从而完成整个视觉定位闭环与任务监控。

5.4 系统详细设计

5.4.1 数据预处理模块

数据预处理模块主要负责打通无人机摄像头传感器与深度学习模型之间的数据流，将原始的高清视频码流转化为符合神经网络输入张量(Tensor)标准的归一化图像数据。为了最大化释放边缘设备算力，本模块在详细设计中深度调用了 Atlas 平台内置的 DVPP（数字视觉预处理）硬件加速模块。

在实际处理流程中，程序首先调用多媒体流接口读取无人机摄像头的实时画面，随后通过调用 DVPP 中的 VDEC（视频解码）组件对 H.264/H.265 格式的视频流进行硬件解码，输出 YUV 格式的图像。紧接着，调用 VPC（视觉预处理）组件完成图像的中心裁剪、指定分辨率缩放以及 YUV 到 RGB 色彩空间的转换，最终输出可以直接送入模型推理的标准化数据。该模块中所涉及的主要参数变量与功能函数如表 5-1 所示。

表 5-1 数据预处理模块的主要变量和函数

所属模块	函数/变量	功能说明
数据预处理 模块	Stream-url	存储与记录无人机实时视频流的拉流地址或端口号
	Target_width/target_height	设置深度学习模型要求的输入图像目标宽度与高度
	InitDvppEngine()	DVPP 硬件引擎初始化函数，负责申请预处理所需的 Device 内存
	DecodeVideoFrame()	视频帧解码函数，调用 VDEC 接口将压缩码流解码为原始图像帧
	ResizeAndFormatConvert()	图像缩放与格式转换函数，调用 VPC 接口完成尺寸裁剪与色域转换

5.4.2 模型转换部署模块

模型转换部署模块负责将训练阶段得到的 VCSA-Net 与 FCFE-Net 转换为边缘端可执行模型。本文采用 PyTorch—ONNX—OM 的模型迁移链路：首先将训练模型导出为 ONNX 中间表示，然后利用 ModelSlim 完成量化校准，最后通过 ATC 工具链生成适配 Atlas 200 DK A2 平台的 OM 离线模型。该模块主要包括模型量化和模型转换两个环节。

(1) 模型量化

模型量化用于降低模型权重和激活值的数据表示精度，使模型在保持定位精度的基础上减少存储占用和推理开销。采用 ModelSlim 对 ONNX 模型进行训练后量化。其核心过程是根据模型权重分布和校准样本的激活分布，确定浮点张量到低精度张量之间的

映射关系，并将相应的量化参数写入模型描述中。对于权重张量，由于其数值在推理阶段保持固定，ModelSlim 可直接根据权重取值范围和分布特征确定量化尺度；对于激活张量，其取值与输入图像内容相关，因此需要通过校准样本前向传播统计各层激活的动态范围。本文选取无人机图像与卫星图像成对样本作为校准数据，并采用与端侧推理一致的尺寸缩放、像素归一化、通道顺序转换和输入格式适配方式，使量化校准过程能够反映实际推理阶段的输入分布。量化过程仅改变权重和激活值的数值表示方式，不改变网络层数、通道数量和连接关系，因此量化前后模型参数量保持一致。量化完成后，本文从精度和效率两个方面进行回归验证，模型文件大小和推理时延用于评估端侧部署收益。模型量化阶段的主要变量和函数如表 5-2 所示。

表 5-2 ModelSlim 量化阶段主要变量和函数

所属模块	函数/变量	功能说明
模型转换部署 模块	calibration_dataset	用于统计激活分布的无人机图像与卫星图像校准样本
	quant_config	量化精度、校准批次大小、量化粒度和输出路径等配置
	PrepareCalibrationData()	完成校准样本预处理与输入格式适配
	RunModelSlimQuant()	统计权重与激活分布，生成量化参数和量化模型
	EvaluateQuantModel()	对比量化前后检索精度、模型大小和推理时延

(2) 模型转换

表 5-3 ATC 转换阶段主要变量和函数

所属模块	函数/变量	功能说明
模型转换部署 模块	input_shape	指定无人机图像与卫星图像两个输入张量的静态尺寸
	soc_version	指定目标昇腾芯片版本
	precision_mode	指定离线转换阶段的精度模式
	BuildATCCommand()	生成包含模型路径、输入尺寸和芯片版本的 ATC 转换命令
	ExecuteATCCommand()	调用 ATC 执行 OM 离线模型转换
	CheckOMModel()	检查 OM 文件生成状态和输入输出张量信息

模型转换用于将量化后的模型编译为 Ascend 平台可执行的 OM 离线模型。本文采用 ATC 工具链完成该过程。与 ModelSlim 侧重数值精度压缩不同，ATC 主要面向昇腾硬件进行计算图编译和算子适配，使模型能够脱离训练框架并在边缘端独立执行。转换过程中，ATC 首先解析输入模型的计算图、权重文件和输入输出节点信息，并根据目标芯片版本检查算子类型、张量维度和数据格式的适配性。随后，ATC 对计算图进行离线优化，包括冗余节点消除、相邻算子融合、数据排布转换、静态内存规划和硬件执行指令生成等操作。由于本文模型包含无人机图像和卫星图像两个输入分支，转换时需同时指定两个输入张量的静态尺寸，并保证输入节点名称与 ONNX 模型保持一致。转换完成后，检查 OM 文件生成状态，并核对输入输出节点、张量维度和输出特征长度是否满

足定位算法推理模块的调用要求。模型转换阶段的主要变量和函数如表 5-3 所示。

5.4.3 定位算法推理模块

定位算法推理模块是本视觉定位系统的核心计算引擎，主要负责将无人机实时捕获并预处理后的图像转化为具有强判别力的高维全局特征向量。为了满足系统对高精度与强鲁棒性的要求，本模块内部封装了本文在理论章节提出的两大核心网络：VCSA-Net 与 FCFE-Net。由于边缘端 CPU 算力羸弱，本模块通过软硬协同设计，深度调度 Atlas200 DK A2 平台内置的 AI Core 来执行这两个网络密集的张量计算。

表 5-4 定位算法推理模块的主要变量和函数

所属模块	函数/变量	功能说明
定位算法推理 模块	vcsa_model_id / fcfe_model_id	整型变量，系统加载 VCSA-Net 与 FCFE-Net 离线模型后返回的唯一身份标识，用于硬件上下文的调用管理
	input_dataset/output_dataset	数据结构体，分别用于描述模型输入张量与输出特征张量在显存中的首地址与空间大小
	LoadDualModels()	模型资源加载函数，负责读取.om 文件并初始化 NPU 运行所需的上下文（Context）与工作内存
	CopyDataHostToDevice()	数据下发函数，负责将归一化图像数据安全地从 CPU 内存拷贝至 NPU 显存中
	ExecuteInferenceVCSA()	封装底层的 aclmdlExecute 接口，调度 AI Core 执行 VCSA-Net 的前向推理，完成倾斜视图校正与尺度自适应处理
	ExecuteInferenceFCFE()	调度 AI Core 执行 FCFE-Net 的前向推理，提取图像的深层关联特征并输出高维全局描述符
	CopyDataDeviceToHost()	结果回传函数，负责将 NPU 最终输出的高维特征张量拷贝回主机端内存供解算使用

该模块中所涉及的主要参数变量与功能函数如表 5-4 所示。在该流程中，本模块直接调用模型转换部署模块生成的.om 格式离线模型文件。系统初始化时，主控程序通过 AscendCL 接口分别为 VCSA-Net 和 FCFE-Net 分配专属的 NPU 运行内存，并获取返回的模型描述符。接收到预处理模块输出的标准化图像后，系统采用灵活的动态路由机制：根据实际无人机作业场景的预设指令（如常规城市复杂视角场景调用 VCSA-Net，郊区弱纹理场景调用 FCFE-Net），选择性地触发对应模型的前向推理计算。在单帧计算数据流中，程序首先通过 aclrtMemcpy 接口将图像数据从主机端异步拷贝至设备端；随后，调用 aclmdlExecute 接口触发 NPU 硬件，执行选定网络的高速推理，从而完成特定场景下的特征提取。这种模块化与按需调用的设计，不仅赋予了系统极强的场景适应能力，还最大程度地避免了同时加载双模型带来的算力挤兑与显存溢出风险。最终特征提取处理完成后，系统再次通过内存拷贝将高维特征向量回传至 CPU 内存，供后处理检索使用，并清理当前帧的计算缓存。

5.4.4 定位后处理与可视化模块

定位后处理与可视化模块是本视觉定位系统的闭环数据处理与输出交互单元。在物理部署上，该模块的业务逻辑横跨无人机机载边缘平台与地面控制站前端，分别承担着端侧高维特征的物理坐标解算与地面端的人机交互展示任务。

在无人机机载端（定位后处理），当 NPU 完成特征提取的前向推理计算后，系统的控制流交回给边缘计算平台的 CPU。首先，程序从主机端内存中读取推理模块回传的无人机实时高维特征描述符，并调用特征度量算法（如余弦相似度），将其与系统初始化时预载的“卫星基准特征库”进行快速检索。通过 Top-K 排序筛选出最佳匹配的卫星参考图像后，系统提取该图绑定的中心点经纬度，并结合无人机的相对飞行高度、相机内外参及实时姿态角数据，通过坐标系映射矩阵解算出无人机当前时刻的二维地理坐标。随后，机载端将该坐标封装为 MAVLink 等标准通信协议帧，通过无线数据链路实时下发至地面控制站，并同步反馈给飞控系统辅助导航。




图 5-5 无人机飞行轨迹坐标展示图

在地面站前端（可视化展示），前端交互软件主要负责接收和解析机载平台实时回传的定位数据帧。如图 5-5 的无人机飞行轨迹坐标展示图所示，系统一旦获取到最新的地理坐标及其关联的匹配图像标识，便会立即触发界面的动态重绘与渲染机制。该机制能够将无人机的实时飞行轨迹、机载相机当前拍摄的视角画面，以及成功检索并配准的卫星参考底图，无缝叠加至基于 Cesium 或常规二维地图引擎构建的实时监控面板上。

这种空地协同的分布式设计，既避免了海量图像原始数据下传导致的带宽阻塞，又为地面操作人员提供了直观的任务监控与决策反馈。该跨端模块中所涉及的主要参数变量与功能函数如表 5-5 所示。

表 5-5 定位后处理与可视化模块主要变量和函数

所属模块	函数/变量	功能说明
定位算法推理模块	offline_feature_db	数据结构/字典变量，存储离线提取的卫星基准特征向量及其对应的真实经纬度标签
	similarity_score	浮点型变量，记录特征配准过程中的余弦相似度得分，用于判定匹配置信度
	drone_current_gps	结构体变量，存储最终解算出的无人机实时地理坐标（经度、纬度）
	CalculateSimilarity()	特征度量函数，计算实时特征向量与基准特征库之间的距离，并返回 Top-K 最佳匹配索引
	SolveGeographicCoordinates()	坐标解算函数，基于匹配图像的中心点绝对坐标与相机透视投影几何关系，计算无人机物理坐标
	SendLocationToFlightCtrl()	通信反馈函数，负责将定位坐标按照 MAVLink 协议打包，并通过串口/网络发送至底层飞控系统
	UpdateVisualizationUI()	界面渲染函数，将无人机实时轨迹、相机视图与匹配成功的卫星参考图叠加更新至前端展示面板

5.5 系统测试

在完成无人机视觉定位系统的总体设计、功能模块实现和边缘端部署后，本文进一步对系统进行测试与分析，以验证所设计系统在机载边缘计算环境下的运行稳定性、推理实时性和定位有效性。系统测试平台为 Atlas 200 DK A2 边缘计算设备，部署模型为经 ATC 工具链转换后的 OM 离线模型。测试过程围绕视觉定位系统的完整工作流程展开，包括图像输入与预处理、模型推理、特征检索、坐标解算和定位结果可视化等环节。

为明确系统测试的适用范围与合格判定依据，本文设置两类典型验证场景。第一类为城市复杂视角场景，主要模拟无人机倾斜视图与卫星正射视图之间存在几何错位、尺度变化和语义差异的情况，用于验证 VCSA-Net 在复杂跨视角条件下的定位能力。第二类为城郊弱纹理场景，主要模拟道路、绿地、屋顶等区域纹理信息较弱、关键地理目标占比较低的情况，用于验证 FCFE-Net 在特征稀疏条件下的定位鲁棒性。

系统测试指标主要包括模型部署指标、运行性能指标和定位精度指标。其中，模型部署指标包括模型存储规模、模型大小和部署后精度保持情况；运行性能指标包括平均推理耗时、处理帧率、端到端定位延迟和连续运行稳定性；定位精度指标采用 R@1 和 AP。本文以部署前 PyTorch 浮点模型的检索结果作为精度参考基准，并将端侧模型 R@1 和 AP 下降幅度不超过 5% 作为定位精度测试的合格标准。

5.5.1 模型复杂度与推理效率测试

为验证所提两种图像配准定位方法在边缘计算平台上的部署可行性，本文分别统计 VCSA-Net 和 FCFE-Net 在训练端 GPU 环境与 Atlas200 DK A2 边缘端部署环境下的模型

复杂度、推理效率和定位精度变化情况，结果如表 5-6 所示。

其中，模型存储规模和模型大小用于表征模型在不同部署形态下的存储开销；平均推理耗时和帧率用于衡量模型在不同硬件平台上的实际执行效率；R@1 和 AP 用于评估模型部署后的定位精度保持情况。训练端模型采用 FP32 浮点权重进行统计，边缘端模型经 ModelSlim 和 ATC 完成模型量化和转换后，在存储规模和模型文件大小方面均得到压缩。

表 5-6 所提算法部署前后模型复杂度与推理效率对比

实验模型	运行环境	输入分辨率	模型参数量 /M	模型大小 /MB	平均推理 延时/ms	帧率 /FPS	R@1/%	AP/%
VCSA-Net	RTX 4090	384×384	43.8	175.2	16.8	59.5	91.27	92.89
VCSA-Net	Atlas 200	384×384	43.8	62.4	46.5	21.5	89.86	91.53
FCFE-Net	RTX 4090	384×384	58.7	234.8	24.6	40.7	93.64	94.85
FCFE-Net	Atlas 200	384×384	58.7	83.6	68.9	14.5	92.18	93.41

由表 5-6 可知，两种模型部署至 Atlas 200 DK A2 后，参数量保持一致，但模型大小均明显降低。其中，VCSA-Net 的模型大小由 175.2MB 降低至 62.4MB，FCFE-Net 的模型大小由 234.8MB 降低至 83.6MB，说明端侧模型转换与混合精度量化能够有效降低模型存储开销，减轻机载边缘平台的模型加载与存储压力。

在推理效率方面，VCSA-Net 在 RTX4090 上的平均推理耗时为 16.8ms，帧率为 59.5FPS；部署至 Atlas 200 DK A2 后，平均推理耗时增加至 46.5ms，帧率为 21.5FPS。FCFE-Net 在 RTX4090 上的平均推理耗时为 24.6ms，帧率为 40.7FPS；部署至 Atlas 200 DK A2 后，平均推理耗时为 68.9ms，帧率为 14.5FPS。可以看出，受边缘端算力规模限制，两种模型在 Atlas 平台上的推理速度均低于训练端 GPU 环境，但仍能够维持较稳定的实时处理能力，满足无人机视觉定位系统对端侧推理效率的基本要求。

在定位精度方面，VCSA-Net 部署至 Atlas 200 DK A2 后，R@1 由 91.27% 降至 89.86%，AP 由 92.89% 降至 91.53%，分别下降 1.41% 和 1.36%。FCFE-Net 部署后，R@1 由 93.64% 降至 92.18%，AP 由 94.85% 降至 93.41%，分别下降 1.46% 和 1.44%。两种模型的精度下降幅度均控制在 5% 以内，说明 ModelSlim 模型量化和 ATC 模型转换虽然会对特征表达和相似度排序产生一定影响，但未明显破坏跨视图图像配准定位能力。

综合来看，VCSA-Net 和 FCFE-Net 在 Atlas 200 DK A2 平台上均能够实现稳定部署。端侧部署后模型文件大小明显降低，边缘端推理虽然相较训练端 GPU 存在一定速度下降，但仍保持可接受的处理帧率和较小的精度损失，表明所提两种图像配准定位方法具备较好的边缘端部署可行性。

5.5.2 系统场景验证与测试

在完成模型部署性能测试的基础上，本文进一步从系统整体运行角度对视觉定位系统进行验证。本节侧重系统在典型应用场景下能否完成端到端定位流程，以及各项测试

结果是否满足预设合格基准。为明确系统测试是否合格，本文从功能完整性、场景适应性、运行性能、系统稳定性和定位精度五个方面设置测试项目，并给出对应的评价指标与合格基准，测试结果如表 5-7 所示。

表 5-7 视觉定位系统测试场景、评价指标与合格基准

测试类别	验证场景	测试指标	合格基准	实测结果	测试结论
功能完整性测试	实时图像输入与端到端定位流程	图像采集、预处理、模型推理、特征检索、坐标解算和结果可视化	各模块连续响应，无模型加载失败、流程中断和显存溢出	全链路正常运行	合格
场景适应性测试	城市复杂视角场景	VCSA-Net 端侧推理与卫星图像匹配能力	能输出 Top-K 匹配结果和无人机定位坐标	正常输出匹配结果与坐标	合格
	城郊弱纹理场景	FCFE-Net 端侧推理与卫星图像匹配能力	能输出 Top-K 匹配结果和无人机定位坐标	正常输出匹配结果与坐标	合格
性能测试	Atlas 200DK A2 端到端定位流程	端到端定位延迟	$\leq 150\text{ms}$	约 118ms	合格
稳定性测试	连续运行测试	内存占用、功耗和芯片温度	无内存溢出、芯片过温和进程异常退出	连续运行稳定，无异常中断	合格
定位精度测试	端侧量化模型检索排序	R@1 精度衰减	相较 PyTorch 浮点模型下降 $\leq 5\%$	精度衰减低于阈值	合格
	端侧量化模型检索排序	AP 精度衰减	相较 PyTorch 浮点模型下降 $\leq 5\%$	精度衰减低于阈值	合格

由表 5-7 可知，系统在两类验证场景下均能够完成从图像输入、预处理、模型推理、特征检索到坐标解算和结果可视化的完整流程，说明系统具备端到端闭环运行能力。在功能完整性方面，系统能够持续接收无人机图像流，并稳定输出 Top-K 候选卫星图像及对应定位结果，未出现模型加载失败、数据流中断或显存溢出等异常情况。

在场景适应性方面，系统能够根据不同视觉定位场景调用对应的定位模型。对于城市复杂视角场景，VCSA-Net 能够完成无人机倾斜视图与卫星正射视图之间的特征匹配；对于城郊弱纹理场景，FCFE-Net 能够利用增强后的结构化特征完成图像配准定位。该结果说明，系统不仅能够完成单一模型推理，还能够在不同场景条件下支撑相应算法模块的部署运行。

在运行性能和稳定性方面，系统端到端定位延迟约为 118ms，低于 150ms 的合格基准；连续图像流处理帧率满足不低于 10FPS 的实时处理要求。连续运行测试过程中，系统未出现内存溢出、芯片过温、进程异常退出或严重帧阻塞等问题，说明该系统在

Atlas200 DK A2 边缘计算平台上具备较好的运行稳定性。

在定位精度方面，端侧模型的 R@1 和 AP 精度衰减均低于 5% 的预设阈值。结合表 5-5 的部署前后模型定位精度对比结果可知，模型转换和混合精度量化虽然会带来一定精度损失，但未破坏跨视角特征匹配能力，系统仍能够保持较可靠的图像配准定位效果。

综上所述，本文从模型复杂度、推理效率、系统功能、运行稳定性和定位精度等方面对无人机视觉定位系统进行了测试验证。结果表明，VCSA-Net 和 FCFE-Net 经边缘端部署后均能够在 Atlas 200DK A2 平台上稳定运行，并在保持较小精度损失的情况下满足实时处理需求。系统在城市复杂视角和城郊弱纹理两类典型场景下均能完成图像配准、特征检索和坐标解算流程，说明本文设计的视觉定位系统具备较好的工程可用性。

5.6 本章小结

本章主要面向无人飞行器在实际作业中对算力、功耗及实时性的严苛约束，将第三章和第四章提出的跨视图视觉配准与定位算法进行了工程化落地与系统级实现。

本章首先从实际应用出发，对视觉定位系统的功能需求与边缘硬件（Atlas 200 DK A2）的物理部署约束进行了深入分析，并在此基础上，确立了系统的总体架构与空地协同的业务流转设计。随后，重点突破了理论算法在边缘端部署的技术瓶颈，对系统的四大核心模块进行了详细设计：利用 DVPP 硬件加速引擎实现了图像的高效预处理；采用 ModelSlim 完成模型量化校准与精度回归验证，并使用 ATC 工具链生成适配 Ascend 平台的 OM 离线模型；通过 AscendCL 接口深度调度 NPU 异构算力，高效完成了 VCSA-Net 与 FCFE-Net 模型的前向推理计算；并设计了端侧解算与地面前端渲染分离的后处理可视化机制。最后，本章设计了严格的系统测试方案，对系统的功能完整性、运行性能以及端侧量化精度进行了全面评估。

测试与运行结果表明，本章所设计与实现的视觉定位系统，能够在受限的机载边缘算力下，稳定、高效、准确地完成无人机视觉定位任务。本章的工作有效实现了理论模型向实际工程应用的转化，为无人机在 GPS 拒止等复杂环境下的高精度自主导航提供系统级实证支撑。

第6章 总结与展望

6.1 全文总结

近年来,随着无人机技术的飞速发展,其在智能物流、灾害救援及自动驾驶等领域的应用日益广泛。然而,在GPS拒止或信号微弱等复杂环境下,实现无人机的高精度自定位成为限制其自主执行任务的关键瓶颈。基于视觉配准的无人机与卫星跨视图地理定位技术为解决这一问题提供了有效途径。但在实际应用中,该技术仍面临复杂环境跨视角特征不一致、特征稀疏以及机载算力受限等核心痛点。

为此,面向复杂多变的真实飞行环境,本文构建了多场景的基于图像配准的地理定位系统。在理论算法层面,针对城市大视角差异场景,着力克服空间、尺度与语义层面差异导致的特征不一致难题;针对城郊特征稀疏场景,则着力解决弱纹理和关键地理目标占比不足导致的底层特征稀疏难题。在工程部署层面,针对机载算力受限与实时性瓶颈,本文进一步设计了适配边缘平台的部署优化机制,降低了定位推理延迟。本文的主要研究工作与贡献总结如下:

(1) 提出了基于视图校正与尺度自适应的图像配准地理定位方法 VCSEA-Net。针对无人机倾斜视图与卫星正射视图因成像机理与观测模式差异导致的几何错位、尺度不一致和语义干扰等跨视图特征不一致难题,本文设计了语义引导视图校正模块 VRM,利用全局语义先验驱动空间仿射变换,将倾斜视角的无人机特征投影至正射空间以消除几何透视偏差;构建了尺度自适应特征校准模块 SAM,通过并行空洞卷积动态匹配语义粒度,并结合空间约束校正布局偏移,有效缓解了特征尺度差异;同时引入了跨视角语义对齐模块 CSM,利用卫星参考视图的静态上下文对无人机查询特征进行加权筛选,过滤非共视区域特征响应并强化静态共有语义。实验结果表明,该方法有效克服了跨视角表征差异,显著提升了图像配准与地理定位的精度。

(2) 提出了基于特征补全与特征增强的图像配准地理定位方法 FCFE-Net。针对郊区、野外等复杂环境下由于地表覆盖同质化、纹理信息薄弱以及关键地理目标占比不足导致的特征稀疏问题,本文设计了多尺度几何结构编码器 MGSE,引入由 Omnidata 框架生成的法线图像作为几何先验,对可见光图像的弱纹理区域进行特征补全,构建对纹理稀疏具有鲁棒性的结构化表征;提出了空间引导语义增强模块 SEM,利用获取的空间结构先验动态调制特征通道,激活并定向增强稀疏的关键地理实体响应;此外,构建了频域感知背景抑制模块 FSM,通过小波变换卷积在频域层面解耦前景结构与背景纹理,并自适应抑制环境中的大面积低频背景噪声。实验结果表明,该方法在弱纹理、目标稀疏等复杂场景下展现出了卓越的配准鲁棒性与定位有效性。

(3) 设计并实现了基于图像配准算法的地理定位系统。针对理论算法在真实无人

飞行器上部署面临的机载设备算力受限与实时性瓶颈问题,本文结合国产昇腾异构计算架构,设计并实现了一套基于 Atlas 200 DK A2 边缘计算平台的无人机视觉定位系统。系统利用 DVPP 硬件加速引擎实现了图像的高效预处理,通过 ATC 工具链完成了模型的混合精度量化与离线转换,并通过 AscendCL 接口深度调度 NPU 异构算力高效完成了 VCSA-Net 与 FCFE-Net 模型的前向推理计算。测试结果表明,该系统能够在受限的机载边缘算力下,稳定、高效、准确地完成无人机视觉定位任务,有效实现了理论模型向实际工程应用的转化。

6.2 未来展望

尽管本文在基于视觉配准的无人机定位算法设计及边缘系统部署方面取得了一定成果,但跨视图地理定位在实际开放环境中的应用仍充满挑战。为了进一步提升无人机高精度视觉导航技术的工程化水平与环境适应能力,未来的研究工作可以从以下几个方面展开深入探索:

(1) 多模态数据深度融合的全天候定位

本文方法主要依赖可见光图像,并辅助引入法线特征。在低照度、强光照变化或复杂气象条件下,可见光图像质量下降可能影响特征提取效果。后续可进一步融合红外、激光雷达等多模态信息,利用不同传感器之间的互补性提升全天候定位能力。

(2) 结合时空连续信息的视频流配准

本文定位框架主要基于单帧图像检索与匹配,而无人机实际飞行过程中获取的是连续视频流。后续可引入时序匹配、光流约束或时空 Transformer 等方法,将帧间运动信息和历史定位结果纳入模型推理过程,从而降低单帧误匹配带来的定位跳变,提升定位结果的连续性与稳定性。

(3) 面向微型无人机的极简模型与端侧自适应学习

虽然本文已在 Atlas 边缘平台上完成模型量化与部署,但面向微型无人机或无人机集群时,算力、功耗和载荷限制仍更为严格。未来可进一步探索知识蒸馏、网络剪枝、神经架构搜索等轻量化方法,并结合少量无标签飞行数据开展端侧自适应优化,以提升模型在未知环境中的泛化能力。

(4) 超大时间跨度下的复杂动态场景配准

实际工程中,卫星底图通常存在一定滞后性,当场景发生季节更替、地貌变化或建筑施工时,无人机实时视图与卫星底图之间会产生明显的物理与语义差异。后续可结合跨时相变化检测、跨季节风格迁移或视图合成方法,增强模型在长期动态环境下的配准鲁棒性。

参考文献

- [1] Dissanayaka D, Wanasinghe T R, De Silva O, et al. Review of Navigation Methods for UAV-Based Parcel Delivery[J]. IEEE Transactions on Automation Science and Engineering, 2024, 21(1): 1068–1082.
- [2] Sorbelli F B, Coro F, Pinotti C M, et al. How the Wind Can Be Leveraged for Saving Energy in a Truck-Drone Delivery System[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(4): 4038–4049.
- [3] Ladosz P, Mammadov M, Shin H, et al. Autonomous Landing on a Moving Platform Using Vision-Based Deep Reinforcement Learning[J]. IEEE Robotics and Automation Letters, 2024, 9(5): 4575–4582.
- [4] Khan M A, Ectors W, Bellemans T, et al. UAV-Based Traffic Analysis: A Universal Guiding Framework Based on Literature Survey[C]//Transportation Research Procedia. Elsevier B.V., 2017: 541-550.
- [5] Wang S, Jiang F, Zhang B, et al. Development of UAV-Based Target Tracking and Recognition Systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(8): 3409–3422.
- [6] Deng L, Mao Z, Li X, et al. UAV-based multispectral remote sensing for precision agriculture: A comparison between different cameras[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2018, 146: 124–136.
- [7] Huang D, Tang Y, Qin R. An evaluation of planetscope images for 3D reconstruction and change detection—experimental validations with case studies[J]. GIScience and Remote Sensing, 2022, 59(1): 744–761.
- [8] Xia M, Que S, Liu N, et al. Motion pattern recognition via CNN-LSTM-attention model using array-based Wi-Fi CSI sensors in GNSS-denied areas[J]. Electronics, 2025, 14(8): 1594.
- [9] Xu Z, Zhong X, Wang N, et al. VG-Fusion: a novel visual geo-localization fused with IMU and LiDAR-inertial odometry for UAVs in GNSS-denied environments[J]. Unmanned Systems, 2025: 1-17.
- [10] Wei K, Li X, Zhu W, et al. Multistage Learning-Based Fusion Framework for Autonomous Vehicle Localization in GNSS-Denied Environments[J]. IEEE Sensors Journal, 2025, 25(16): 31897–31909.
- [11] Bai D, Li X, Zhou L, et al. An integrated RF sensor design for anchor-free collaborative

- localization in GNSS-denied environments[J]. *Electronics*, 2025, 14(8): 1667.
- [12] Liu D, Chen X, Cui B. An improved cubature Kalman filter for GNSS-denied and system-noise-varying INS/GNSS navigation[J]. *Micromachines*, 2025, 16(10): 1116.
- [13] 张鸿翔, 董烁, 汪进文. 卫星拒止时深度学习辅助自主导航技术综述[J]. *导航与控制*, 2025, 24(6): 13-38, 123.
- [14] 刘小汇, 王怡晨, 文超, 等. 复杂城市环境下的 GNSS/SINS 组合导航算法[J]. *电子与信息学报*, 2024, 46(3): 899-909.
- [15] 王瑞, 王茂森, 戴劲松, 等. 基于改进视觉惯性里程计的无人机系统设计[J]. *兵器装备工程学报*, 2023, 44(4): 275-281.
- [16] 万开方, 吴志林, 武韞晖, 等. 拒止环境下基于深度强化学习的多无人机协同定位[J]. *航空学报*, 2025, 46(8): 277-297.
- [17] 叶熠彬, 陈硕, 滕锡超, 等. 低空无人飞行器绝对视觉定位技术综述[J]. *国防科技大学学报*, 2026, 48(2): 29-47.
- [18] 孙淑光, 徐延枝, 王浩琳. 卫星拒止环境下无人机 INS/GNSS 紧组合定位算法研究[J]. *物联网技术*, 2025, 15(1): 44-48.
- [19] Sun B, Liu G, Yuan Y. F3-Net: Multiview Scene Matching for Drone-Based Geo-Localization[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2023, 61(1): 1–11.
- [20] Ding L, Zhou J, Meng L, et al. A practical cross-view image matching method between UAV and satellite for UAV-based geo-localization[J]. *Remote Sensing*, 2021, 13(1): 47.
- [21] Wang T, Zheng Z, Sun Y, et al. Multiple-environment Self-adaptive Network for aerial-view geo-localization[J]. *Pattern Recognition*, 2024, 152: 1–15.
- [22] Zhao H, Ren K, Yue T, et al. TransFG: A Cross-View Geo-Localization of Satellite and UAVs Imagery Pipeline Using Transformer-Based Feature Aggregation and Gradient Guidance[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 1–12.
- [23] Dai M, Hu J, Zhuang J, et al. A Transformer-Based Feature Segmentation and Region Alignment Method for UAV-View Geo-Localization[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2022, 32(7): 4376–4389.
- [24] Zhuang J, Dai M, Chen X, et al. A faster and more effective cross-view matching method of UAV and satellite images for UAV geolocalization[J]. *Remote Sensing*, 2021, 13(19): 3979.
- [25] Li H, Chen Q, Yang Z, et al. Drone satellite matching based on multi-scale local pattern network[C]//*Proceedings of the 2023 Workshop on UAVs in Multimedia: Capturing the World from a New Perspective*. ACM, 2023: 51-55.

- [26] 盛怡宁, 赵理君, 张正, 等. 跨视角图像地理定位方法综述[J]. 中国图象图形学报, 2024, 29(9): 2716-2736.
- [27] Bansal M, Daniilidis K, Sawhney H. Ultra-wide baseline facade matching for geo-localization[C]//Computer Vision - ECCV 2012 Workshops and Demonstrations. Berlin, Heidelberg: Springer, 2012: 175-186.
- [28] Senlet T, Elgammal A. A framework for global vehicle localization using stereo images and satellite and road maps[C]//2011 IEEE International Conference on Computer Vision Workshops. IEEE, 2011: 2034-2041.
- [29] Lin J, Zheng Z, Zhong Z, et al. Joint Representation Learning and Keypoint Detection for Cross-View Geo-Localization[J]. IEEE Transactions on Image Processing, 2022, 31: 3780–3792.
- [30] Castaldo F, Zamir A, Angst R, et al. Semantic cross-view matching[C]//2015 IEEE International Conference on Computer Vision Workshop. IEEE, 2015: 1044-1052.
- [31] Tuytelaars T, Mikolajczyk K. Local Invariant Feature Detectors: A Survey[J]. Foundations & Trends in Computer Graphics & Vision, 2007, 3(3): 177–280.
- [32] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [33] Bay H, Tuytelaars T, Van Gool L. SURF: speeded up robust features[C]//Computer Vision - ECCV 2006. Berlin, Heidelberg: Springer, 2006: 404-417.
- [34] Rublee E, Rabaud V, Konolige K, et al. ORB: an efficient alternative to SIFT or SURF[C]//2011 IEEE International Conference on Computer Vision. IEEE, 2011: 2564-2571.
- [35] Philbin J, Chum O, Isard M, et al. Object retrieval with large vocabularies and fast spatial matching[C]//2007 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2007: 1-8.
- [36] Mironica I, Duta I, Ionescu B, et al. Beyond bag-of-words: fast video classification with Fisher kernel vector of locally aggregated descriptors[C]//2015 IEEE International Conference on Multimedia and Expo. IEEE, 2015: 1-6.
- [37] Perronnin F, Liu Y, Sanchez J, et al. Large-scale image retrieval with compressed Fisher vectors[C]//2010 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2010: 3384-3391.
- [38] Zamir A R, Shah M. Image geo-localization based on multiple nearest neighbor feature matching using generalized graphs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 36(8): 1546-1558.

-
- [39] Shechtman E, Irani M. Matching local self-similarities across images and videos[C]//2007 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2007: 1-8.
- [40] Lin T Y, Cui Y, Belongie S, et al. Learning deep representations for ground-to-aerial geolocalization[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 5007-5015.
- [41] Shan Q, Wu C, Curless B, et al. Accurate geo-registration by ground-to-aerial image matching[C]//2014 2nd International Conference on 3D Vision. IEEE, 2014: 525-532.
- [42] Han X, Leung T, Jia Y, et al. MatchNet: unifying feature and metric learning for patch-based matching[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 3279-3286.
- [43] Hu S, Feng M, Nguyen R M H, et al. CVM-Net: cross-view matching network for image-based ground-to-aerial geo-localization[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018: 7258-7267.
- [44] Sun B, Chen C, Zhu Y, et al. GeoCapsNet: ground to aerial view image geo-localization using capsule network[C]//2019 IEEE International Conference on Multimedia and Expo. IEEE, 2019: 742-747.
- [45] Wang T, Zheng Z, Yan C, et al. Each Part Matters: Local Patterns Facilitate Cross-View Geo-Localization[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(2): 867-879.
- [46] Deuser F, Habel K, Oswald N. Sample4Geo: hard negative sampling for cross-view geo-localisation[C]//2023 IEEE/CVF International Conference on Computer Vision. IEEE, 2023: 16801-16810.
- [47] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 8748-8763.
- [48] Cai S, Guo Y, Khan S, et al. Ground-to-aerial image geo-localization with a hard exemplar reweighting triplet loss[C]//2019 IEEE/CVF International Conference on Computer Vision. IEEE, 2019: 8390-8399.
- [49] Yang H, Lu X, Zhu Y. Cross-view geo-localization with layer-to-layer transformer[C]//Advances in Neural Information Processing Systems. 2021, 34: 29009-29020.
- [50] Zhu S, Shah M, Chen C. TransGeo: transformer is all you need for cross-view image geo-localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2022: 1162-1171.

-
- [51] Zhang X, Li X, Sultani W, et al. Cross-view geo-localization via learning disentangled geometric layout correspondence[C]//Proceedings of the AAAI Conference on Artificial Intelligence. AAAI Press, 2023, 37(3): 3480-3488.
- [52] Pearl J. Causality: models, reasoning and inference[M]. 2nd ed. Cambridge: Cambridge University Press, 2009.
- [53] Shi Y, Liu L, Yu X, et al. Spatial-aware feature aggregation for cross-view image based geo-localization[C]//Advances in Neural Information Processing Systems. 2019, 32: 10090-10100.
- [54] Deng X, Zhu Y, Newsam S. What is it like down there? Generating dense ground-level views and image features from overhead imagery using conditional generative adversarial networks[C]//Proceedings of the 26th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. ACM, 2018: 43-52.
- [55] Toker A, Zhou Q, Maximov M, et al. Coming down to earth: satellite-to-street view synthesis for geo-localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2021: 6484-6493.
- [56] Tian X, Shao J, Ouyang D, et al. UAV-satellite view synthesis for cross-view geo-localization[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(7): 4804-4815.
- [57] Liu Z, Mao H, Wu C Y, et al. A ConvNet for the 2020s[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2022: 11976-11986.
- [58] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2323.
- [59] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [60] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 2015: 1-9.
- [61] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.
- [62] Katharopoulos A, Vyas A, Pappas N, et al. Transformers are RNNs: fast autoregressive transformers with linear attention[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020, 119: 5156-5165.

- [63] Jaderberg M, Simonyan K, Zisserman A, et al. Spatial transformer networks[C]//Advances in Neural Information Processing Systems. 2015, 28: 2017-2025.
- [64] Eftekhar A, Sax A, Malik J, et al. Omnidata: a scalable pipeline for making multi-task mid-level vision datasets from 3D scans[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. IEEE, 2021: 10786-10796.
- [65] Ranftl R, Bochkovskiy A, Koltun V. Vision transformers for dense prediction[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. IEEE, 2021: 12179-12188.
- [66] Yao Y, Luo Z, Li S, et al. BlendedMVS: a large-scale dataset for generalized multi-view stereo networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2020: 1787-1796.
- [67] Mallat S G. A Theory for Multiresolution Signal Decomposition: The Wavelet Representation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1989, 11(7): 674–693.
- [68] Zhu R, Yin L, Yang M, et al. SUES-200: A Multi-Height Multi-Scene Cross-View Image Benchmark Across Drone and Satellite[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33: 4825–4839.
- [69] Oord A van den, Li Y, Vinyals O. Representation learning with contrastive predictive coding[EB/OL]. arXiv:1807.03748, 2018.
- [70] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 2881-2890.
- [71] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2018: 7132-7141.
- [72] Shen T, Wei Y, Kang L, et al. MCCG: A ConvNeXt-Based Multiple-Classifer Method for Cross-View Geo-Localization[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(3): 1456–1468.
- [73] Chen Q, Wang T, Yang Z, et al. SDPL: Shifting-Dense Partition Learning for UAV-View Geo-Localization[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(11): 11810–11824.
- [74] Liu X, Wang Z, Wu Y, et al. SeGCN: a semantic-aware graph convolutional network for UAV geo-localization[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 6055-6066.
- [75] Ge F, Zhang Y, Wang L, et al. Multilevel Feedback Joint Representation Learning Network Based on Adaptive Area Elimination for Cross-View Geo-Localization[J]. IEEE

- Transactions on Geoscience and Remote Sensing, 2024, 62.
- [76] Du H, He J, Zhao Y. CCR: A Counterfactual Causal Reasoning-Based Method for Cross-View Geo-Localization[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(11): 11630–11643.
- [77] Hu S, Shi Z, Jin T, et al. Query-Driven Feature Learning for Cross-View Geo-Localization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63.
- [78] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]//Proceedings of the IEEE International Conference on Computer Vision. IEEE, 2017: 764-773.
- [79] Radenovic F, Tolias G, Chum O. Fine-Tuning CNN Image Retrieval with No Human Annotation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(7): 1655–1668.
- [80] Schonberger J L, Frahm J M. Structure-from-Motion Revisited[C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 2016: 4104–4113.
- [81] Bleyer M, Rhemann C, Rother C. PatchMatch stereo: stereo matching with slanted support windows[C]//Proceedings of the British Machine Vision Conference. BMVA Press, 2011: 1-11.
- [82] Zhu R, Yang M, Yin L, et al. UAV's Status Is Worth Considering: A Fusion Representations Matching Method for Geo-Localization[J]. Sensors, 2023, 23(2): 720.
- [83] Lv H, Zhu H, Zhu R, et al. Direction-Guided Multiscale Feature Fusion Network for Geo-Localization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1–13.
- [84] Zhang X, Zhao S, Zhang Y, et al. APA-BI: adaptive partition aggregation and bidirectional integration for UAV-view geo-localization[C]//Proceedings of IEEE International Conference on Robotics and Automation. IEEE, 2025: 4175-4181.
- [85] Liao H, Tu J, Xia J, et al. Ascend: a scalable and unified architecture for ubiquitous deep neural network computing[C]//Proceedings of IEEE International Symposium on High-Performance Computer Architecture. IEEE, 2021: 789-801.

致 谢

时光荏苒，为期三年的硕士研究生生涯即将落幕。当这篇承载着心血与思考的论文画上句点，回望这段深耕学术、砥砺成长的旅程，心中满是感恩与不舍。从初入校园的懵懂探索，到课题研究的攻坚克难，再到论文的反复打磨，每一步前行都离不开师长、同窗、家人的鼎力支持与温暖陪伴。在此，我谨以最诚挚的心意，向所有给予我帮助与关怀的人致以最衷心的感谢。

首先，我要向我的导师魏倩茹致以最崇高的敬意与最诚挚的感谢。在我遭遇研究瓶颈、陷入迷茫困惑时，导师总能耐心倾听我的困惑，用通俗易懂的讲解为我拨开迷雾，给予我宝贵的指导建议；在我懈怠退缩时，导师的鼓励与鞭策，让我重新坚定信念、迎难而上。三年来，导师不仅在学术上为我传道授业解惑，更在为人处世、品格修养上为我树立了榜样，让我在成长路上收获颇丰。师恩难忘，这份教诲与关怀，将永远激励我在未来的工作中脚踏实地、精益求精。

感谢我的同门师兄姐妹与各位同窗好友。在科研路上，我们并肩作战、相互扶持，一起探讨研究中的难点问题，分享研究中的收获与喜悦。每当我在实验中遇到困难、在论文撰写中陷入瓶颈时，同门们总能毫无保留地分享自己的经验与思路，给予我无私的帮助与支持；在日常学习生活中，我们相互鼓励、共同进步，一起度过了这段充实而难忘的时光。是你们的陪伴，让枯燥的科研生活多了一份温暖与乐趣；是你们的鼓励，让我在成长路上不再孤单。这段珍贵的同窗情谊，将成为我人生中宝贵的财富，值得我永远珍藏。

最要感谢的，是我最亲爱的家人。你们是我坚实的后盾，是我前行路上最温暖的港湾。三年来，你们默默付出、无私奉献，包容我的任性与疲惫，理解我的忙碌与追求，始终给予我最坚定的支持与最真挚的关爱。无论是物质上的保障，还是精神上的慰藉，都让我能够毫无后顾之忧地投入到学习与科研中。你们的理解、支持与期盼，是我克服困难、勇往直前的不竭动力。在此，向你们道一声：辛苦了，我爱你们。

聚散终有时，感恩伴我行。硕士研究生生涯的结束，是一段旅程的终点，更是另一段旅程的起点。未来，我将带着这段时光里收获的知识、经验与感动，带着师长、同窗与家人的期盼与祝福，不忘初心、砥砺前行，在学术道路上继续深耕细作，在人生道路上勇敢追逐梦想，努力成为更好的自己，不辜负所有关心与帮助过我的人。

最后，再次向所有给予我帮助与关怀的师长、同窗、家人致以最衷心的感谢与最美好的祝福！

在学期间发表的学术成果和参加科研情况

一、参与的科研项目：

[1] 2023.7-2023.12 xxxxx 环境视觉增强技术设计与实现[军口横向]，负责天气检测算法的开发

[2] 2023.12-2025.1 xxxxx 环境三维构建技术设计与实现[军口国家级纵向]，负责无人机自定位算法的设计、开发与实现

[3] 2023.11-2024.01 面向巡飞器机载平台的全天时目标跟踪和定位系统软件开发，负责无人机视角的目标检测与跟踪算法的设计、开发与实现

二、专利：

[1] 基于无人机与卫星视图的图像配准的地理定位方法（受理中）

西北工业大学

学位论文使用授权声明

本人完全了解学校有关保护知识产权的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属于西北工业大学。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版。本人允许论文被查阅和借阅。学校可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时本人保证，毕业后结合学位论文研究课题再撰写的文章一律注明作者单位为西北工业大学。

本学位论文属于（在以下方框内打“√”）：

☐ 保密论文，保密期（ 年 月 日至 年 月 日）。

☒ 公开论文。

学位论文作者签名：黄如意，
2026年6月7日

指导教师签名：魏倩茹
2026年6月7日

西北工业大学

学位论文原创性声明

秉承学校严谨的学风和优良的科学道德，本人郑重声明：所呈交的学位论文，是本人在导师的指导下进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容和致谢的地方外，本论文不包含任何其他个人或集体已经公开发表或撰写过的研究成果，不包含本人或他人已申请学位或其他用途使用过的成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

本人学位论文与资料若有不实，愿意承担一切相关的法律责任。

学位论文作者签名：黄如意
2026年6月7日

